EST-744

Mecanismos de Atención

Juan Zamora O.

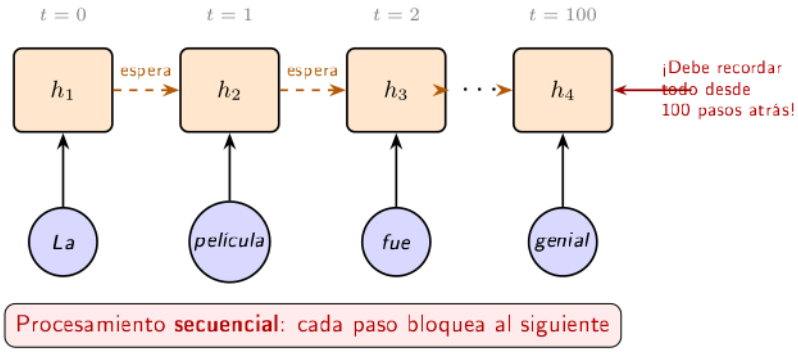
Deep Learning





El Problema: Cuello de Botella Secuencial

Las RNN procesan una palabra a la vez, creando un cuello de botella:

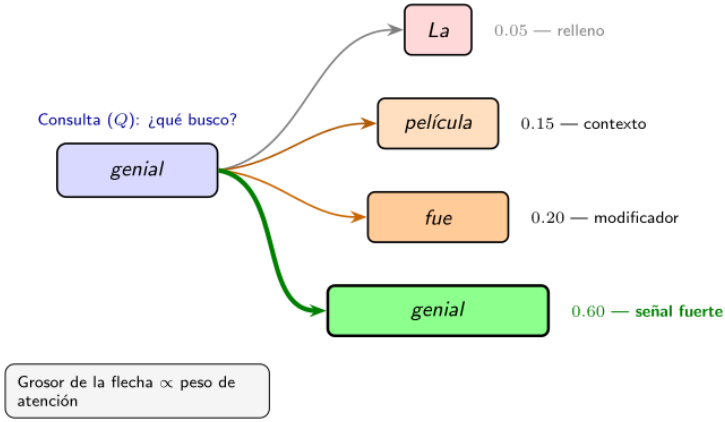


Problemas:

- No se puede paralelizar (hay que procesar en secuencia)

Selección Suave

En lugar de leer de izquierda a derecha, la **atención** permite enfocarse en las palabras relevantes:



La Matemática (Intuitiva)

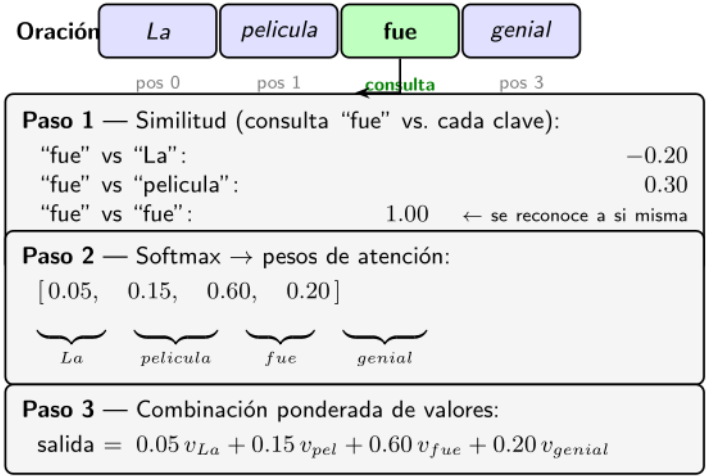
$$\text{Atención}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

Paso a paso:

1. **Consulta** Q: proyección lineal de la posición actual — "¿qué busco?"
2. **Producto** QK^T: similitud entre la consulta y cada clave — "¿cuánto encaja cada palabra?"
3. **Escala** $/\sqrt{d_k}$: evita que los productos internos crezcan demasiado y saturen el softmax
4. **Softmax**: convierte similitudes en pesos de atención (entre 0 y 1, suman 1)
5. **Valores** V: combinación ponderada de los vectores de palabras

Vaswani et al. (2017), sección 3.2. Para una derivación paso a paso: Alammar (2018), "The Illustrated Transformer" — `jalammar.github.io/illustrated-transformer`

¿Qué atiende la palabra “fue”?

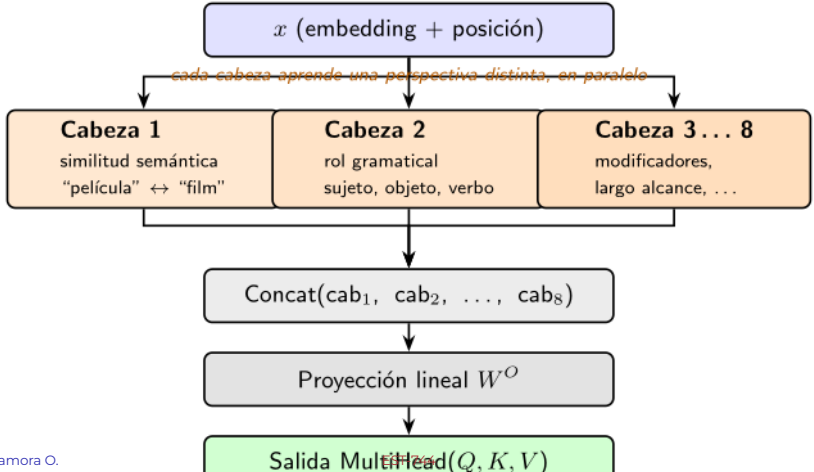


La representación final de “fue” incorpora información de toda la oración,

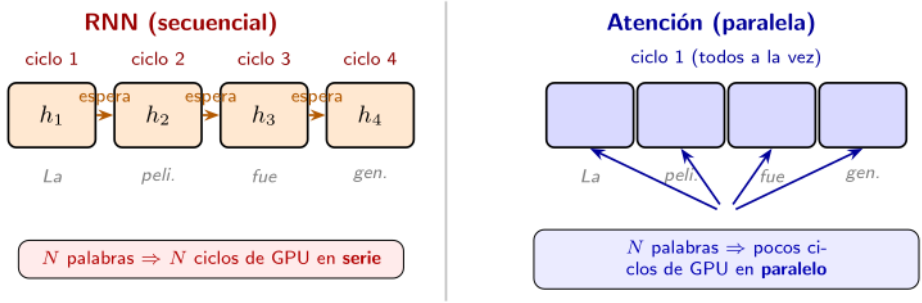
Múltiples Perspectivas Simultáneas

Una sola cabeza de atención no captura todas las relaciones posibles.

Solución: usar varias cabezas (***heads***), cada una aprendiendo patrones distintos:



RNN vs. Atención



Ganancia de velocidad: **10–50**× en secuencias largas

Métrica	RNN/LSTM	Atención
Procesamiento	Secuencial	**Paralelo**
Ganancia en velocidad	1× (base)	**10–50×** en secuencias largas
Uso de GPU	Bajo (un paso a la vez)	**Alto** (todos los pares)

¿Cómo Sabe la Atención el Orden?

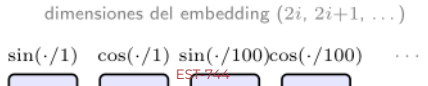
La atención trata todas las palabras por igual: no tiene noción de posición.

Problema: “El perro mordió al hombre” ≠ “El hombre mordió al perro” producirían la misma representación sin información posicional.

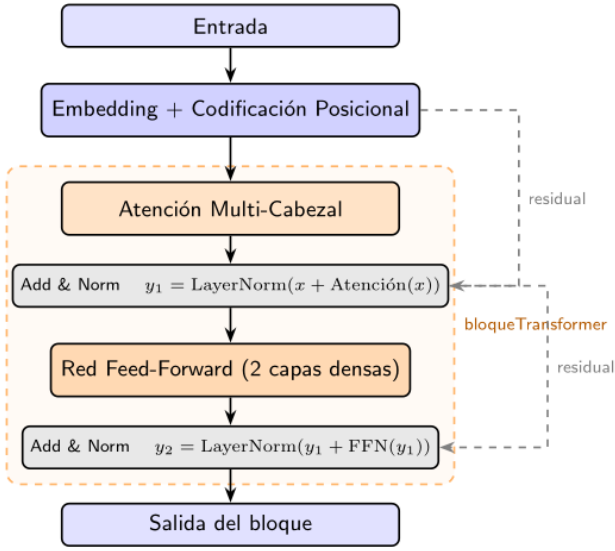
Solución: sumar una **codificación posicional** al embedding de cada palabra:

$$PE(\text{pos},\, 2i) = \sin\left(\frac{\text{pos}}{10000^{2i/d}}\right)$$
$$PE(\text{pos},\, 2i+1) = \cos\left(\frac{\text{pos}}{10000^{2i/d}}\right)$$

Cada posición recibe un patrón sinusoidal único que varía a distintas frecuencias:



Las Piezas Ensambladas



Usar la Capa Incorporada

TensorFlow 2.x incluye `MultiHeadAttention` lista para usar:

```
capa_atencion = keras.layers.MultiHeadAttention(
    num_heads=8,        # numero de cabezas independientes
    key_dim=64          # dimension por cabeza (total = key_dim x num_heads)
)

# Auto-atencion: la secuencia atiende a si misma
salida = capa_atencion(query=x, value=x, key=x)
```

Parámetros clave:

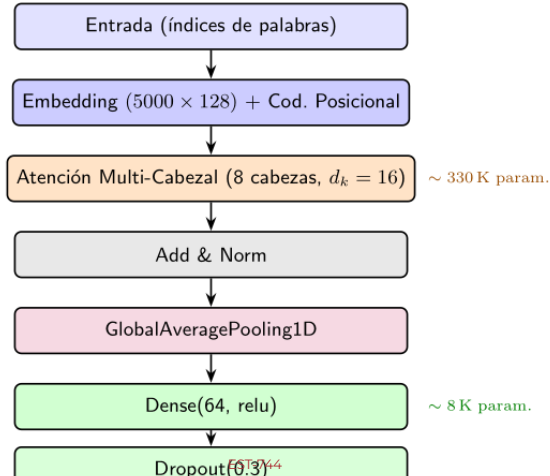
Parámetro	Significado	Valor típico
`num_heads`	Cabezas independientes	4–16
`key_dim`	Dimensión por cabeza	32–128
`dropout`	Regularización en los pesos	0.1–0.3

El código completo del modelo, codificación posicional, entrenamiento y visualización

Tarea y Arquitectura

Objetivo: clasificar reseñas de IMDb como positivas/negativas usando atención

Arquitectura del clasificador:



Rendimiento y Velocidad

Modelo	Precisión	Tiempo/época	Paralelizable
Embeddings promediados	0.88	2 seg	Ok
LSTM	0.92	45 seg	X (secuencial)
CNN	0.91	8 seg	Ok
Atención	**0.92**	**10 seg**	**Ok (totalmente)**

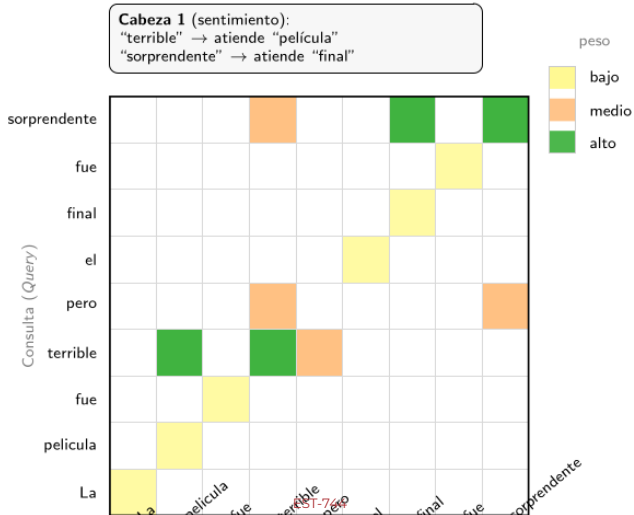
Ventajas de la atención:

- Precisión comparable a LSTM
- Mucho más rápido (paralelizable)
- Mejor escalabilidad a secuencias largas
- **Interpretable**: los pesos de atención muestran en qué se enfocó el modelo

Tiempos medidos en GPU NVIDIA T4. En CPU la ganancia relativa es similar pero los tiempos absolutos son mayores.

¿Qué Está Mirando el Modelo?

Los pesos de atención permiten **interpretar** las decisiones del modelo:



Lo Que Hemos Aprendido

Ok **Cuello de botella RNN**: procesamiento secuencial limita velocidad y memoria

Ok **Selección suave**: la atención pondera todas las palabras en lugar de elegir una

Ok **Marco Consulta-Clave-Valor**: formalización matemática de la atención

Ok **Atención multi-cabezal**: múltiples perspectivas aprendidas en paralelo

Ok **Codificación posicional**: sinusoides que preservan el orden de la secuencia

Ok **Bloque Transformer**: atención + conexión residual + normalización + FFN

Ok **Paralelización**: 10–50× más rápido que RNN en secuencias largas

Por Qué Importa

La atención es el **mecanismo central** de BERT, GPT y todos los modelos modernos de NLP. Comprender su funcionamiento es imprescindible para la Clase 5.

Diagnóstico

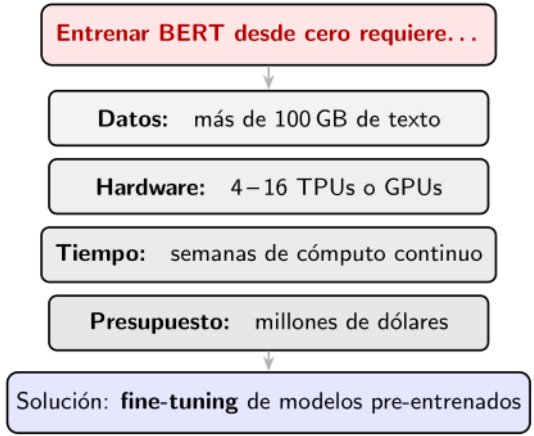
Problema	Causa	Solución
Toda la atención a una sola palabra	Entrenamiento insuficiente	Entrenar más épocas; aumentar tasa de aprendizaje
Atención uniforme (sin foco)	Modelo muy simple	Agregar más cabezas o capas más profundas
Error de memoria	Muchas cabezas × dimensiones altas	Reducir `key_dim` o `num_heads`
Entrenamiento lento	Implementación ineficiente	Usar capas integradas de Keras, no implementación manual
Sobreajuste severo	Pocos datos o modelo muy grande	Agregar `dropout` en atención y capas densas

Tareas Prácticas

1. **Visualizar atención**: obtener pesos de atención para 10 reseñas. ¿Los patrones tienen sentido lingüístico?
2. **Variar `num_heads`**: probar 2, 4, 8 y 16 cabezas. ¿Más siempre es mejor?
3. **Comparar con LSTM**: entrenar LSTM con los mismos hiperparámetros. ¿Cuánto gana la atención en velocidad?
4. **Ablación posicional**: entrenar sin codificación posicional. ¿Cuánto impacta en la precisión?
5. **Interpretabilidad**: para reseñas mal clasificadas, ¿qué atendió el modelo? ¿Explica el error?
6. **Escala**: entrenar con secuencias de largo 100, 500 y 1000. Comparar tiempo de época: Atención vs. LSTM.

De Bloques a Modelos Pre-entrenados

La atención es poderosa, pero entrenar desde cero es costoso:



Para Profundizar

- **Vaswani et al. (2017).** “Attention Is All You Need.” ***NeurIPS***. `arxiv.org/abs/1706.03762` — El artículo fundacional de los Transformers; lectura obligatoria.
- **Bahdanau, Cho & Bengio (2015).** “Neural Machine Translation by Jointly Learning to Align and Translate.” ***ICLR***. `arxiv.org/abs/1409.0473` — Origen del mecanismo de atención para secuencias.
- **Alammar, J. (2018).** “The Illustrated Transformer.” `jalammar.github.io/illustrated-transformer` — La explicación visual más recomendada; sin necesidad de código previo.
- **Goodfellow, Bengio & Courville (2016).** ***Deep Learning***, Cap. 12. MIT Press. `deeplearningbook.org` — Marco teórico de modelos de secuencias.
- **Clark et al. (2019).** “What Does BERT Look at?” ***ACL Workshop***. `arxiv.org/abs/1906.04341` — Análisis empírico de qué aprenden las cabezas de atención.

Preguntas y Discusión

¡Gracias!

Conclusión clave: Los mecanismos de atención permiten que cada palabra “vea” a todas las demás de forma instantánea y paralela. Esta combinación de expresividad y eficiencia computacional es la razón por la que los Transformers dominan el NLP moderno.

Siguiente: Arquitectura completa del Transformer y modelos pre-entrenados (BERT, GPT)