MSC-011

Juan Zamora O.

Octubre, 2023.





Estructura de la Presentación

1. Revisitando técnicas basadas en representantes
2. DBSCAN Clustering
3. OPTICS Clustering

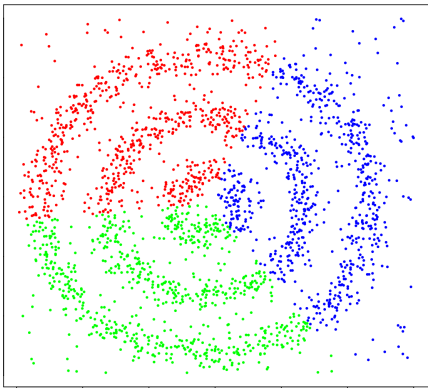
Revisitando técnicas basadas en representantes

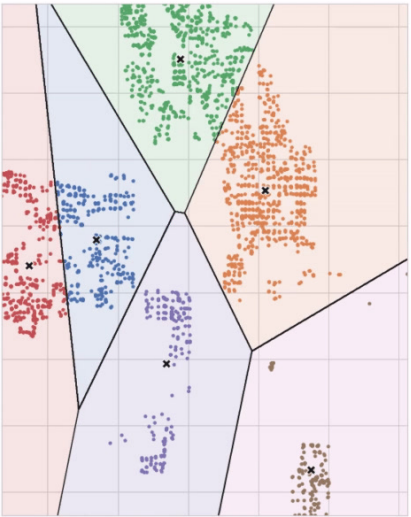
Supuesto bastante usado

- Grupos/Clusters generados a partir de una distribución o mezcla de distribuciones simétricas (e.g. Normal)
- Expectation Maximization, K-Means y extensiones por mencionar algunos

Enfoque basado en densidad no supone forma específica.

- Útil por ejemplo en datos geo-espaciales.

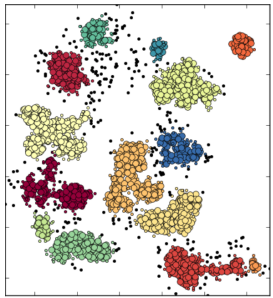




- Minimización de la distancia al cuadrado entre los puntos y sus respectivos centroides produce a un particionamiento tipo polígono de Voronoi. Esto no solo ocurren en 2D
- **Urge** contar con mecanismos de descubrimiento de grupos
  - con forma arbitraria.
  - identificando ruido
  - que no requieran de k

Clustering basado en densidad

- *Grupos basados en densidad* se definen como areas densas y conectadas, *separadas* entre sí por áreas de menor densidad.
- El ruído se define como áreas con densidad menor que la de los clusters
- Noción de *Localidad* asociada a la definición de cluster
  - Posibilita encontrar regiones densas con forma arbitraria



DBSCAN Clustering

- Cuenta la cantidad de puntos en vecindarios de radio fijo (ϵ)

$$N_\epsilon(p) = \{q \in \mathbf{D} | dist(p,q) \leq \epsilon\}$$

- Considera dos puntos conectados cuando son vecinos recíprocos
- Un *core-point* es aquel cuyo vecindario contiene *al menos MinPts* puntos
  - Es decir, punto cuya densidad excede un determinado umbral.
- Un punto q es alcanzable de manera directa (*directly-density-reachable*) por un *core-point* p si se encuentra en su vecindario,

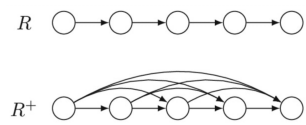
$$|N_\epsilon(p)| \geq MinPts \, y \, q \in N_\epsilon(p)$$

- Alcance (*density-reachable*(R)) queda dado por la clausura transitiva de la relación *directly-density-reachable*(DR)

$$q \mathsf{R} p \exists p_1, \dots, p_m \text{ con } p_1 = p \, y \, p_m = q \;\; t.q. \;\; p_{i+1} \mathsf{DR} p_i$$

- Dos puntos p y q están conectados por densidad (*density-connected*) si existe otro r a partir del cual ambos son *density-reachable*
- Un **cluster** es entonces un conjunto de puntos conectados por densidad (*density-connected*(C))
  - maximal respecto de *density-reachability*

$$q \mathsf{C} p, \exists r \;\; t.q. \;\; r \mathsf{R} p \wedge r \mathsf{R} q$$



- Ruido se define como aquel conjunto de puntos que no pertenecen a ningún cluster

OPTICS Clustering

- Dificil caracterizar estructura intrinseca de grupos mediante parámetros globales de densidad
- Pueden existir grupos de diversa densidad en distintas regiones del espacio
- *Idea base*: Grupos de mayor densidad están contenidos en grupos con menor densidad
- Se construyen *simultaneamente* grupos con diferentes densidades para un valor fijo de *MinPts*

Conceptos relevantes

OPTICS introduce dos conceptos:

1. *Core-distance*: Valor ϵ más pequeño para un punto p que lo convierte en *core-point*.
2. *reachability-distance*: Distancia más pequeña entre un par de puntos p y q que los hace directamente alcanzables

Además usa un gráfico (*reachability plot*) que muestra la densidad y conectividad de los puntos. **Útil** para distinguir clusters

