MSC-011

Fundamentos de Ciencia de Datos

Juan Zamora O.

Octubre 2023





Estructura de la Presentación

1. Revisitando técnicas basadas en representantes
2. DBSCAN Clustering
3. OPTICS Clustering

INSTITUTO DE ESTADÍSTICA
IES PUCV

Revisitando técnicas basadas en representantes

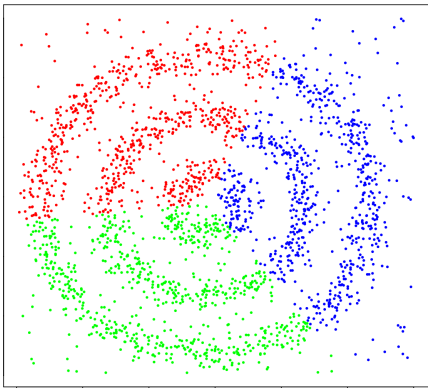
Supuesto bastante usado

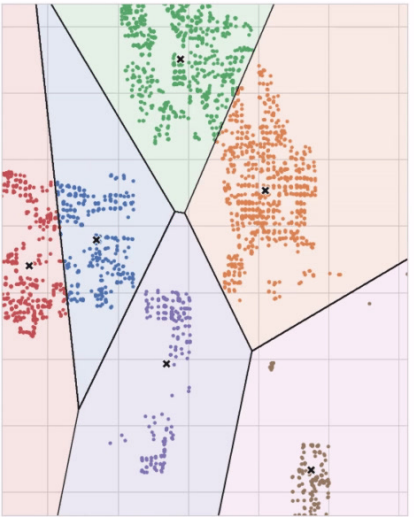
- Grupos/Clusters generados a partir de una distribución o mezcla de distribuciones simétricas (e.g. Normal)
- Expectation Maximization, K-Means y extensiones por mencionar algunos

Enfoque basado en densidad no supone forma específica.

- Útil por ejemplo en datos geo-espaciales.

INSTITUTO DE ESTADÍSTICA IES PUCV



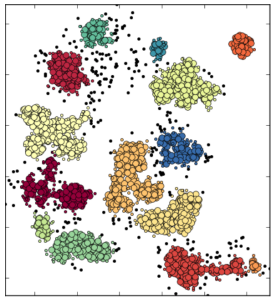


INSTITUTO DE ESTADISTICA
IES PUCV

- Minimización de la distancia al cuadrado entre los puntos y sus respectivos centroides produce a un particionamiento tipo polígono de Voronoi. Esto no solo ocurren en 2D
- **Urge** contar con mecanismos de descubrimiento de grupos
  - con forma arbitraria.
  - identificando ruido
  - que no requieran de k

Clustering basado en densidad

- *Grupos basados en densidad* se definen como areas densas y conectadas, *separadas* entre sí por áreas de menor densidad.
- El ruído se define como áreas con densidad menor que la de los clusters
- Noción de *Localidad* asociada a la definición de cluster
  - Posibilita encontrar regiones densas con forma arbitraria



INSTITUTO DE ESTADÍSTICA IES PUCV

DBSCAN Clustering

- Cuenta la cantidad de puntos en vecindarios de radio fijo (ϵ)

$$N_\epsilon(p) = \{q \in \mathbf{D} | dist(p, q) \leq \epsilon\}$$

- Considera dos puntos conectados cuando son vecinos recíprocos
- Un *core-point* es aquel cuyo vecindario contiene *al menos MinPts* puntos
  - Es decir, punto cuya densidad excede un determinado umbral.
- Un punto q es alcanzable de manera directa (*directly-density-reachable*) por un *core-point* p si se encuentra en su vecindario,

$$|N_\epsilon(p)| \geq MinPts \; y \; q \in N_\epsilon(p)$$

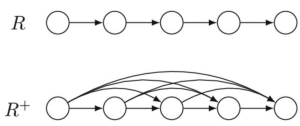
INSTITUTO DE ESTADÍSTICA IES PUCV

- Alcance (*density-reachable*(R)) queda dado por la clausura transitiva de la relación *directly-density-reachable*(DR)

$$q \mathrm{R} p \exists p_1, \ldots, p_m \text{ con } p_1 = p \; y \; p_m = q \;\; t.q. \;\; p_{i+1} \mathrm{DR} p_i$$

- Dos puntos p y q están conectados por densidad (*density-connected*) si existe otro *r* a partir del cual ambos son *density-reachable*
- Un **cluster** es entonces un conjunto de puntos conectados por densidad (*density-connected*(C))
  - maximal respecto de *density-reachability*

$$q \mathrm{C} p, \exists r \;\; t.q. \;\; r \mathrm{R} p \; \wedge r \mathrm{R} q$$



- Ruido se define como aquel conjunto de puntos que no pertenecen a ningún cluster

INSTITUTO DE ESTADÍSTICA
IES PUCV

OPTICS Clustering

- Dificil caracterizar estructura intrinseca de grupos mediante parámetros globales de densidad
- Pueden existir grupos de diversa densidad en distintas regiones del espacio
- *Idea base*: Grupos de mayor densidad están contenidos en grupos con menor densidad
- Se construyen *simultaneamente* grupos con diferentes densidades para un valor fijo de *MinPts*

INSTITUTO DE ESTADISTICA IES PUCV

Conceptos relevantes

OPTICS introduce dos conceptos:

1. *Core-distance*: Valor ϵ más pequeño para un punto p que lo convierte en *core-point*.
2. *reachability-distance*: Distancia más pequeña entre un par de puntos p y q que los hace directamente alcanzables

Además usa un gráfico (*reachability plot*) que muestra la densidad y conectividad de los puntos. **Útil** para distinguir clusters

