MSC-011

Fundamentos de Ciencia de Datos

Juan Zamora O.

Octubre 2023





Estructura de la Presentación

1. Clustering basado en representantes
2. Algoritmo Kernel K-Means
3. Clustering Spectral

INSTITUTO DE ESTADÍSTICA
IES PUCV

Clustering basado en representantes

- Dado un conjunto de datos con n puntos en un espacio d-dimensional, $\mathcal{D} = \{\mathbf{x}_j\}_{j=1}^{n}$
- Dado también $k \in \mathbb{Z}$, el número de grupos a encontrar en $\mathcal{D}$
- El **objetivo** de la tarea es particionar $\mathcal{D}$ en k grupos o *clusters*, representados como $\mathcal{C} = \{C_1, C_2, \ldots, C_k\}$
- Luego, para cada cluster C_i existe un punto representativo μ_i
  - Comúnmente se le denomina centroide y corresponde a

$$\mu_i = \frac{1}{|C_i|} \sum_{\mathbf{x}_j \in C_i} \mathbf{x}_j$$

INSTITUTO DE ESTADÍSTICA
IES PUCV

Método de Fuerza bruta

Una posible solución a este problema consiste en

1. Generar todos las posibles particiones de n puntos en k grupos, $\binom{n}{k}$
2. Para cada una, evaluar alguna puntuación que favorezca *ciertas propiedades*
   - Podría usarse

$$SSE(\mathscr{C}) = \sum_{i=1}^{k} \sum_{\mathbf{x}_j \in C_i} \|\mathbf{x}_j - \mu_i\|^2$$

3. Reportar aquella partición con la mejor puntuación, es decir

$$\mathscr{C}^* = \arg\min_{\mathscr{C}} SSE(\mathscr{C})$$

Problema $\mathcal{O}(k^n/k!)$ posibles soluciones …

INSTITUTO DE ESTADÍSTICA IES PUCV

Algoritmo K-Means

- K-Means utiliza una estrategia *Greedy* e iterativa para encontrar $\mathscr{C}^*$
  1. Inicializa los centroides al azar, generando k puntos en $\mathbb{R}^d$
  2. Comienza a iterar y en cada iteración realiza dos pasos: Asignación a un grupo y actualización de centroides
  3. Cada punto es asignado al grupo asociado al centroide más cercano.
  4. Se actualizan los centroides, calculando nuevamente las medias sobre los puntos asignados en el paso anterior.
  5. Al alcanzarse una cierta cantidad de iteraciones, no haber cambios en las asignaciones o bien, no encontrarse cambios significativos, el método termina.

INSTITUTO DE ESTADÍSTICA
IES PUCV

K-MEANS (D, k, ϵ):

$t = 0$

Randomly initialize k centroids: $\boldsymbol{\mu}_1^t, \boldsymbol{\mu}_2^t, \ldots, \boldsymbol{\mu}_k^t \in \mathbb{R}^d$

repeat

  $t \leftarrow t + 1$

  $C_j \leftarrow \emptyset$ for all $j = 1, \cdots, k$

  `// Cluster Assignment Step`

  foreach $\mathbf{x}_j \in \mathbf{D}$ **do**

    $j^* \leftarrow \arg\min_i \left\{ \left\| \mathbf{x}_j - \boldsymbol{\mu}_i^t \right\|^2 \right\}$ `// Assign` $\mathbf{x}_j$ `to closest centroid`

    $C_{j^*} \leftarrow C_{j^*} \cup \{\mathbf{x}_j\}$

  `// Centroid Update Step`

  foreach $i = 1$ *to* k **do**

    $\boldsymbol{\mu}_i^t \leftarrow \frac{1}{|C_i|} \sum_{\mathbf{x}_j \in C_i} \mathbf{x}_j$

until $\sum_{i=1}^k \left\| \boldsymbol{\mu}_i^t - \boldsymbol{\mu}_i^{t-1} \right\|^2 \leq \epsilon$

INSTITUTO DE ESTADÍSTICA IES PUCV

Algoritmo Kernel K-Means

- K-means realiza una separación en el espacio original de características de los datos
- El uso del *Kernel Trick* puede ayudar a construir grupos usando transformaciones no-lineales de este espacio

INSTITUTO DE ESTADÍSTICA
IES PUCV

- Se mapea cada $\mathbf{x_j} \in \mathscr{C}$ mediante $\phi(\mathbf{x_j})$
- Una función de kernel $\mathbf{K}$ es aplicada sobre cada par de puntos, $\mathbf{K}(\mathbf{x_i}, \mathbf{x_j}) = \phi(\mathbf{x_i})^T \phi(\mathbf{x_j})$
- Se aplica K-Means en este nuevo espacio
- La nueva función objetivo en el espacio de características es:

$$\min_{\mathscr{C}} SSE(\mathscr{C}) = \sum_{i=1}^{k} \sum_{\mathbf{x}_j \in C_i} \|\phi(\mathbf{x}_j) - \mu_i^{\phi}\|^2$$

$$\min_{\mathscr{C}} SSE(\mathscr{C}) = \sum_{j=1}^{n} \mathbf{K}(\mathbf{x}_j, \mathbf{x}_j) - \sum_{i=1}^{k} \frac{1}{|C_i|} \sum_{\mathbf{x}_p \in C_i} \sum_{\mathbf{x}_q \in C_i} \mathbf{K}(\mathbf{x}_p, \mathbf{x}_q)$$

INSTITUTO DE ESTADÍSTICA IES PUCV

KERNEL-KMEANS($\mathbf{K}, k, \epsilon$):

$t \leftarrow 0$

$\mathcal{C}^t \leftarrow \{C_1^t, \ldots, C_k^t\}$ // Randomly partition points into k clusters

repeat

  $t \leftarrow t+1$

  foreach $C_i \in \mathcal{C}^{t-1}$ **do** // Squared norm of cluster means

    $\text{sqnorm}_i \leftarrow \frac{1}{n_i^2} \sum_{\mathbf{x}_a \in C_i} \sum_{\mathbf{x}_b \in C_i} K(\mathbf{x}_a, \mathbf{x}_b)$

  foreach $\mathbf{x}_j \in \mathbf{D}$ **do** // Average kernel value for $\mathbf{x}_j$ and C_i

    foreach $C_i \in \mathcal{C}^{t-1}$ **do**

      $\text{avg}_{ji} \leftarrow \frac{1}{n_i} \sum_{\mathbf{x}_a \in C_i} K(\mathbf{x}_a, \mathbf{x}_j)$

  // Find closest cluster for each point

  foreach $\mathbf{x}_j \in \mathbf{D}$ **do**

    foreach $C_i \in \mathcal{C}^{t-1}$ **do**

      $d(\mathbf{x}_j, C_i) \leftarrow \text{sqnorm}_i - 2 \cdot \text{avg}_{ji}$

    $j^* \leftarrow \arg\min_i \{d(\mathbf{x}_j, C_i)\}$

    $C_{j^*}^t \leftarrow C_{j^*}^t \cup \{\mathbf{x}_j\}$ // Cluster reassignment

  $\mathcal{C}^t \leftarrow \{C_1^t, \ldots, C_k^t\}$

until $1 - \frac{1}{n} \sum_{i=1}^{k} \left| C_i^t \cap C_i^{t-1} \right| \leq \epsilon$

INSTITUTO DE ESTADÍSTICA IES PUCV

Vista general del método

1. Pre-procesamiento: Construir una representación de grafo (matriz)
2. Descomposición:
   - Calcular los valores y vectores propios de la matriz
   - Mapear cada punto en $\mathscr{D}$ a una representación vectorial basado en uno o más vectores propios
3. Agrupar
   - Asignar todos los puntos a 2 o más grupos, usando la nueva representación vectorial

INSTITUTO DE ESTADÍSTICA IES PUCV

Particionamiento espectral de un grafo

- Dado un grafo $G = (V, E)$, con $V = \{1, 2, \dots, n\}$ y $E : V \times V \to \{0, 1\}$
- A: Matriz de adyacencia de un grafo no dirigido que codifica los vecindarios de cada nodo en G
  - $A_{ij} = 1$ cuando existe conexión entre instancias i y j. 0 en otro caso.
  - Simétrica
  - Tiene n valores propios
  - Vectores propios reales y ortogonales
- D: Matriz de grados
  - $D = [d_{ii}]$, donde d_{ii} es el grado del nodo i
  - Es diagonal

INSTITUTO DE ESTADÍSTICA IES PUCV

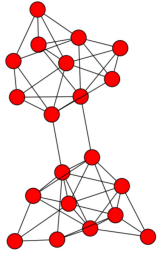
Laplaciano

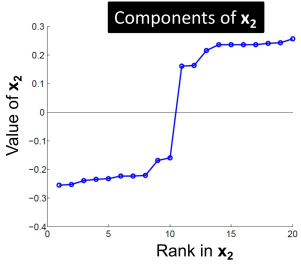
- $L = D - A$: Matriz Laplaciano
- Todos sus valores propios son ≥ 0
- $xLx = \sum_{ij} L_{ij} x_i x_j \geq 0$ para todo x
- Multiplicidad del primer valor propio es igual al número de componentes conectados
- Si vértices i y j están conectados en el grafo, en algún vector propio asociado al primer valor propio las conmponentes i y j serán 1

INSTITUTO DE ESTADÍSTICA IES PUCV

Clustering

- El segundo valor propio es clave
- El vector propio de este segundo valor será usado para encontrar los grupos
- **Obj.** Minimizar la cantidad de arcos de una partición a otra.
- Este vector es real, no tiene etiquetas $\{-1, +1\}$
  - Puede usarse la función signo

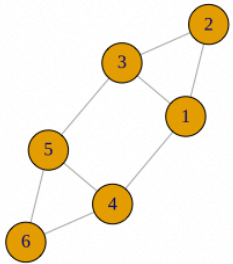




¿Cómo generar más de 2 clusters?

- Tomar los k vectores propios asociados a los valores propios más pequeños
- Esta matriz de $n \times k$ es entregada a otro método (e.g. K-Means)

INSTITUTO DE ESTADÍSTICA IES PUCV



- **Adyacencia**

$$\begin{bmatrix} 0 & 1 & 1 & 1 & 0 & 0 \\ 1 & 0 & 1 & 0 & 0 & 0 \\ 1 & 1 & 0 & 0 & 1 & 0 \\ 1 & 0 & 0 & 0 & 1 & 1 \\ 0 & 0 & 1 & 1 & 0 & 1 \\ 0 & 0 & 0 & 1 & 1 & 0 \end{bmatrix}$$

- **Grado**

$$\begin{bmatrix} 3 & 0 & 0 & 0 & 0 & 0 \\ 0 & 2 & 0 & 0 & 0 & 0 \\ 0 & 0 & 3 & 0 & 0 & 0 \\ 0 & 0 & 0 & 3 & 0 & 0 \\ 0 & 0 & 0 & 0 & 3 & 0 \\ 0 & 0 & 0 & 0 & 0 & 2 \end{bmatrix}$$

INSTITUTO DE ESTADÍSTICA
IES PUCV

Las otras matrices …

- $L = D - A$

- **Laplaciano**

$$\begin{bmatrix} 3 & -1 & -1 & -1 & 0 & 0 \\ -1 & 2 & -1 & 0 & 0 & 0 \\ -1 & -1 & 3 & 0 & -1 & 0 \\ -1 & 0 & 0 & 3 & -1 & -1 \\ 0 & 0 & -1 & -1 & 3 & -1 \\ 0 & 0 & 0 & -1 & -1 & 2 \end{bmatrix}$$

- **Valores propios**

$$\begin{bmatrix} 0 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 3 & 0 & 0 & 0 \\ 0 & 0 & 0 & 3 & 0 & 0 \\ 0 & 0 & 0 & 0 & 4 & 0 \\ 0 & 0 & 0 & 0 & 0 & 5 \end{bmatrix}$$

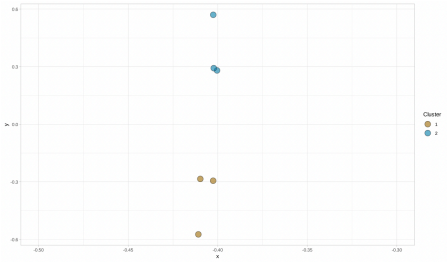
- **Vectores propios**

$$\begin{bmatrix} -0{,}408 & 0{,}289 & 0 & -0{,}577 & -0{,}408 & 0{,}5 \\ -0{,}408 & 0{,}577 & 0{,}5 & 0{,}289 & 0{,}408 & 0 \\ -0{,}408 & 0{,}289 & -0{,}5 & 0{,}289 & -0{,}408 & -0{,}5 \\ -0{,}408 & -0{,}289 & 0 & -0{,}577 & 0{,}408 & -0{,}5 \\ -0{,}408 & -0{,}289 & -0{,}5 & 0{,}289 & 0{,}408 & 0{,}5 \\ -0{,}408 & -0{,}577 & 0{,}5 & 0{,}289 & -0{,}408 & 0 \end{bmatrix}$$

INSTITUTO DE ESTADÍSTICA IES PUCV

Datos proyectados sobre los vectores propios

$$\left(\begin{array}{cc|cccc} -0{,}408 & 0{,}289 & 0 & -0{,}577 & -0{,}408 & 0{,}5 \\ -0{,}408 & 0{,}577 & 0{,}5 & 0{,}289 & 0{,}408 & 0 \\ -0{,}408 & 0{,}289 & -0{,}5 & 0{,}289 & -0{,}408 & -0{,}5 \\ -0{,}408 & -0{,}289 & 0 & -0{,}577 & 0{,}408 & -0{,}5 \\ -0{,}408 & -0{,}289 & -0{,}5 & 0{,}289 & 0{,}408 & 0{,}5 \\ -0{,}408 & -0{,}577 & 0{,}5 & 0{,}289 & -0{,}408 & 0 \end{array}\right)$$



$$\left(\begin{array}{ccc|ccc} -0{,}408 & 0{,}289 & 0 & -0{,}577 & -0{,}408 & 0{,}5 \\ -0{,}408 & 0{,}577 & 0{,}5 & 0{,}289 & 0{,}408 & 0 \\ -0{,}408 & 0{,}289 & -0{,}5 & 0{,}289 & -0{,}408 & -0{,}5 \\ -0{,}408 & -0{,}289 & 0 & -0{,}577 & 0{,}408 & -0{,}5 \\ -0{,}408 & -0{,}289 & -0{,}5 & 0{,}289 & 0{,}408 & 0{,}5 \\ -0{,}408 & -0{,}577 & 0{,}5 & 0{,}289 & -0{,}408 & 0 \end{array}\right)$$