MSC-011

Fundamentos de Ciencia de Datos

Juan Zamora O.

Octubre 2023





Estructura de la Presentación I

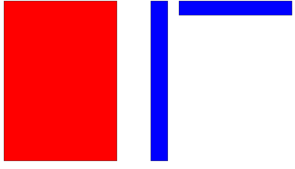
INSTITUTO DE ESTADÍSTICA
IES PUCV

Aproximaciones Low-Rank para Clustering

Una matriz X de rango r admite una factorización de la forma

$$X = BC^T,\ B \in \mathbf{R}^{m \times r},\ C \in \mathbf{R}^{n \times r}$$

X es aproximada con bajo rango (low-rank) cuando $rango(X) << \text{mín}(m, n)$



INSTITUTO DE ESTADÍSTICA IES PUCV

(NMF) Factorización de matrices no-negativas

- Grupo de algoritmos de de análisis multivariado y algebra lineal donde una matriz X es factorizada en dos matrices W y H
- Cada columna de X es aproximada por una combinación lineal no-negativa de las columnas de W, donde los coeficientes de mezcla corresponden a las columnas de H
- Las tres matrices tienen elementos no-negativos
- Usado en sistemas recomendadores, procesamiento de audio, agrupamiento de texto.

INSTITUTO DE ESTADÍSTICA
IES PUCV

NMF

- Dada una matriz no-negativa $X \in \mathbf{R}^{m \times n}$ y un $k \in \mathbf{Z} << \min(m, n)$
- Encuentra matrices no-negativas $W \in \mathbf{R}^{m \times k}$ y $H \in \mathbf{R}^{k \times n}$ tales que minimizan

$$\|X - WH\|_F^2 = \sum_i \sum_j (X_{ij} - [WH]_{ij})^2$$

- W: base para un espacio k-dimensional, la i-ésima columna de H: corresponde a representación k-dim de i-ésima columna de X

INSTITUTO DE ESTADÍSTICA IES PUCV

Aplicación de NMF para extracción de tópicos en texto

- Se construye matriz de terminos vs documentos
- Se aplica NMF para obtener W y H

