MSC-011

Juan Zamora O.

Noviembre, 2023.





Estructura de la Presentación

El objetivo de esta parte del Curso es introducir Topic Models para encontrar grupos de palabras que permitan caracterizar a un conjunto de documentos.

Referencias: Blei et al. 2003

Idea fundamental

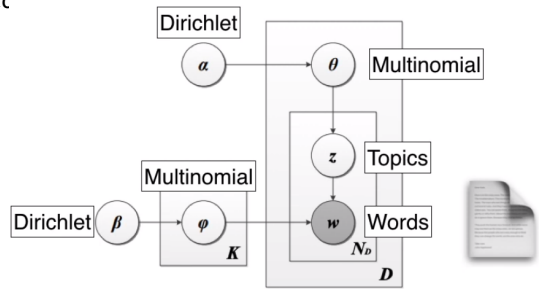
- Documentos son mezclas de tópicos

Que es un tópico?

- Distribución de probabilidad sobre la ocurrencia de palabras

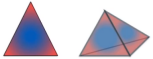
Topic Models

- Modelo *generativo* para documentos
- Documento en blanco con una cierta distribución de tópicos.
- Se escoge un tópico al azar a partir de la distribución.
- Se escoge al azar una palabra a partir de este tópico (recordemos la definición anterior de *tópicc* `



$$P(\boldsymbol{W}, \boldsymbol{Z}, \boldsymbol{\theta}, \boldsymbol{\varphi}; \alpha, \beta) = \prod_{j=1}^{M} P(\theta_j; \alpha) \prod_{i=1}^{K} P(\varphi_i; \beta) \prod_{t=1}^{N} P(Z_{j,t} \mid \theta_j)\, P(W_{j,t} \mid \varphi_{Z_{j,t}})$$







Dirichlet Distributions

Multinomial Distributions

¿De qué sirve esta perspectiva generadora de documentos?

- Existen técnicas estadísticas y computacionales para invertir este procedimiento a partir de documentos existentes (…nuestros documentos), pudiendo así inferir la composición *más probable* de los tópicos que permitieron generar esta colección de documentos.

En esta sección del curso revisaremos Latent− Dirichlet Allocation .

Dirichlet distribution for documents in topics