Sesión 3. Análisis exploratorio de datos de lectura

Sesión 3. Análisis exploratorio de datos de lectura

Sesión 3. Análisis exploratorio de datos de lectura

Módulo de Análisis Exploratorio de Datos, Doctorado en Lingüística.

En la sesión anterior repasamos las estructuras de R sobre datos inventados. Ahora trabajamos con un corpus real, y la pregunta deja de ser cómo funciona una función para pasar a ser qué nos dicen estos datos sobre la lectura.

El apunte tiene dos partes. La primera es un recorrido guiado sobre datos de movimientos oculares de lectura en varias lenguas, que haremos en clase. La segunda es una extensión que cada uno aplicará a un subconjunto de lenguas de su propio interés, repitiendo el análisis. El objetivo de esa segunda parte no es solo practicar: es que el procedimiento quede disponible para sus propias investigaciones.

Una advertencia sobre el formato. A diferencia de la prelectura, aquí casi no se muestran resultados. El código está para ejecutarlo, y los números deben salir de la consola de cada uno. Cuando una pregunta aparece en el texto, es una pregunta genuina cuya respuesta está en los datos.

1. El corpus: MECO

MECO, el Corpus Multilingüe de Movimientos Oculares (***Multilingual Eye-movement Corpus***), es un esfuerzo internacional coordinado de laboratorios de seguimiento ocular. Los participantes leen textos en su lengua materna mientras un rastreador infrarrojo de video registra sus movimientos oculares. Es el conjunto de datos de movimientos oculares multilingües más completo disponible, con más de veinte lenguas representadas entre sus distintas versiones.

Los materiales son doce textos expositivos de estilo enciclopédico, traducidos y adaptados a cada lengua. Cada participante lee los doce textos y responde después preguntas de comprensión. Eso significa que la estructura de los datos es la de un diseño cruzado: cada palabra fue leída por muchos participantes, y cada participante leyó muchas palabras.

1.1 Por qué este corpus para una sesión de EDA

Tres razones.

Primero, contiene los cuatro tipos de variable simultáneamente. Hay variables nominales (la lengua, el participante, el texto), variables binarias (si una palabra fue omitida, si hubo una regresión hacia ella), variables de conteo (número de fijaciones) y

2. Primera inspección y el problema de los faltantes

Cuatro preguntas de inventario:

```r
nrow(meco)                          # observaciones palabra por participar
length(unique(meco$subid))          # participantes
length(unique(meco$lang))           # lenguas
length(unique(meco$itemid))         # textos

table(meco$lang)
```

La tabla por lengua merece atención. Las muestras no son de igual tamaño: el número de participantes varía entre laboratorios. Eso condicionará cualquier comparación posterior y hay que tenerlo presente desde el principio.

```r
# Participantes por lengua, no observaciones
participantes_por_lengua <- tapply(meco$subid, meco$lang,
                                   function(x) length(unique(x)))
sort(participantes_por_lengua)
```

2.1 Faltantes informativos

3. Variables binarias: omisión y regresión

Las medidas oculomotoras binarias son variables nominales, y las herramientas son las mismas que usamos con cualquier variable categórica: tablas de frecuencia, proporciones y gráficos de barras.

```
table(meco$skip)
round(prop.table(table(meco$skip)) * 100, 2)
```

Si la variable está codificada como 0 y 1, su media es directamente la proporción de unos, de modo que no hace falta calcular la tabla para obtener una tasa.

```
mean(meco$skip)                 # tasa global de omisión
mean(meco$reg.in, na.rm = TRUE)  # tasa de regresiones entrantes
```

Las regresiones, o sacádicos retrógrados, son frecuentes en la lectura: la literatura las sitúa entre el cinco y el veinte por ciento de todos los sacádicos. Comprobar dónde cae este corpus dentro de ese rango es la primera verificación empírica de la sesión.

3.1 Comparación entre lenguas

```
omision_por_lengua <- tapply(meco$skip, meco$lang, mean)
```

4. Derivar predictores de la palabra

Hasta aquí las variables venían dadas. Ahora las construiremos. Los dos predictores canónicos del comportamiento ocular durante la lectura son la longitud y la frecuencia de la palabra, y el primero se deriva directamente del texto.

4.1 Longitud de palabra

```
meco$long_palabra <- nchar(meco$ia)

summary(meco$long_palabra)
table(meco$long_palabra)
```

La columna `ia` contiene la palabra como cadena de texto, y `nchar()` obtiene de ella una variable numérica nueva. Es el procedimiento básico para construir un predictor a partir de un campo de texto.

Un detalle que importa en un corpus multilingüe. El recuento de caracteres depende de la codificación, y las lenguas con diacríticos frecuentes o con sistemas de escritura no alfabéticos pueden comportarse de forma inesperada. Verifícalo antes de confiar en los promedios:

```
tapply(meco$long_palabra, meco$lang, mean)
```

5. Del nivel de la palabra al del participante

Hasta aquí cada fila era una palabra leída por un participante. Muchas preguntas, sin embargo, se formulan sobre el lector: cuán rápido lee, con qué frecuencia regresa, cuánto comprende. Eso requiere agregar (***aggregate***).

5.1 La forma de la distribución

Antes de agregar, conviene mirar la distribución de la variable que vamos a resumir.

```
fijadas <- subset(meco, skip == 0)

hist(fijadas$dur, breaks = 100,
     main = "Distribución del tiempo total de lectura por palabra",
     xlab = "Milisegundos")

mean(fijadas$dur)
median(fijadas$dur)
```

La distribución es fuertemente asimétrica hacia la derecha: muchas palabras con duraciones breves y una cola larga de duraciones muy prolongadas. La media y la mediana difieren de forma sustantiva, y la media está siendo desplazada hacia arriba

6. Relaciones entre variables

Ahora las preguntas cruzan dos variables. Es el paso del análisis univariado al bivariado, que estructura el resto del módulo.

6.1 Una variable numérica por una categórica

```
boxplot(dur_media ~ lang, data = por_participante,
        las = 2, cex.axis = 0.8,
        main = "Tiempo medio de lectura por lengua",
        xlab = "", ylab = "Milisegundos")
```

Nota que agregamos primero por participante y comparamos después. Hacer el diagrama de cajas directamente sobre las palabras produciría cajas basadas en decenas de miles de observaciones no independientes, con una dispersión que refleja la variabilidad entre palabras y no entre lectores.

```
medianas <- tapply(por_participante$dur_media, por_participante$lang, median
sort(medianas)
```

6.2 Dos variables numéricas

La relación entre longitud de palabra y tiempo de lectura es el efecto más establecido de la literatura sobre lectura.

7. Extensión: tus propias lenguas

Todo lo anterior se aplica a cualquier subconjunto del corpus, porque la estructura de los datos es la misma para todas las lenguas.

Esta parte es individual y se entrega junto con las actividades. Elige dos lenguas del corpus y justifica la elección con un criterio explícito: pueden ser lenguas relacionadas con tu investigación, tipológicamente contrastantes, o con sistemas de escritura distintos. El criterio importa porque determina qué comparación tiene sentido: contrastar dos lenguas emparentadas responde a una pregunta distinta que contrastar dos lenguas de morfología muy diferente.

7.1 Preparar el subconjunto

```
mis_lenguas <- c("es", "fi")      # ajustar
mi_sub <- subset(meco, lang %in% mis_lenguas)

table(mi_sub$lang)
length(unique(mi_sub$subid))
```

A partir de aquí, todo el código de las secciones 3 a 6 funciona sin cambios sobre `mi_sub`.

8. Cierre

Lo que hicimos en esta sesión responde a una estructura que se repetirá en cualquier análisis exploratorio, con independencia de los datos.

Primero, inventario: qué hay, cuánto hay, qué falta y por qué falta. Segundo, distribuciones univariadas, empezando por las categóricas y binarias y siguiendo por las numéricas, atendiendo siempre a la forma de la distribución antes de resumirla con un solo número. Tercero, construcción de variables derivadas a partir de las disponibles. Cuarto, agregación a otro nivel de análisis, decidiendo explícitamente cuál corresponde a la pregunta. Quinto, relaciones entre variables.

Y a lo largo de todo el proceso, decisiones que hay que documentar. En esta sesión fueron al menos estas: si el análisis se hace sobre todas las palabras o solo sobre las fijadas, si las duraciones se transforman o no, en qué puntos se cortan los grupos de longitud, a qué nivel se agrega antes de comparar y qué coeficiente de correlación se reporta. Ninguna de esas decisiones es obvia y todas afectan los resultados.

La diferencia entre un análisis exploratorio y una serie de gráficos sueltos está, en buena medida, en si esas decisiones quedaron registradas.

Referencias

Siegelman, N., Schroeder, S., Acartürk, C. et al. (2022). Expanding horizons of cross-linguistic research on reading: The Multilingual Eye-movement Corpus (MECO). ***Behavior Research Methods***, 54, 2843-2863.

Siegelman, N. et al. (2025). Wave 2 of the Multilingual Eye-Movement Corpus (MECO): New text reading data across languages. ***Scientific Data***.

Schroeder, S. popEye: An R package to analyze eye-tracking data from reading experiments. https://github.com/sascha2schroeder/popEye

Repositorio de datos de lectura en lengua materna del proyecto MECO: https://osf.io/3527a