Sesión 2. Análisis exploratorio morfosintáctico

Sesión 2. Análisis exploratorio morfosintáctico

Sesión 2. Análisis exploratorio morfosintáctico

Módulo de Análisis Exploratorio de Datos, Doctorado en Lingüística.

En la sesión anterior repasamos las estructuras de R sobre datos inventados. Ahora trabajamos con un corpus real y anotado, y la pregunta deja de ser cómo funciona una función para pasar a ser qué nos dicen estos datos sobre la lengua.

El apunte tiene dos partes. La primera es un recorrido guiado sobre un treebank del español que haremos en clase. La segunda es una extensión que cada uno aplicará a un texto de su propio interés, anotándolo automáticamente y repitiendo el análisis. El objetivo de esa segunda parte no es solo practicar: es que el procedimiento quede disponible para sus propias investigaciones.

Una advertencia sobre el formato de este documento. A diferencia de la prelectura, aquí casi no se muestran resultados. El código está para ejecutarlo, y los números deben salir de la consola de cada uno. Cuando una pregunta aparece en el texto, es una pregunta genuina cuya respuesta está en los datos.

1. El corpus: UD Spanish AnCora

Trabajaremos con el treebank AnCora del español dentro del proyecto Universal Dependencies. Es un corpus de texto periodístico y de ficción anotado morfosintácticamente, cuya anotación fue revisada manualmente. La versión completa contiene alrededor de 17.700 oraciones y 547.000 ocurrencias (***tokens***).

Usaremos el archivo de desarrollo (***dev***), de unas 1.650 oraciones y 53.000 ocurrencias. Es suficiente para todo lo que haremos y se carga en segundos. Quien quiera trabajar después con el corpus completo solo tiene que cambiar el nombre del archivo.

1.1 Descarga

El corpus está en el repositorio público del proyecto:
https://github.com/UniversalDependencies/UD_Spanish-AnCora
Descarga el archivo `es_ancora-ud-dev.conllu` y guárdalo en la carpeta de tu proyecto de RStudio. Puedes hacerlo desde el navegador o desde R:

```
url_base <- "https://raw.githubusercontent.com/UniversalDependencies/UD_Span
download.file(paste0(url_base, "es_ancora-ud-dev.conllu"),
              destfile = "es_ancora-ud-dev.conllu")
```

Si la descarga automática falla por restricciones de red, usa el navegador. El archivo

2. Primera inspección

Antes de preguntarle nada a los datos, hay que saber qué hay.

```
str(ancora)
dim(ancora)
names(ancora)
head(ancora[, c("sentence_id", "token_id", "token", "lemma", "upos", "feats'
```

Cuatro preguntas de inventario que conviene responder siempre al abrir un corpus nuevo:

```
# Cuántas ocurrencias
nrow(ancora)

# Cuántas oraciones
length(unique(ancora$sentence_id))

# Cuántas categorías gramaticales distintas
length(unique(ancora$upos))
```

3. Distribución de categorías gramaticales

Esta es la variable morfosintáctica más básica y la puerta de entrada al análisis. Es nominal, de modo que las herramientas son tablas de frecuencia y gráficos de barras.

```
frec_upos <- table(ancora$upos)
frec_upos


# En proporciones
prop_upos <- round(prop.table(frec_upos) * 100, 2)
sort(prop_upos, decreasing = TRUE)
```

Para visualizarlo conviene ordenar las barras por frecuencia, porque el orden alfabético no dice nada:

```
barplot(sort(frec_upos, decreasing = TRUE),
        las = 2,
        cex.names = 0.8,
        main = "Distribución de categorías gramaticales",
        ylab = "Ocurrencias")
```

4. Rasgos morfológicos

El campo `feats` contiene la información flexiva codificada como pares atributo-valor separados por barras verticales. Una forma verbal puede aparecer, por ejemplo, como `Mood=Ind|Number=Sing|Person=3|Tense=Pres|VerbForm=Fin`.

Extraer esa información es el primer problema real de manipulación de datos de la sesión, y se resuelve con las funciones de búsqueda de patrones que vimos en la prelectura.

4.1 Extraer un rasgo

Para saber si una ocurrencia tiene un valor determinado basta `grepl()`:

```
# Ocurrencias marcadas como femeninas
ancora$femenino <- grepl("Gender=Fem", ancora$feats)

table(ancora$femenino)
```

Para extraer el valor del rasgo, no solo su presencia, se usa una expresión regular con grupo de captura:

```
extraer_rasgo <- function(feats, rasgo) {
  patron <- paste0(rasgo, "=([A-Za-z]+)")
```

5. Del token a la oración

Hasta aquí cada fila era una ocurrencia. Muchas preguntas morfosintácticas, sin embargo, se formulan a nivel de oración: cuán larga es, cuántos verbos contiene, qué densidad léxica tiene. Eso requiere agregar (***aggregate***).

5.1 Longitud de oración

```
long_oracion <- aggregate(token_id ~ sentence_id,
                          data = ancora,
                          FUN = length)
names(long_oracion)[2] <- "n_tokens"

summary(long_oracion$n_tokens)

hist(long_oracion$n_tokens,
     breaks = 40,
     main = "Distribución de la longitud de oración",
     xlab = "Ocurrencias por oración",
     ylab = "Frecuencia")
```

6. Relaciones de dependencia

La anotación no solo asigna categorías: también establece qué depende de qué. Esto abre un tipo de análisis que no está disponible en un corpus etiquetado únicamente por categoría gramatical.

6.1 Distribución de relaciones

```
frec_dep <- sort(table(ancora$dep_rel), decreasing = TRUE)
head(frec_dep, 15)

round(prop.table(frec_dep)[1:10] * 100, 2)
```

6.2 Distancia de dependencia

La distancia de dependencia es el número de posiciones que separan a una palabra de su núcleo sintáctico. Es una medida con respaldo empírico considerable en psicolingüística: distancias mayores implican mayor carga de memoria de trabajo, y las lenguas parecen tender a minimizarlas.

```
# Los identificadores vienen como texto; hay que convertirlos
ancora$tok_num  <- as.numeric(ancora$token_id)
ancora$head_num <- as.numeric(ancora$head_token_id)
```

7. Extensión: tu propio texto

Todo lo anterior se aplica a cualquier texto en español, porque `udpipe` incluye modelos entrenados que producen exactamente la misma estructura de datos.

Esta parte es individual y se entrega junto con las actividades. Elige un texto relacionado con tu investigación: un fragmento de tu corpus de trabajo, un texto de un género que te interese, o dos textos que quieras comparar.

7.1 Descargar y cargar el modelo

```
library(udpipe)

# Solo la primera vez: descarga el modelo al directorio de trabajo
modelo_archivo <- udpipe_download_model(language = "spanish-ancora")

# En sesiones posteriores basta cargar el archivo ya descargado
modelo <- udpipe_load_model(modelo_archivo$file_model)
```

El modelo pesa alrededor de quince megabytes y queda guardado en tu carpeta. No hace falta volver a descargarlo.

8. Cierre

Lo que hicimos en esta sesión responde a una estructura que se repetirá en cualquier análisis exploratorio, con independencia del corpus.

Primero, inventario: qué hay, cuánto hay, qué falta. Segundo, distribuciones univariadas, empezando por las categóricas y siguiendo por las numéricas, atendiendo siempre a la forma de la distribución antes de resumirla con un solo número. Tercero, agregación a otro nivel de análisis, en este caso de la ocurrencia a la oración. Cuarto, relaciones entre variables.

Y a lo largo de todo el proceso, decisiones que hay que documentar: si la puntuación entra o no en el análisis, qué hacer con las oraciones sin verbos, qué categorías cuentan como palabras de contenido. Ninguna de esas decisiones es obvia y todas afectan los resultados. La diferencia entre un análisis exploratorio y una serie de gráficos sueltos está, en buena medida, en si esas decisiones quedaron registradas.

Referencias

Nivre, J. et al. (2020). Universal Dependencies v2: An Evergrowing Multilingual Treebank Collection. ***Proceedings of LREC 2020***. Disponible en universaldependencies.org.

Taulé, M., Martí, M. A. y Recasens, M. (2008). AnCora: Multilevel Annotated Corpora for Catalan and Spanish. ***Proceedings of LREC 2008***.

Wijffels, J. (2023). ***udpipe: Tokenization, Parts of Speech Tagging, Lemmatization and Dependency Parsing with the UDPipe NLP Toolkit***. Paquete de R. Documentación en bnosac.github.io/udpipe.

Liu, H. (2008). Dependency distance as a metric of language comprehension difficulty. ***Journal of Cognitive Science***, 9(2), 159-191.

Gries, S. Th. (2009). ***Quantitative Corpus Linguistics with R***. Routledge.