Semana 3. Medidas estadísticas y resumen de datos

Semana 3. Medidas estadísticas y resumen de datos

Semana 3. Medidas estadísticas y resumen de datos

Módulo de Análisis Exploratorio de Datos, Doctorado en Lingüística.

En la sesión anterior describimos la forma de una distribución mediante histogramas y diagramas de dispersión. Esa descripción visual es indispensable, pero es imprecisa: dos personas pueden mirar el mismo histograma y describir su asimetría con palabras distintas. El objetivo de esta sesión es sustituir esas descripciones cualitativas por números que se calculan de una forma establecida y que, por lo tanto, permiten comparar resultados entre corpus, entre lenguas y entre estudios distintos.

El apunte sigue trabajando con el corpus MECO. No se introduce un conjunto de datos nuevo: cada medida que se presenta se aplica sobre variables que ya se exploraron visualmente en la sesión anterior, en particular `dur`, el tiempo total de lectura de una palabra, y `long_palabra`, su longitud en caracteres. Esto tiene un propósito deliberado. Al calcular una medida sobre una variable cuya forma ya se conoce, es posible verificar si el número obtenido es coherente con lo que el histograma mostraba, y detectar así un error de cálculo o de interpretación antes de que se propague al resto del análisis.

El apunte tiene siete partes. Las primeras cinco corresponden a otras tantas familias

Antes de empezar: recuperar los objetos

El siguiente bloque reconstruye los objetos que se usaron en la sesión anterior, por si la sesión de R no se mantuvo abierta entre una clase y la otra.

```
load("joint_data_trimmed.rda")   # ajustar al nombre real del archivo
meco <- get(ls()[1])             # ajustar al nombre del objeto cargado

meco$long_palabra <- nchar(meco$ia)
meco$long_grupo <- cut(meco$long_palabra,
                       breaks = c(0, 3, 5, 8, Inf),
                       labels = c("muy corta", "corta",
                                  "media", "larga"))

fijadas <- subset(meco, skip == 0)
```

`fijadas` contiene únicamente las observaciones de palabras que recibieron al menos una fijación. Todas las medidas que involucran duraciones de lectura se calculan sobre este subconjunto, por la razón discutida en la sesión anterior: una palabra omitida no tiene duración porque nunca fue mirada, y promediar sobre NA sin filtrar antes oculta

1. Medidas de tendencia central

Las medidas de tendencia central resumen un conjunto de datos con un único valor que representa su centro. Existen tres medidas de uso común, y no son intercambiables: cada una responde a una pregunta distinta y es sensible a distintos aspectos de los datos.

1.1 Media aritmética

La media aritmética es la suma de todas las observaciones dividida por su número:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i$$

```
mean(fijadas$dur)
```

La media utiliza el valor exacto de cada observación, lo que la hace sensible a valores extremos. Una sola observación con un valor muy alto desplaza la media hacia arriba, incluso si el resto de las observaciones está concentrado en valores mucho menores. Esta sensibilidad no es un defecto de la media en sí misma, sino una consecuencia directa de su definición: si se busca un resumen que use la información completa de cada dato, incluyendo su magnitud exacta, la media es la medida apropiada. El

2. Medidas de dispersión

Una medida de tendencia central, por sí sola, no informa sobre cuánto varían los datos alrededor de ese centro. Dos conjuntos de datos pueden compartir la misma media y tener una dispersión completamente distinta. Las medidas de dispersión cuantifican esa variabilidad.

2.1 Rango

El rango es la diferencia entre el valor máximo y el valor mínimo:

$$R = x_{max} - x_{min}$$

```
max(fijadas$dur) - min(fijadas$dur)
```

El rango es la medida de dispersión más simple, pero también la más inestable: depende únicamente de dos observaciones, las más extremas, y por tanto puede cambiar de manera drástica si se agrega o elimina un solo dato del conjunto.

2.2 Rango intercuartílico

El rango intercuartílico, abreviado RIC, es la diferencia entre el tercer cuartil y el primer cuartil:

3. Medidas de posición relativa

Las medidas de posición relativa ubican una observación, o un valor arbitrario, dentro de la distribución completa de los datos, expresando esa ubicación en términos de proporción de observaciones por debajo o por encima.

3.1 Percentiles y cuantiles

Un percentil es el valor por debajo del cual se encuentra un porcentaje determinado de las observaciones. El percentil 50 coincide, por definición, con la mediana; los percentiles 25 y 75 son el primer y el tercer cuartil, ya presentados en la sección anterior.

```
quantile(fijadas$dur, probs = c(0.10, 0.25, 0.50, 0.75, 0.90))
```

El argumento `probs` de la función `quantile()` recibe proporciones entre 0 y 1, no porcentajes entre 0 y 100. Puede recibir cualquier vector de proporciones, lo que permite calcular deciles, dividiendo la distribución en diez partes:

```
quantile(fijadas$dur, probs = seq(0, 1, by = 0.1))
```

o cualquier otro corte que una pregunta particular requiera. Cuando el número de observaciones no permite dividir la distribución en partes exactas, existen varios métodos de interpolación entre observaciones adyacentes; R implementa nueve de

4. Diagrama de caja y bigotes

El diagrama de caja y bigotes, comúnmente llamado por su nombre en inglés, ***boxplot***, condensa en una sola representación gráfica cinco valores de una distribución: el mínimo, el primer cuartil, la mediana, el tercer cuartil y el máximo, ajustando los dos últimos según un criterio explícito de valores atípicos que se detalla más adelante.

4.1 Elementos del diagrama

```
boxplot(fijadas$dur,
        main = "Tiempo total de lectura por palabra",
        ylab = "Milisegundos")
```

La caja central se extiende desde el primer cuartil hasta el tercer cuartil, de modo que su altura es exactamente el rango intercuartílico definido en la sección 2.2. Una línea interior marca la mediana. Dos líneas, llamadas bigotes, se extienden desde los bordes de la caja hasta el valor observado más alejado que aún se considera dentro de un rango razonable, según el criterio que se define en la sección siguiente. Las observaciones que quedan fuera de ese rango se representan como puntos individuales.

El diagrama de caja es especialmente útil para comparar varios grupos en un mismo

5. Medidas de asociación

Las medidas anteriores describen una variable a la vez. Las medidas de asociación describen la relación entre dos variables, y son el primer paso hacia el análisis bivariado que se desarrollará con mayor profundidad en las próximas sesiones del módulo.

5.1 Correlación de Pearson

El coeficiente de correlación de Pearson mide el grado de asociación lineal entre dos variables numéricas:

$$r = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \bar{x})^2}\sqrt{\sum_{i=1}^{n}(y_i - \bar{y})^2}}$$

```
cor(fijadas$long_palabra, fijadas$dur, method = "pearson")
```

El coeficiente toma valores entre -1 y 1. Un valor cercano a 1 indica una asociación lineal positiva fuerte, un valor cercano a -1 indica una asociación lineal negativa fuerte, y un valor cercano a 0 indica ausencia de asociación lineal, aunque esto último no descarta la existencia de una asociación no lineal entre las variables.

El coeficiente de Pearson tiene dos limitaciones que conviene tener presentes.

6. Extensión: aplicar las medidas a tus lenguas

Esta parte retoma el subconjunto de dos lenguas que cada estudiante seleccionó al final de la sesión anterior. El objetivo es aplicar sobre ese subconjunto el repertorio completo de medidas presentadas en este apunte, no solo alguna de ellas de manera aislada.

```
mis_lenguas <- c("es", "fi")      # ajustar a los codigos y lenguas propias
mi_sub <- subset(meco, lang %in% mis_lenguas)
mis_fijadas <- subset(fijadas, lang %in% mis_lenguas)
```

El informe de esta extensión debe incluir, como mínimo, los siguientes elementos, calculados sobre las dos lenguas seleccionadas y presentados de forma comparativa entre ambas:

Tendencia central. Media, mediana y, si corresponde a alguna de las variables elegidas, moda, con una justificación explícita de cuál de las tres medidas resulta más adecuada para reportar como resumen principal.

Dispersión. Rango intercuartílico y desviación estándar, junto con el coeficiente de variación si se desea comparar la dispersión relativa de más de una variable medida en

7. Cierre

Cada medida presentada en esta sesión responde a una pregunta específica sobre un conjunto de datos, y ninguna de ellas sustituye a las demás. La media y la mediana pueden ofrecer una imagen distinta del centro de una distribución; el rango intercuartílico y la desviación estándar cuantifican la dispersión de maneras que responden de forma distinta ante los valores extremos; los percentiles permiten fijar umbrales sin recurrir a números arbitrarios; el diagrama de caja resume en un solo gráfico buena parte de esta información, con un criterio explícito y documentado para señalar observaciones inusuales; y las medidas de asociación son el primer paso hacia preguntas sobre cómo se relacionan dos variables entre sí.

A lo largo del apunte aparecieron varias decisiones que, igual que en la sesión anterior, deben quedar documentadas en cualquier análisis: qué medida de tendencia central se reporta y por qué, si se usa la desviación estándar o el coeficiente de variación según se comparen variables en la misma escala o en escalas distintas, en qué percentil se fija un umbral, si se sigue la convención de 1,5 veces el rango intercuartílico para valores atípicos o una convención distinta, y qué coeficiente de correlación se elige según la forma esperada de la relación entre las variables.

Referencias

Tukey, J. W. (1977). ***Exploratory Data Analysis***. Addison-Wesley.

Gries, S. Th. (2021). ***Statistics for Linguistics with R*** (3.ª ed.). Mouton de Gruyter.

Baayen, R. H. (2008). ***Analyzing Linguistic Data: A Practical Introduction to Statistics using R***. Cambridge University Press.

Siegelman, N., Schroeder, S., Acartürk, C. et al. (2022). Expanding horizons of cross-linguistic research on reading: The Multilingual Eye-movement Corpus (MECO). ***Behavior Research Methods***, 54, 2843-2863.

Datos: https://osf.io/3527a