LIIN-933

Módulo de Análisis Exploratorio de Datos

Juan Zamora O.

Módulo de Análisis Exploratorio de Datos





¿Por qué empezar por aquí?

Antes de aprender ***cómo*** explorar datos, conviene entender ***por qué*** debemos hacerlo de forma metódica.

La respuesta es incómoda:

Confiabilidad en la cognición humana

- Buscamos confirmar lo que ya creemos
- Razonamos mal con probabilidades
- Vemos patrones donde no los hay

El concepto ancla: sesgo de confirmación

Sesgo de confirmación: tendencia a buscar, notar y recordar información que confirma lo que ya creemos e ignorar la que la contradice.

- Uno de los sesgos mejor documentados
- Afecta a expertos tanto como a legos
- El método científico existe, en su núcleo, para contrarrestarlo

En lugar de buscar confirmación, intentamos **falsar** nuestras hipótesis.

Somos malos con probabilidades: Monty Hall

Tres puertas: dos cabras, un premio.

1. Eliges la puerta 1
2. El presentador abre una puerta con cabra (la 3)
3. ¿Cambias a la puerta 2?

Somos malos con probabilidades: Monty Hall

Tres puertas: dos cabras, un premio.

1. Eliges la puerta 1
2. El presentador abre una puerta con cabra (la 3)
3. ¿Cambias a la puerta 2?

Sí: cambiar eleva tu probabilidad de 1/3 a 2/3.

- Tu puerta: 1/3. Las otras dos juntas: 2/3
- Al abrir una perdedora, esos 2/3 se concentran en la que queda

Subestimamos lo exponencial: cumpleaños

En una clase de 23, ¿probabilidad de un cumpleaños compartido?

Subestimamos lo exponencial: cumpleaños

En una clase de 23, ¿probabilidad de un cumpleaños compartido?

Aproximadamente **50%** (la intuición dice ~6%).

El error: pensar en individuos, no en **pares**.

$$\frac{23 \cdot 22}{2} = 253 \text{ pares} \qquad \left(\frac{364}{365}\right)^{253} \approx 0.50$$

\note{El punto es la combinatoria: 253 pares posibles, no 23 personas. Cada par tiene alta probabilidad de NO coincidir (364/365), pero compuesta sobre 253 pares, la probabilidad de que nadie coincida cae a ~50%. Relevante en lingüística: cualquier análisis con comparaciones múltiples es terreno donde la intuición engaña —conecta con el problema de comparaciones múltiples en estadística inferencial.}

Verificación en R

```r
n <- 73                                  # estudiantes
days_in_year <- 365
prob_all_different <-
  prod((days_in_year - 0:(n-1)) / days_in_year)
prob_at_least_one_shared <- 1 - prob_all_different
prob_at_least_one_shared
#> [1] 0.9995608
```

Con 73 estudiantes: probabilidad $\approx$ 99.96%.

Pensamiento rápido y lento

Bate + pelota = 1.10. El bate cuesta 1.00 más. ¿La pelota?

Pensamiento rápido y lento

Bate + pelota = 1.10. El bate cuesta 1.00 más. ¿La pelota?

No es 0.10, sino **0.05** (0.05 + 1.05 = 1.10).

Rápido (Sistema 1)	Lento (Sistema 2)
Intuitivo, automático	Deliberado, esforzado
Económico	Costoso
Propenso a errores	Más preciso

La ciencia = aplicar **pensamiento lento** a problemas que resolveríamos por reflejo.

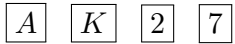
Vemos patrones en el ruido

Las palomas de Skinner: alimentadas a intervalos aleatorios, desarrollaron rituales (girar, picotear) asociando por azar conducta y recompensa.

- Superstición: relación causal donde solo hay coincidencia
- Pareidolia: caras en Marte, en tostadas
- Sobreatribución de agencia (ruido nocturno $\rightarrow$ “alguien me sigue”)

La tarea de Wason

Cuatro cartas (letra en una cara, número en la otra):



Regla: ***si hay vocal en una cara, hay número par en la otra.*** ¿Qué cartas voltear?

La tarea de Wason

Cuatro cartas (letra en una cara, número en la otra):

$$\boxed{A} \quad \boxed{K} \quad \boxed{2} \quad \boxed{7}$$

Regla: ***si hay vocal en una cara, hay número par en la otra.*** ¿Qué cartas voltear?

Respuesta correcta: **A y 7** (no “A y 2”).

- **7** (impar): si detrás hay vocal, rompe la regla
- **2** es irrelevante: la regla no dice nada sobre los pares

El juego 1-2-4

El instructor tiene una regla y da tres números que la cumplen: **1, 2, 4**. Propón un número; te digo si cumple.

- Típico: proponer 8 (cumple) $\rightarrow$ “duplicar el anterior” **X**
- Luego 16 (cumple) $\rightarrow$ “elevar al cuadrado” **X**
- Regla real: **“cada número mayor que el anterior”**

Solo proponiendo números que **contradicen** la hipótesis nos acercamos a la verdad.

Percepción dependiente del contexto

El mismo trazo se lee distinto según el entorno:

$$\texttt{A ? C} \rightarrow \text{”B”} \qquad\qquad \texttt{12 ? 14} \rightarrow \text{”13”}$$

- Estímulo idéntico, interpretación distinta
- La ilusión de Thatcher (rostros invertidos): el cerebro autocorrige
- **La categorización depende del contexto**

Falacias lógicas: un catálogo defensivo

Argumentos defectuosos frecuentes; la defensa es reconocerlos:

- **Cherry-picking** — seleccionar solo evidencia favorable
- **Ad hominem** — atacar a la persona, no al argumento
- **Apelación a la autoridad** — la persona en lugar de su investigación
- **Hombre de paja** — refutar una versión debilitada del argumento
- **Argumento desde la ignorancia** — “no se ha probado falso, luego es verdad”
- **Falsa dicotomía** — solo dos extremos cuando hay más opciones
- **Pendiente resbaladiza / circular / pista falsa / costo hundido**

El método científico

Procedimiento cíclico para conocimiento fiable:

1. Observar un fenómeno
2. Formular una hipótesis **contrastable**
3. Derivar predicciones
4. Contrastar con datos sistemáticos
5. Revisar o rechazar según el resultado

Su poder no está en garantizar la verdad, sino en hacer las afirmaciones **contrastables** y los errores **corregibles**.

Clever Hans

Caballo que “resolvía” aritmética golpeando el casco (c. 1900).

- **Más de una docena de científicos** lo observaron y no vieron truco
- Pfungst (1904): Hans respondía a **señales musculares involuntarias**
- Si nadie conocía la respuesta, Hans tampoco
- Si no veía a quien la sabía, fallaba

Popper y la falsación

En las ciencias empíricas nada se prueba; las hipótesis solo se falsan.

$$10.000 \text{ cisnes blancos} \not\Rightarrow \text{"todos los cisnes son blancos"}$$

$$1 \text{ cisne negro} \Rightarrow \text{refutación inmediata}$$

- Asimetría entre verificación y falsación
- **Falsable ≠ falso**: significa que ***podría*** mostrarse falso
- Criterio de demarcación: una teoría es científica ***sii*** es falsable

El progreso como evolución

Conjeturas → Intentos de refutación → Eliminación de errores → Teorías más aptas

- La falsación cumple para la ciencia lo que la selección natural para la biología
- Las teorías que sobreviven no son “más verdaderas”, sino más **aptas**
- Ninguna prueba superada protege de una refutación futura
- El conocimiento empírico es siempre **provisional**

La lingüística empírica

Lingüística: el estudio científico del lenguaje y las lenguas.

- Descubrir, describir y modelar los sistemas del lenguaje
- La lingüística empírica investiga basándose en **observaciones de la realidad**
- Es **descriptiva, no prescriptiva**: cómo se usa la lengua, no cómo "debería" usarse

El círculo científico: buscar las llaves

Paso	Llaves	Lingüística
Observación	¡No están!	Los jóvenes usan menos sujeto nulo
Pregunta	¿Dónde están?	¿Varía el sujeto nulo con la edad?
Hipótesis (H1)	En la mesa del TV	Los jóvenes usan menos sujeto nulo
H nula (H0)	NO en esa mesa	No hay relación edad–sujeto nulo
Diseño	Voy a mirar	Corpus estratificado por edad
Análisis	—	Test de asociación
Interpretación	No están; otro lado	Rechazar o no H0

¿Qué es la estadística y para qué sirve?

La estadística es una forma de conocer el mundo en **términos cuantitativos**.

Tres propósitos:

1. **Resumir** datos — estadística descriptiva
2. **Explorar** datos — estadística exploratoria
3. **Relacionar** variables — estadística inferencial Schweinberger añade una definición pragmática: un **dispositivo para ahorrar trabajo**.

La hipótesis en el centro

Retomando a Wilson (1999), la ciencia es:

> Una empresa sistemática que construye y organiza conocimiento en forma de **explicaciones y predicciones contrastables**.

Reformulado: **ciencia = testeo metódico de hipótesis**.

Hoja de ruta

1. **Hipótesis** — nula vs. alternativa, dirigida vs. no dirigida, falsabilidad
2. **Datos y diseños** — experimental vs. observacional
3. **Variables y validez** — operacionalización y escalas de medición
4. **Relaciones entre variables** — correlación y causalidad

H0 y H1: el concepto ancla

- **Hipótesis alternativa (H1):** existe un efecto o relación
- **Hipótesis nula (H0):** no existe efecto El testeo funciona de forma **indirecta**:
- Nunca probamos H1
- Evaluamos cuán **incompatibles** son los datos con H0
- Solo si los datos serían muy improbables bajo H0, la rechazamos **Por eso las hipótesis se formulan antes de mirar los datos.**

Falsabilidad

> ***Las manzanas siempre caen hacia abajo.***

Un solo contraejemplo la falsa. Ninguna cantidad de evidencia a favor la prueba.

- **Es imposible probar una hipótesis empírica**
- Basta una observación refutadora
- Por eso buscamos falsar, no confirmar

La frontera: hipótesis vs. especulación

Enunciados que **no** pueden falsarse:

- ***Hay formas de vida en la galaxia de Andrómeda*** (razones técnicas)
- ***Prefiero el helado de chocolate al de vainilla*** (subjetivo) Esto es **especulación**: fuera del alcance de la ciencia empírica.

No es algo negativo — el arte, la literatura, la música y la filosofía viven ahí.

Los cuatro criterios

Una hipótesis debe ser:

1. **Falsable** — sobre la realidad empírica
2. **Contrastable** — sobre el mundo empírico
3. **Inequívoca** — sin ambigüedad
4. **Internamente consistente** La **universalidad no es requisito**: una hipótesis puede referirse a un evento singular y seguir siendo válida.

Tipologías de hipótesis

Distinción	Formulación
No dirigida	Los grupos A y B ***difieren*** ($\mu_A \neq \mu_B$)
Dirigida	A obtiene resultados ***mayores*** que B ($\mu_A > \mu_B$)
Determinista	La palabra corta ***siempre*** precede a la larga
Probabilística	Es ***más probable*** que la corta preceda a la larga

Por qué testeamos H0

En términos no técnicos: evaluamos **cuán probable es que el resultado se deba al azar**.

- $p > .05$ — probable que sea aleatorio $\rightarrow$ **no** descartamos H0
- $p < .05$ — improbable que sea aleatorio $\rightarrow$ descartamos H0, asumimos H1

Muestra y población

Una **muestra** es una selección de **una** población —no de ***la*** población.

> Si la muestra incluye solo alemanes de 20 a 30 años, la población no es “todos los alemanes”, sino los alemanes de esa franja etaria en ese momento.

Debemos ser conscientes sobre **qué población podemos realmente inferir**.

Diseño ≠ análisis

Dos pasos separados:

- **Diseño de investigación:** cómo se ***recogen*** los datos
- **Análisis de datos:** cómo se ***analizan*** Por eso **no tiene sentido** hablar de “diseño cualitativo” o “diseño cuantitativo”.

Cualquier diseño admite ambos enfoques analíticos.

La distinción central

Experimental vs. observacional, y el criterio que los separa es la causalidad:

- **Observacional:** solo confirma **correlaciones** (X e Y coocurren)
- **Experimental:** puede determinar **causalidad** (X causa Y)

Diseños en ciencias del lenguaje

Diseño	Ejemplo	V. interna	V. externa	Costo
Experimental	Tiempos de reacción	Alta	Baja	Alto
Corpus	Estudio variacionista	Baja/var.	Alta	Bajo*
Archivo	Revisión sistemática	Media	Baja	Bajo
Introspección	Juicios de gramaticalidad	Alta	Baja/var.	Bajo
Cuestionario	Encuesta de uso	Media	Media	Bajo

* Si el corpus ya existe; alto si hay que compilarlo.

Experimental y cuasi-experimental

Experimental (true experiment): asignación **aleatoria** a grupos de test y control.

Cuasi-experimental: sin asignación aleatoria → vulnerable a ***confounding***.

Caen aquí:

- Estudios variacionistas de corpus
- Análisis de datos históricos (ya recogidos)
- Estudios de diferencias por sexo o edad

Observacional: corpus

Los sujetos se observan en su **“hábitat natural”**.

- Alta **validez externa**: resultados transferibles al mundo real
- Precio: **sin control** sobre factores contextuales y de confusión
- Costo variable: mínimo si el corpus existe, alto si hay que grabar y transcribir

Introspección

La vieja **“lingüística de sillón”** (***armchair linguistics***).

- Dominante en el siglo XX
- La forma más barata y fácil de “recoger datos”
- **Subjetiva** y sesgada por expectativas y marco teórico Desde los 90, relegada a **generación de hipótesis**, no como fuente única.

Cuestionarios y elicitación

Métodos donde los informantes proveen información consciente:

- **Escalas Likert** (5 o 7 puntos): de ***muy en desacuerdo*** a ***muy de acuerdo***
- **Discourse Completion Tasks (DCT):** imaginar un contexto y responder
  Salvaguardas metodológicas:
- **Fillers** — ítems distractores contra ***agreeability effects***
- **Aleatorización** de ítems contra ***fatigue effects***

Operacionalización: el concepto ancla

Operacionalización: traducir un concepto abstracto en algo concretamente medible.

Concepto	Operacionalización posible
Competencia lingüística	Puntaje de un ensayo
Complejidad	Longitud media de enunciado
Cortesía	Frecuencia de atenuadores

Cada operacionalización es una elección.

Dos tipos de validez

Validez intrínseca: correspondencia entre el concepto y la variable que lo mide.

- ***Ej.:*** complejidad → número de nodos sintácticos **Validez externa:** aplicabilidad de los hallazgos al mundo real.
- ***Ej.:*** recordar sílabas sin sentido en laboratorio → ¿aprender vocabulario real?

Variables dependientes e independientes

- **Independiente:** el predictor (lo que manipulamos o registramos como causa potencial)
- **Dependiente:** el resultado (lo que medimos como efecto) ***Ejemplo médico:*** el fármaco (independiente) $\rightarrow$ presencia de síntomas (dependiente).

Ejemplo lingüístico: la edad del hablante (independiente) $\rightarrow$ frecuencia de sujeto nulo (dependiente).

Escalas de medición

Escala	Propiedad	Ejemplo lingüístico
Nominal / categórica	Solo pertenencia a clase	Parte del discurso
Ordinal	Orden sin distancias cuantificables	Juicios Likert, rangos
Intervalo	Diferencias sí, razones no	Juicios de aceptabilidad
Razón	Diferencias y razones	Duración, n° de sílabas
Conteos	Enteros positivos, frecuencias	Errores por 1000 palabras

La escala dicta el test

Consecuencia práctica directa:

- $\chi^2 \rightarrow$ solo variables **nominales/categóricas**
- t-test $\rightarrow$ solo variables **numéricas Elegir mal la operacionalización cierra puertas analíticas.**

La jerarquía es unidireccional

$$\text{nominal/categórica} < \text{ordinal} < \text{intervalo/razón}$$

Se puede **degradar** una variable, **nunca ascender**.

Ejemplo: demasiados hablantes con cero palabrotas $\rightarrow$ se viola la normalidad de residuos.

- Opción A: rankear hablantes $\rightarrow$ Mann-Whitney U
- Opción B: dicotomizar (usa / no usa) $\rightarrow \chi^2$

Cuatro dimensiones de una correlación

- **Fuerza** — ¿cuánto explica una variable la variabilidad de la otra?
- **Dirección** — ¿positiva o negativa?
- **Linealidad** — ¿es constante la relación?
- **Homogeneidad** — ¿es consistente? Fuerza y dirección son **ortogonales**: una correlación negativa puede ser tan fuerte como una positiva.

Correlación espuria

> ***Los estudiantes que beben más café sacan mejores notas.***

¿Causa el café las buenas notas?

Correlación espuria

> ***Los estudiantes que beben más café sacan mejores notas.***

¿Causa el café las buenas notas?

No necesariamente. El **tiempo de estudio** puede causar ambas cosas.

Una tercera variable explica la asociación observada.

Cierre

Concepto del capítulo	En nuestro módulo
Hipótesis previas a los datos	El EDA explora; no reemplaza el preregistro
Diseño y muestra	Fundamentos de muestreo (Semana 0)
Escalas de medición	Tipología de datos (Semana 1)
Correlación y dirección	Medidas de asociación (Semana 3–4)
Correlación espuria	Interpretación cautelosa (Semana 5)

Una hipótesis es un enunciado **falsable**; el testeo evalúa la compatibilidad de los datos con **H0**, no la verdad de H1.

La **operacionalización** es una elección que determina la validez: ningún análisis rescata una mala medida.

La **escala de medición** decide qué análisis y qué visualización son posibles.

Fundamento	En el EDA
Sesgo de confirmación	No quedarse solo con la visualización que confirma
Falsación	El EDA sugiere; validar exige refutar en datos nuevos
Patrones en el ruido	Distinguir patrón genuino de azar del corpus
Correlación ≠ causalidad	Una asociación no establece mecanismo causal
Pensamiento lento	El EDA es “pensamiento lento” sobre los datos

Para retener

> El **EDA no confirma** lo que ya sospechas.
>
> Es un procedimiento para **ver lo que hay** —incluyendo lo que no esperabas y lo que contradice tu intuición.

Su valor está precisamente en su capacidad de **sorprenderte y corregirte**.

Referencias

- Evans, V., & Green, M. (2006). ***Cognitive Linguistics: An Introduction.*** Edinburgh UP.
- Hood, B. M. (2009). ***SuperSense.*** HarperOne.
- Kahneman, D. (2011). ***Thinking, Fast and Slow.*** Farrar, Straus and Giroux.
- Popper, K. R. (1959). ***The Logic of Scientific Discovery.*** Hutchinson.
- Sagan, C. (1995). ***The Demon-Haunted World.*** Ballantine Books.
- Schweinberger, M. ***Statistics for Linguists*** (SLAT7855), cap. 1. University of Queensland.

Referencias

- Schweinberger, M. ***Statistics for Linguists*** (SLAT7855), cap. 2: Hypotheses and Variables. University of Queensland.
- Wilson, E. O. (1999). “The Natural Sciences”. En ***Consilience: The Unity of Knowledge***, 49–71.
- Popper, K. R. (1959). ***The Logic of Scientific Discovery.*** Hutchinson.
- Gries, S. T. (2021). ***Statistics for Linguistics with R*** (3ª ed.). Mouton de Gruyter.