# LIIN-933

## Módulo de Análisis Exploratorio de Datos

Juan Zamora O.

Módulo de Análisis Exploratorio de Datos






# ¿Por qué empezar por aquí?

Antes de aprender ***cómo*** explorar datos, conviene entender ***por qué*** debemos hacerlo de forma metódica.

La respuesta es incómoda:

- **La cognición humana es sistemáticamente poco fiable**
- Vemos patrones donde no los hay
- Buscamos confirmar lo que ya creemos
- Razonamos mal con probabilidades

El método científico no es una formalidad: es un conjunto de **salvaguardas contra nuestros propios errores**.

# Hoja de ruta

Tres bloques:

1. **¿Por qué necesitamos ciencia?** — límites de la lógica pura y la intuición
2. **Errare humanum est** — sesgos cognitivos y falacias
3. **¿Qué es la ciencia?** — falsación y método científico en lingüística

# Una definición mínima

> La ciencia es un proceso metódico para adquirir conocimiento sobre el mundo basado en **evidencia empírica**.

La palabra clave es ***empírica***.

Para entender su peso, contrastemos dos familias de disciplinas.

# Ciencias formales vs. empíricas

| | **Formales** | **Empíricas** |
|---|---|---|
| Ejemplos | Lógica, matemáticas | Sociolingüística, biología |
| Punto de partida | Axiomas | Observaciones |
| Método | Inferencia lógica | Observación / experimentación |
| Conocimiento | Demostrable | Provisional, revisable |

Las formales son poderosas para la **coherencia lógica**:

- ***Sócrates es humano*** + ***todos los humanos son mortales*** $\Rightarrow$ ***Sócrates es mortal***

# El límite de la lógica pura

La lógica construye representaciones **coherentes**, pero no puede decidir **cuál** corresponde a la realidad.

> ¿Levantaré el brazo izquierdo o el derecho al contar hasta tres?

- Ambos mundos son igualmente coherentes
- Solo la observación resuelve cuál ocurre
- Hay infinitos mundos lógicamente posibles

**La coherencia interna no garantiza adecuación al mundo.**

# El concepto ancla: sesgo de confirmación

**Sesgo de confirmación:** tendencia a buscar, notar y recordar información que confirma lo que ya creemos —e ignorar la que la contradice.

- Uno de los sesgos mejor documentados
- Afecta a expertos tanto como a legos
- El método científico existe, en su núcleo, para contrarrestarlo

En lugar de buscar confirmación, intentamos **falsar** nuestras hipótesis.

# Somos malos con probabilidades: Monty Hall

Tres puertas: dos cabras, un premio.

1. Eliges la puerta 1
2. El presentador abre una puerta con cabra (la 3)
3. ¿Cambias a la puerta 2?

# Somos malos con probabilidades: Monty Hall

Tres puertas: dos cabras, un premio.

1. Eliges la puerta 1
2. El presentador abre una puerta con cabra (la 3)
3. ¿Cambias a la puerta 2?

**Sí: cambiar eleva tu probabilidad de 1/3 a 2/3.**

- Tu puerta: 1/3. Las otras dos juntas: 2/3
- Al abrir una perdedora, esos 2/3 se concentran en la que queda

# Subestimamos lo exponencial: cumpleaños

**En una clase de 23, ¿probabilidad de un cumpleaños compartido?**

# Subestimamos lo exponencial: cumpleaños

**En una clase de 23, ¿probabilidad de un cumpleaños compartido?**

Aproximadamente **50%** (la intuición dice ~6%).

El error: pensar en individuos, no en **pares**.

$$\frac{23 \cdot 22}{2} = 253 \text{ pares} \qquad \left(\frac{364}{365}\right)^{253} \approx 0.50$$

\note{El punto es la combinatoria: 253 pares posibles, no 23 personas. Cada par tiene alta probabilidad de NO coincidir (364/365), pero compuesta sobre 253 pares, la probabilidad de que nadie coincida cae a ~50%. Relevante en lingüística: cualquier análisis con comparaciones múltiples es terreno donde la intuición engaña —conecta con el problema de comparaciones múltiples en estadística inferencial.}

# Verificación en R

```r
n <- 73                                  # estudiantes
days_in_year <- 365
prob_all_different <-
  prod((days_in_year - 0:(n-1)) / days_in_year)
prob_at_least_one_shared <- 1 - prob_all_different
prob_at_least_one_shared
#> [1] 0.9995608
```

Con 73 estudiantes: probabilidad $\approx$ 99.96%.

# Pensamiento rápido y lento

**Bate + pelota = 1.10. El bate cuesta 1.00 más. ¿La pelota?**

# Pensamiento rápido y lento

**Bate + pelota = 1.10. El bate cuesta 1.00 más. ¿La pelota?**

No es 0.10, sino **0.05** (0.05 + 1.05 = 1.10).

| Rápido (Sistema 1) | Lento (Sistema 2) |
|---|---|
| Intuitivo, automático | Deliberado, esforzado |
| Económico | Costoso |
| Propenso a errores | Más preciso |

La ciencia = aplicar **pensamiento lento** a problemas que resolveríamos por reflejo.

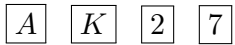
# Vemos patrones en el ruido

**Las palomas de Skinner:** alimentadas a intervalos aleatorios, desarrollaron rituales (girar, picotear) asociando por azar conducta y recompensa.

- Superstición: relación causal donde solo hay coincidencia
- Pareidolia: caras en Marte, en tostadas
- Sobreatribución de agencia (ruido nocturno $\rightarrow$ “alguien me sigue”)

# La tarea de Wason

Cuatro cartas (letra en una cara, número en la otra):




Regla: ***si hay vocal en una cara, hay número par en la otra.*** ¿Qué cartas voltear?

# La tarea de Wason

Cuatro cartas (letra en una cara, número en la otra):

$$\boxed{A} \quad \boxed{K} \quad \boxed{2} \quad \boxed{7}$$

Regla: ***si hay vocal en una cara, hay número par en la otra.*** ¿Qué cartas voltear?

Respuesta correcta: **A y 7** (no “A y 2”).

- **7** (impar): si detrás hay vocal, rompe la regla
- **2** es irrelevante: la regla no dice nada sobre los pares

# El juego 1-2-4

El instructor tiene una regla y da tres números que la cumplen: **1, 2, 4**. Propón un número; te digo si cumple.

- Típico: proponer 8 (cumple) $\rightarrow$ “duplicar el anterior” **X**
- Luego 16 (cumple) $\rightarrow$ “elevar al cuadrado” **X**
- Regla real: **“cada número mayor que el anterior”**

Solo proponiendo números que **contradicen** la hipótesis nos acercamos a la verdad.

# Percepción dependiente del contexto

El mismo trazo se lee distinto según el entorno:

$$\texttt{A ? C} \rightarrow \text{”B”} \qquad\qquad \texttt{12 ? 14} \rightarrow \text{”13”}$$

- Estímulo idéntico, interpretación distinta
- La ilusión de Thatcher (rostros invertidos): el cerebro autocorrige
- **La categorización depende del contexto**

# Falacias lógicas: un catálogo defensivo

Argumentos defectuosos frecuentes; la defensa es reconocerlos:

- **Cherry-picking** — seleccionar solo evidencia favorable
- **Ad hominem** — atacar a la persona, no al argumento
- **Apelación a la autoridad** — la persona en lugar de su investigación
- **Hombre de paja** — refutar una versión debilitada del argumento
- **Argumento desde la ignorancia** — “no se ha probado falso, luego es verdad”
- **Falsa dicotomía** — solo dos extremos cuando hay más opciones
- **Pendiente resbaladiza / circular / pista falsa / costo hundido**

# El método científico

Procedimiento cíclico para conocimiento fiable:

1. Observar un fenómeno
2. Formular una hipótesis **contrastable**
3. Derivar predicciones
4. Contrastar con datos sistemáticos
5. Revisar o rechazar según el resultado

Su poder no está en garantizar la verdad, sino en hacer las afirmaciones **contrastables** y los errores **corregibles**.

# Clever Hans

Caballo que “resolvía” aritmética golpeando el casco (c. 1900).

- **Más de una docena de científicos** lo observaron y no vieron truco
- Pfungst (1904): Hans respondía a **señales musculares involuntarias**
- Si nadie conocía la respuesta, Hans tampoco
- Si no veía a quien la sabía, fallaba

# Popper y la falsación

**En las ciencias empíricas nada se prueba; las hipótesis solo se falsan.**

$$10.000 \text{ cisnes blancos} \not\Rightarrow \text{"todos los cisnes son blancos"}$$

$$1 \text{ cisne negro} \Rightarrow \text{refutación inmediata}$$

- Asimetría entre verificación y falsación
- **Falsable ≠ falso**: significa que ***podría*** mostrarse falso
- Criterio de demarcación: una teoría es científica ***sii*** es falsable

# El progreso como evolución

Conjeturas → Intentos de refutación → Eliminación de errores → Teorías más aptas

- La falsación cumple para la ciencia lo que la selección natural para la biología
- Las teorías que sobreviven no son “más verdaderas”, sino más **aptas**
- Ninguna prueba superada protege de una refutación futura
- El conocimiento empírico es siempre **provisional**

# La lingüística empírica

**Lingüística:** el estudio científico del lenguaje y las lenguas.

- Descubrir, describir y modelar los sistemas del lenguaje
- La lingüística empírica investiga basándose en **observaciones de la realidad**
- Es **descriptiva, no prescriptiva**: cómo se usa la lengua, no cómo "debería" usarse

# El círculo científico: buscar las llaves

| Paso | Llaves | Lingüística |
|---|---|---|
| Observación | ¡No están! | Los jóvenes usan menos sujeto nulo |
| Pregunta | ¿Dónde están? | ¿Varía el sujeto nulo con la edad? |
| Hipótesis (H1) | En la mesa del TV | Los jóvenes usan menos sujeto nulo |
| H nula (H0) | NO en esa mesa | No hay relación edad–sujeto nulo |
| Diseño | Voy a mirar | Corpus estratificado por edad |
| Análisis | — | Test de asociación |
| Interpretación | No están; otro lado | Rechazar o no H0 |

# ¿Qué es la estadística y para qué sirve?

La estadística es una forma de conocer el mundo en **términos cuantitativos**.

Tres propósitos:

1. **Resumir** datos — estadística descriptiva
2. **Explorar** datos — estadística exploratoria
3. **Relacionar** variables — estadística inferencial Schweinberger añade una definición pragmática: un **dispositivo para ahorrar trabajo**.

# La hipótesis en el centro

Retomando a Wilson (1999), la ciencia es:

> Una empresa sistemática que construye y organiza conocimiento en forma de **explicaciones y predicciones contrastables**.

Reformulado: **ciencia = testeo metódico de hipótesis**.

# Hoja de ruta

1. **Hipótesis** — nula vs. alternativa, dirigida vs. no dirigida, falsabilidad
2. **Datos y diseños** — experimental vs. observacional
3. **Variables y validez** — operacionalización y escalas de medición
4. **Relaciones entre variables** — correlación y causalidad

# H0 y H1: el concepto ancla

- **Hipótesis alternativa (H1):** existe un efecto o relación
- **Hipótesis nula (H0):** no existe efecto El testeo funciona de forma **indirecta**:
- Nunca probamos H1
- Evaluamos cuán **incompatibles** son los datos con H0
- Solo si los datos serían muy improbables bajo H0, la rechazamos **Por eso las hipótesis se formulan antes de mirar los datos.**

# Falsabilidad

> ***Las manzanas siempre caen hacia abajo.***

Un solo contraejemplo la falsa. Ninguna cantidad de evidencia a favor la prueba.

- **Es imposible probar una hipótesis empírica**
- Basta una observación refutadora
- Por eso buscamos falsar, no confirmar

# La frontera: hipótesis vs. especulación

Enunciados que **no** pueden falsarse:

- ***Hay formas de vida en la galaxia de Andrómeda*** (razones técnicas)
- ***Prefiero el helado de chocolate al de vainilla*** (subjetivo) Esto es **especulación**: fuera del alcance de la ciencia empírica.

No es algo negativo — el arte, la literatura, la música y la filosofía viven ahí.

# Los cuatro criterios

Una hipótesis debe ser:

1. **Falsable** — sobre la realidad empírica
2. **Contrastable** — sobre el mundo empírico
3. **Inequívoca** — sin ambigüedad
4. **Internamente consistente** La **universalidad no es requisito**: una hipótesis puede referirse a un evento singular y seguir siendo válida.

# Tipologías de hipótesis

| Distinción | Formulación |
|---|---|
| **No dirigida** | Los grupos A y B ***difieren*** ($\mu_A \neq \mu_B$) |
| **Dirigida** | A obtiene resultados ***mayores*** que B ($\mu_A > \mu_B$) |
| **Determinista** | La palabra corta ***siempre*** precede a la larga |
| **Probabilística** | Es ***más probable*** que la corta preceda a la larga |

# Por qué testeamos H0

En términos no técnicos: evaluamos **cuán probable es que el resultado se deba al azar**.

- $p > .05$ — probable que sea aleatorio $\rightarrow$ **no** descartamos H0
- $p < .05$ — improbable que sea aleatorio $\rightarrow$ descartamos H0, asumimos H1

# Muestra y población

Una **muestra** es una selección de **una** población —no de ***la*** población.

> Si la muestra incluye solo alemanes de 20 a 30 años, la población no es “todos los alemanes”, sino los alemanes de esa franja etaria en ese momento.

Debemos ser conscientes sobre **qué población podemos realmente inferir**.

# Diseño ≠ análisis

Dos pasos separados:

- **Diseño de investigación:** cómo se ***recogen*** los datos
- **Análisis de datos:** cómo se ***analizan*** Por eso **no tiene sentido** hablar de “diseño cualitativo” o “diseño cuantitativo”.

Cualquier diseño admite ambos enfoques analíticos.

# La distinción central

**Experimental vs. observacional**, y el criterio que los separa es la causalidad:

- **Observacional:** solo confirma **correlaciones** (X e Y coocurren)
- **Experimental:** puede determinar **causalidad** (X causa Y)

# Diseños en ciencias del lenguaje

| Diseño | Ejemplo | V. interna | V. externa | Costo |
|---|---|---|---|---|
| **Experimental** | Tiempos de reacción | Alta | Baja | Alto |
| **Corpus** | Estudio variacionista | Baja/var. | Alta | Bajo* |
| **Archivo** | Revisión sistemática | Media | Baja | Bajo |
| **Introspección** | Juicios de gramaticalidad | Alta | Baja/var. | Bajo |
| **Cuestionario** | Encuesta de uso | Media | Media | Bajo |

* Si el corpus ya existe; alto si hay que compilarlo.

# Experimental y cuasi-experimental

**Experimental (true experiment):** asignación **aleatoria** a grupos de test y control.

**Cuasi-experimental:** sin asignación aleatoria → vulnerable a ***confounding***.

Caen aquí:

- Estudios variacionistas de corpus
- Análisis de datos históricos (ya recogidos)
- Estudios de diferencias por sexo o edad

# Observacional: corpus

Los sujetos se observan en su **“hábitat natural”**.

- Alta **validez externa**: resultados transferibles al mundo real
- Precio: **sin control** sobre factores contextuales y de confusión
- Costo variable: mínimo si el corpus existe, alto si hay que grabar y transcribir

# Introspección

La vieja **“lingüística de sillón”** (***armchair linguistics***).

- Dominante en el siglo XX
- La forma más barata y fácil de “recoger datos”
- **Subjetiva** y sesgada por expectativas y marco teórico Desde los 90, relegada a **generación de hipótesis**, no como fuente única.

# Cuestionarios y elicitación

Métodos donde los informantes proveen información consciente:

- **Escalas Likert** (5 o 7 puntos): de ***muy en desacuerdo*** a ***muy de acuerdo***
- **Discourse Completion Tasks (DCT):** imaginar un contexto y responder
Salvaguardas metodológicas:
- **Fillers** — ítems distractores contra ***agreeability effects***
- **Aleatorización** de ítems contra ***fatigue effects***

# Operacionalización: el concepto ancla

**Operacionalización:** traducir un concepto abstracto en algo concretamente medible.

| Concepto | Operacionalización posible |
|---|---|
| Competencia lingüística | Puntaje de un ensayo |
| Complejidad | Longitud media de enunciado |
| Cortesía | Frecuencia de atenuadores |

**Cada operacionalización es una elección.**

# Dos tipos de validez

**Validez intrínseca:** correspondencia entre el concepto y la variable que lo mide.

- ***Ej.:*** complejidad → número de nodos sintácticos **Validez externa:** aplicabilidad de los hallazgos al mundo real.
- ***Ej.:*** recordar sílabas sin sentido en laboratorio → ¿aprender vocabulario real?

# Variables dependientes e independientes

- **Independiente:** el predictor (lo que manipulamos o registramos como causa potencial)
- **Dependiente:** el resultado (lo que medimos como efecto) ***Ejemplo médico:*** el fármaco (independiente) $\rightarrow$ presencia de síntomas (dependiente).

***Ejemplo lingüístico:*** la edad del hablante (independiente) $\rightarrow$ frecuencia de sujeto nulo (dependiente).

# Escalas de medición

| Escala | Propiedad | Ejemplo lingüístico |
|---|---|---|
| **Nominal / categórica** | Solo pertenencia a clase | Parte del discurso |
| **Ordinal** | Orden sin distancias cuantificables | Juicios Likert, rangos |
| **Intervalo** | Diferencias sí, razones no | Juicios de aceptabilidad |
| **Razón** | Diferencias y razones | Duración, n° de sílabas |
| **Conteos** | Enteros positivos, frecuencias | Errores por 1000 palabras |

# La escala dicta el test

Consecuencia práctica directa:

- $\chi^2 \rightarrow$ solo variables **nominales/categóricas**
- $t$-test $\rightarrow$ solo variables **numéricas Elegir mal la operacionalización cierra puertas analíticas.**

# La jerarquía es unidireccional

$$\text{nominal/categórica} < \text{ordinal} < \text{intervalo/razón}$$

Se puede **degradar** una variable, **nunca ascender**.

***Ejemplo:*** demasiados hablantes con cero palabrotas $\rightarrow$ se viola la normalidad de residuos.

- Opción A: rankear hablantes $\rightarrow$ Mann-Whitney U
- Opción B: dicotomizar (usa / no usa) $\rightarrow \chi^2$

# Cuatro dimensiones de una correlación

- **Fuerza** — ¿cuánto explica una variable la variabilidad de la otra?
- **Dirección** — ¿positiva o negativa?
- **Linealidad** — ¿es constante la relación?
- **Homogeneidad** — ¿es consistente? Fuerza y dirección son **ortogonales**: una correlación negativa puede ser tan fuerte como una positiva.

# Correlación espuria

> ***Los estudiantes que beben más café sacan mejores notas.***

¿Causa el café las buenas notas?

# Correlación espuria

> ***Los estudiantes que beben más café sacan mejores notas.***

¿Causa el café las buenas notas?

**No necesariamente.** El **tiempo de estudio** puede causar ambas cosas.

Una tercera variable explica la asociación observada.

# Cierre

| Concepto del capítulo | En nuestro módulo |
|---|---|
| Hipótesis previas a los datos | El EDA explora; no reemplaza el preregistro |
| Diseño y muestra | Fundamentos de muestreo (Semana 0) |
| Escalas de medición | Tipología de datos (Semana 1) |
| Correlación y dirección | Medidas de asociación (Semana 3–4) |
| Correlación espuria | Interpretación cautelosa (Semana 5) |

Una hipótesis es un enunciado **falsable**; el testeo evalúa la compatibilidad de los datos con **H0**, no la verdad de H1.

La **operacionalización** es una elección que determina la validez: ningún análisis rescata una mala medida.

La **escala de medición** decide qué análisis y qué visualización son posibles.

| Fundamento | En el EDA |
|---|---|
| Sesgo de confirmación | No quedarse solo con la visualización que confirma |
| Falsación | El EDA sugiere; validar exige refutar en datos nuevos |
| Patrones en el ruido | Distinguir patrón genuino de azar del corpus |
| Correlación ≠ causalidad | Una asociación no establece mecanismo causal |
| Pensamiento lento | El EDA es “pensamiento lento” sobre los datos |

# Para retener

> El **EDA no confirma** lo que ya sospechas.
>
> Es un procedimiento para **ver lo que hay** —incluyendo lo que no esperabas y lo que contradice tu intuición.

Su valor está precisamente en su capacidad de **sorprenderte y corregirte**.

# Referencias


- Evans, V., & Green, M. (2006). ***Cognitive Linguistics: An Introduction.*** Edinburgh UP.
- Hood, B. M. (2009). ***SuperSense.*** HarperOne.
- Kahneman, D. (2011). ***Thinking, Fast and Slow.*** Farrar, Straus and Giroux.
- Popper, K. R. (1959). ***The Logic of Scientific Discovery.*** Hutchinson.
- Sagan, C. (1995). ***The Demon-Haunted World.*** Ballantine Books.
- Schweinberger, M. ***Statistics for Linguists*** (SLAT7855), cap. 1. University of Queensland.

# Referencias


- Schweinberger, M. ***Statistics for Linguists*** (SLAT7855), cap. 2: Hypotheses and Variables. University of Queensland.
- Wilson, E. O. (1999). “The Natural Sciences”. En ***Consilience: The Unity of Knowledge***, 49–71.
- Popper, K. R. (1959). ***The Logic of Scientific Discovery.*** Hutchinson.
- Gries, S. T. (2021). ***Statistics for Linguistics with R*** (3ª ed.). Mouton de Gruyter.