LIIN-933

Conceptos Básicos y Tipos de Muestreo

Juan Zamora O.

Módulo de Análisis Exploratorio de Datos





El problema que organiza todo el curso

Casi nunca podemos observar la población completa. Trabajamos con una parte y queremos afirmar algo sobre el todo.

Tres preguntas encadenadas:

1. ¿Cómo **describimos** lo que tenemos delante?
2. ¿Cómo **exploramos** su estructura?
3. ¿Cómo **generalizamos** a lo que no observamos? Cada pregunta corresponde a una rama de la estadística —y el muestreo es lo que hace posible la tercera.

Agenda

Parte I — Conceptos básicos

- Las tres ramas de la estadística y el papel de la probabilidad
- Población, muestra, censo, parámetro y estadístico
- Variables: tipos y escalas de medición

Parte II — Métodos de muestreo

- La distinción fundamental: probabilístico vs. no probabilístico
- Cinco diseños probabilísticos
- Cuatro diseños no probabilísticos
- Limitaciones y criterio de elección

Las tres ramas de la estadística

La estadística es un conjunto de métodos de análisis de datos que se agrupan en tres categorías:

Rama	Qué hace
Descriptiva	Resume grandes volúmenes de datos mediante medidas de resumen, tablas y gráficos calculados a partir de ellos
—-	—-
Análisis exploratorio	Busca estructuras en la masa de datos que revelen las características de la fuente que los originó
Inferencia	Confirma o concluye propiedades de la población conociendo solo una parte representativa: la muestra

El puente: teoría de probabilidades

La teoría de probabilidades es la teoría matemática que modela el azar.

Su función en este esquema es precisa: **permite el paso desde la muestra hacia la población.**

Estadística descriptiva $\longrightarrow$ **Probabilidad** $\longrightarrow$ Inferencia estadística

Población y muestra

Población (estadística): cualquier colección o agrupación de objetos que comparten características básicas comunes. Sus objetos se denominan **unidades** o **elementos de la población**.

Muestra: cualquier subconjunto de elementos poblacionales. Sus miembros son **elementos** o **unidades muestrales**.

Para propósitos estadísticos, ese subconjunto debe obtenerse mediante **procedimientos objetivos**.

Muestra aleatoria: el calificativo que importa

Para distinguir una muestra **subjetiva** de una **objetiva** se añade el calificativo ***aleatoria***.

> Una **muestra aleatoria** es un subconjunto de elementos poblacionales seleccionados mediante alguna metodología objetiva.

Toda la Parte II de esta presentación desarrolla qué significa “metodología objetiva”.

Censo, parámetro y estadístico

Censo: observar la población completa; equivale a tomar una muestra igual a la población.

	Parámetro	**Estadístico**
Se refiere a	La población	La muestra
¿Se conoce?	En general, **no**	Sí, es un valor conocido
Estabilidad	Fijo	Varía de una muestra a otra
Ejemplo	Edad promedio de los habitantes de una región	Edad promedio de los habitantes seleccionados en la muestra

El estadístico se utiliza para **estimar** el parámetro y obtener conclusiones sobre la población.

Variables

Variables: características o atributos —de interés para el investigador— presentes en cada uno de los elementos que conforman la población.

Primera gran división:

- **Cualitativas (categóricas):** los elementos se clasifican en categorías o clases excluyentes
  - ***Ejemplos:*** estado civil, lugar de procedencia, marca de un artículo
- **Cuantitativas (numéricas):** los valores posibles son cantidades o números
  - ***Ejemplos:*** tiempo que demora un alumno en madurar un concepto, cantidad de palabras escritas por una secretaria en un minuto, porcentaje de impurezas en una jeringa

Subclasificación de las variables cuantitativas

Discretas: el conjunto de valores posibles es finito o infinito numerable.

- ***Ejemplos:*** cantidad de consultas atendidas por un profesor, cantidad de crías por camada **Continuas:** pueden asumir infinitos valores.
- ***Ejemplos:*** el sueldo de una persona, tiempo que tarda un animal en alcanzar un peso previamente determinado

Escalas de medición: variables categóricas

Nominal: las categorías no admiten ordenación por magnitud.

- ***Ejemplos:*** colores, sexo, actividad profesional (químico, agrónomo, etc.) **Ordinal:** las categorías admiten una ordenación —no alfabética.
- ***Ejemplos:*** nivel socioeconómico (alto, medio, bajo); sistema de evaluación en los primeros años de enseñanza básica (muy bueno, bueno, suficiente, insuficiente)

Escalas de medición: variables numéricas

Intervalos: poseen un punto de referencia (cero) **relativo** —relativo en el sentido de que al cambiar la unidad de medición, el punto de referencia difiere.

- Solo permiten comparaciones por **diferencias Razones:** poseen un cero **absoluto**, es decir, único.
- Permiten además comparaciones por **cocientes**

Síntesis de la Parte I

Población $\longrightarrow$ **muestra** $\longrightarrow$ estadístico $\longrightarrow$ estimación del parámetro

En cada elemento de la población medimos **variables**, cuyo tipo y escala determinan qué análisis es legítimo.

La calidad de todo el proceso depende del segundo paso: **cómo se obtuvo la muestra**.

La distinción fundamental

Muestreo probabilístico: se puede calcular la probabilidad que tiene cada muestra posible de ser sorteada durante el proceso.

- El **azar siempre está presente** en la selección
- Eso tiende a garantizar que la muestra sea **representativa** de la población bajo estudio **Muestreo no probabilístico:** no es posible conocer la probabilidad de sortear cada una de las muestras posibles.

Diseños probabilísticos: panorama

Cinco procedimientos, ordenados de menor a mayor complejidad estructural:

Diseño	Idea central
Aleatorio simple	Sorteo directo sobre la lista completa
Sistemático	Sorteo del punto de partida y recorrido regular
Estratificado	Dividir en grupos homogéneos y muestrear en cada uno
Conglomerados	Muestrear grupos completos y censarlos
Bietápico	Muestrear grupos y luego muestrear dentro de ellos

Muestreo aleatorio simple

Procedimiento en el que **todas las muestras posibles de un tamaño fijo tienen igual probabilidad** de ser seleccionadas.

Ejecución:

1. Enumerar todas las unidades muestrales
2. Sortear unidades hasta completar el número requerido

Muestreo sistemático

Se aplica cuando existe una lista de todas las unidades muestrales **en un orden independiente de la variable que se desea medir**.

Sea N el tamaño de la población y n el tamaño de la muestra. Se define:

$$M = \text{entero más cercano a } \frac{N}{n}$$

Procedimiento:

1. Seleccionar al azar un número entre 1 y M: será el orden de la primera unidad
2. Recorrer la lista seleccionando **una de cada** M hasta completar las n unidades

Muestreo estratificado

Consiste en dividir la población en grupos **homogéneos**, o **estratos**, según los valores de una variable relacionada con la característica bajo estudio, y aplicar muestreo aleatorio simple **dentro de cada estrato**.

Ejemplo: para medir las preferencias de una población de consumidores, se separa la población en estratos según nivel socioeconómico y se muestrea cada estrato por separado.

Muestreo por conglomerados

Consiste en dividir la población en pequeños grupos, o **conglomerados**, obtener una muestra aleatoria simple **de conglomerados**, y practicar un **censo dentro de cada conglomerado seleccionado**.

Ejemplo: para una encuesta de hogares en una ciudad, en lugar de muestrear hogares se muestrean **manzanas**. Se envía un encuestador a cada manzana seleccionada para encuestar todos sus hogares, lo que resulta más eficiente.

Muestreo en dos etapas (bietápico)

La muestra se toma en **dos pasos**:

1. Seleccionar una muestra de **unidades primarias**
2. Seleccionar una muestra de **elementos dentro de cada unidad primaria** escogida

Diseños no probabilísticos: panorama

Cuatro procedimientos donde la selección depende del criterio del investigador:

Diseño	Criterio de selección
Por cuotas	Proporciones fijadas por el investigador, sin sorteo interno
Bola de nieve	Los propios sujetos reclutan a los siguientes
Por conveniencia	Proximidad, facilidad de acceso, disponibilidad
Juicio experto	Filtrado por alguien con conocimiento del dominio

Muestreo por cuotas

El investigador construye una muestra con individuos que representan a la población, elegidos según rasgos o cualidades que él mismo define.

- Es similar al **estratificado**, salvo que los elementos de cada estrato **no se seleccionan aleatoriamente**
- Exige que el investigador comprenda muy bien los elementos constitutivos de la población ***Ejemplo:*** dividir la muestra por sexo, grupo etario o actividad laboral; decidir qué proporción corresponde a cada grupo y reclutar según su criterio.

Muestreo por bola de nieve o en cadena

Se utiliza para estudiar grupos muy pequeños o individuos difíciles de encontrar.

Procedimiento: seleccionar unos pocos sujetos iniciales —uno o dos— y pedirles que **recluten a otras personas** del mismo grupo o con las mismas características.

- ***Ejemplos:*** personas sin hogar, integrantes de grupos clandestinos, personas con comportamientos socialmente no aceptados como el consumo de drogas
- **Inconveniente:** el investigador tiene poco control sobre la muestra obtenida, y los sujetos finales dependen fuertemente de los seleccionados inicialmente

Muestreo intencionado o por conveniencia

La selección la hace el investigador por **proximidad, facilidad de acceso o disponibilidad** de las personas para formar parte de la muestra.

Ejemplos:

- Investigadores que se ubican a la salida de una clase y solicitan voluntarios para responder un cuestionario
- Periodistas que entrevistan transeúntes para conocer y difundir su opinión sobre un hecho de actualidad Los seleccionados comparten características comunes, lo que introduce un **fuerte sesgo** en los resultados.

Muestreo por juicio experto

Involucra a alguien con **conocimiento acabado** de las características de ciertos miembros de la población de interés.

- Esa persona ejecuta un **filtrado** de los sujetos para seleccionar solo los elegibles
- ***Ejemplo:*** en un estudio médico, seleccionar individuos que presentan cierta patología y están sometidos a un tratamiento determinado
- Generalmente las muestras resultantes son **muy pequeñas**

Limitaciones del muestreo

En el muestreo probabilístico es posible estimar la magnitud del error que se puede estar cometiendo, porque se conoce la probabilidad de obtener cada muestra.

En el muestreo no probabilístico, al no poder determinarse esa probabilidad:

- Es **imposible estimar el error muestral**
- Se producen **sesgos importantes**, porque la muestra depende fuertemente del criterio de quien la selecciona > Por eso el muestreo probabilístico siempre será mejor que el no probabilístico.

Mapa integrador

POBLACIÓN (parámetro desconocido)

↓ ***método de muestreo***

MUESTRA (estadístico conocido)

↓ ***teoría de probabilidades***

INFERENCIA (estimación con error cuantificable)

La flecha central solo funciona si la primera fue **probabilística**.

Tres ideas para retener

Un **estadístico** es conocido y variable; un **parámetro** es fijo y desconocido. Toda la estadística inferencial vive en esa asimetría.

El **tipo y la escala** de una variable determinan qué análisis es legítimo aplicarle.

Solo el **muestreo probabilístico** permite cuantificar el error; los demás diseños describen, pero no autorizan a generalizar formalmente.

Referencia

Videla J., Patricio. ***Conceptos básicos y tipos de muestreo.*** Material del curso Estadística 2.

Esta versión reorganiza el contenido original en dos partes, añade slides de articulación (marco general, panoramas de diseños, síntesis y mapa integrador) y parafrasea las definiciones buscando mayor precisión, sin suprimir contenido.