LIIN-933

Análisis exploratorio morfosintáctico

Juan Zamora O.

Módulo de Análisis Exploratorio de Datos





Agenda

Dejamos los datos inventados. A partir de ahora, corpus real y anotado.

La pregunta cambia: ya no es cómo funciona una función, sino **qué nos dicen estos datos sobre la lengua**.

Dos partes:

- Recorrido guiado sobre el treebank AnCora del español
- Extensión individual: anotar y analizar un texto propio

Ten RStudio abierto. Casi no mostraré resultados: los números salen de tu consola.

El arco de la sesión

Bloque	Análisis	Tipo de variable
Categorías gramaticales	Univariado	Nominal
Rasgos morfológicos	Univariado y cruces	Nominal extraída de texto
Nivel oracional	Agregación	Conteo, sesgada
Dependencias	Bivariado	Numérica por categórica

Cada bloque introduce un tipo de variable nuevo. La complejidad crece de forma deliberada.

UD Spanish AnCora

Treebank del español dentro del proyecto Universal Dependencies.

- Texto periodístico y de ficción
- Anotación morfosintáctica **revisada manualmente**
- Versión completa: unas 17.700 oraciones, 547.000 ocurrencias

Trabajaremos con el archivo de desarrollo: 1.650 oraciones, 53.000 ocurrencias.
Suficiente y rápido.

```
url_base <- "https://raw.githubusercontent.com/UniversalDependencies/UD_Span
download.file(paste0(url_base, "es_ancora-ud-dev.conllu"),
              destfile = "es_ancora-ud-dev.conllu")
```

El formato CoNLL-U

Una línea por ocurrencia, diez campos separados por tabuladores, oraciones separadas por líneas en blanco.

Campo	Contenido
`token`, `lemma`	Forma del texto y forma de diccionario
`upos`	Categoría gramatical universal
`feats`	Rasgos morfológicos, separados por barras
`head_token_id`	Posición del núcleo del que depende
`dep_rel`	Relación de dependencia

Cuando `head_token_id` vale 0, la ocurrencia es la raíz de la oración.

```
writeLines(head(readLines("es_ancora-ud-dev.conllu", n = 30)))
```

Carga e inventario

```
library(udpipe)
ancora <- udpipe_read_conllu("es_ancora-ud-dev.conllu")
str(ancora)
```

Cuatro preguntas antes de preguntarle nada a los datos:

```
nrow(ancora)                          # ocurrencias
length(unique(ancora$sentence_id))    # oraciones
length(unique(ancora$upos))           # categorías
colSums(is.na(ancora))                # faltantes
```

El campo `feats` estará vacío en categorías sin morfología flexiva. Eso no es un error del corpus, es una propiedad del sistema.

```
table(ancora$upos, is.na(ancora$feats))
```

Actividades 1

1.1 Carga el corpus y responde: ocurrencias, oraciones, tipos léxicos distintos en `token` y en `lemma`. ¿Por qué difieren los dos últimos, y en qué dirección?

1.2 Con `table()` sobre `upos`, cuenta las categorías presentes. El inventario oficial de UD tiene diecisiete. ¿Falta alguna? Propón una explicación.

1.3 Calcula la razón tipo-ocurrencia sobre `token` y sobre `lemma`. ¿Cuál responde mejor a la pregunta por la riqueza léxica?

Distribución univariada

Variable nominal: tablas de frecuencia y gráficos de barras.

```
frec_upos <- table(ancora$upos)
round(prop.table(frec_upos) * 100, 2)

barplot(sort(frec_upos, decreasing = TRUE),
        las = 2, cex.names = 0.8,
        main = "Distribución de categorías gramaticales",
        ylab = "Ocurrencias")
```

Ordenar por frecuencia, no alfabéticamente: el orden alfabético no informa nada.

Dos cosas que discutir al ver el gráfico: dónde queda `PUNCT`, y cuán sesgada está la distribución pese a tratarse de un inventario pequeño y cerrado.

Densidad léxica

Proporción de palabras de contenido sobre el total.

```
contenido <- c("NOUN", "VERB", "ADJ", "ADV", "PROPN")
ancora$es_contenido <- ancora$upos %in% contenido
mean(ancora$es_contenido)
```

Recuerda el mecanismo: `%in%` devuelve lógicos, y la media de un vector lógico es la proporción de verdaderos.

La cifra no dice nada en abstracto. Cobra sentido al **comparar** entre textos o registros.

Actividades 2

2.1 Genera la tabla de proporciones de `upos` ordenada de mayor a menor. ¿Qué tres categorías concentran la mayor parte de las ocurrencias?

2.2 Repite el gráfico excluyendo la puntuación. Compara ambas versiones: ¿cambia la interpretación?

2.3 Calcula la densidad léxica global, y luego excluyendo `PUNCT` del denominador. ¿Cuál es más comparable con otro corpus?

2.4 Calcula qué proporción del corpus ocupan `DET` y `ADP` juntos. Comenta el resultado a la luz de la ley de Zipf.

El campo feats

Pares atributo-valor separados por barras verticales:

```
Mood=Ind|Number=Sing|Person=3|Tense=Pres|VerbForm=Fin
```

Presencia de un rasgo, con `grepl()`:

```
ancora$femenino <- grepl("Gender=Fem", ancora$feats)
table(ancora$femenino)
```

Extraer el **valor**, no solo la presencia, requiere una expresión regular con captura. Lo haremos con una función propia.

Extraer valores

```r
extraer_rasgo <- function(feats, rasgo) {
  patron <- paste0(rasgo, "=([A-Za-z]+)")
  valor <- regmatches(feats, regexpr(patron, feats))
  valor <- sub(paste0(rasgo, "="), "", valor)
  resultado <- rep(NA_character_, length(feats))
  resultado[grepl(patron, feats)] <- valor
  resultado
}

ancora$genero <- extraer_rasgo(ancora$feats, "Gender")
ancora$modo   <- extraer_rasgo(ancora$feats, "Mood")

table(ancora$genero, useNA = "ifany")
```

`useNA = "ifany"` hace visibles los faltantes. Sin él, `table()` los oculta.

Atajo del paquete: `cbind_morphological(ancora, term = "feats")`

Preguntas específicamente lingüísticas

```r
sust <- subset(ancora, upos == "NOUN")
table(sust$genero, sust$numero)

verbos <- subset(ancora, upos == "VERB")
sort(table(verbos$modo), decreasing = TRUE)
```

Antes de ejecutar la última línea: anota tu estimación de la proporción de subjuntivo sobre indicativo.

Después compárala con el dato.

Actividades 3

3.1 Extrae `Person` y tabula su distribución en formas finitas (`VerbForm=Fin`). ¿Qué persona domina y qué relación tiene con el tipo de texto?

3.2 Tabla de contingencia género por número en adjetivos. Conviértela a proporciones por filas con `margin = 1` e interprétala.

3.3 Proporción de subjuntivo sobre el total de formas con modo marcado. Contrasta con tu estimación previa.

3.4 Compara la distribución de número entre sustantivos y adjetivos. ¿Son similares? Explica la diferencia si la hay.

3.5 Tabula `VerbForm` y calcula qué proporción de las formas verbales son no finitas.

Longitud de oración

Muchas preguntas se formulan a nivel de oración, no de ocurrencia. Eso requiere agregar.

```
long_oracion <- aggregate(token_id ~ sentence_id,
                          data = ancora, FUN = length)
names(long_oracion)[2] <- "n_tokens"

hist(long_oracion$n_tokens, breaks = 40,
     main = "Longitud de oración", xlab = "Ocurrencias")

mean(long_oracion$n_tokens)
median(long_oracion$n_tokens)
```

Mira la forma antes de resumirla con un número. Si media y mediana difieren, la cola está arrastrando la media.

Valores atípicos y composición

```r
boxplot(long_oracion$n_tokens, horizontal = TRUE)

# Inspeccionar el caso extremo
oracion_larga <- long_oracion$sentence_id[which.max(long_oracion$n_tokens)]
paste(subset(ancora, sentence_id == oracion_larga)$token, collapse = " ")
```

Composición gramatical por oración:

```r
comp <- as.data.frame.matrix(table(ancora$sentence_id, ancora$upos))
comp$n_tokens <- rowSums(comp)
comp$ratio_nom_verb <- comp$NOUN / comp$VERB
```

Cuidado: si una oración no tiene verbos, la razón es infinita. Verifícalo antes de promediar.

Actividades 4

4.1 Calcula longitud media y mediana de oración. Interpreta la diferencia.

4.2 Histograma de la longitud, y luego el mismo restringido a oraciones de menos de cincuenta ocurrencias. ¿Qué se ve mejor en cada uno?

4.3 Identifica las cinco oraciones más largas y reconstruye su texto. ¿Son legítimas o hay problemas de segmentación?

4.4 Calcula la densidad léxica por oración y compara su distribución con la cifra global. ¿Por qué pueden diferir?

4.5 Razón sustantivo sobre verbo por oración, excluyendo las oraciones sin verbos. Examina las cinco más altas: ¿qué tienen en común?

Distribución de relaciones

La anotación establece qué depende de qué. Esto no está disponible en un corpus etiquetado solo por categoría.

```
frec_dep <- sort(table(ancora$dep_rel), decreasing = TRUE)
head(frec_dep, 15)
round(prop.table(frec_dep)[1:10] * 100, 2)
```

Distancia de dependencia

Número de posiciones entre una palabra y su núcleo. Medida con respaldo empírico en psicolingüística: distancias mayores implican mayor carga de memoria de trabajo.

```
ancora$tok_num  <- as.numeric(ancora$token_id)
ancora$head_num <- as.numeric(ancora$head_token_id)

ancora$dist_dep <- ifelse(ancora$head_num == 0, NA,
                          abs(ancora$head_num - ancora$tok_num))

hist(ancora$dist_dep[!is.na(ancora$dist_dep)], breaks = 50,
     main = "Distancia de dependencia", xlab = "Distancia")
```

La distribución es fuertemente asimétrica: casi todas las dependencias son cortas. Ese es el hallazgo que sostiene la hipótesis de minimización de distancia.

El primer análisis bivariado

¿Depende la distancia del tipo de relación?

```
relaciones <- c("det", "amod", "nsubj", "obj", "obl", "advmod")
sub_rel <- subset(ancora, dep_rel %in% relaciones)

boxplot(dist_dep ~ dep_rel, data = sub_rel,
        main = "Distancia por tipo de relación",
        xlab = "", ylab = "Distancia", las = 2)
```

También la dirección:

```
ancora$direccion <- ifelse(ancora$head_num > ancora$tok_num,
                           "núcleo a la derecha", "núcleo a la izquierda")
table(ancora$direccion)
```

Actividades 5

5.1 Diez relaciones más frecuentes con sus proporciones. ¿Cuáles esperabas arriba y cuáles te sorprenden?

5.2 Distancia media y mediana del corpus. Interpreta la diferencia según la forma de la distribución.

5.3 Proporción de núcleo a la izquierda frente a la derecha. Relaciónalo con el orden de constituyentes del español.

5.4 Diagrama de cajas de distancia por tipo de relación. ¿Qué relaciones muestran distancias más largas? Explicación sintáctica.

5.5 ¿Se relaciona la distancia con la longitud de la oración? Agrega por oración, une con `merge()` y haz un diagrama de dispersión. Describe el patrón **sin afirmar causalidad**.

Anotar con udpipe

Todo lo anterior funciona sobre cualquier texto en español, porque `udpipe` produce la misma estructura de datos.

```
# Solo la primera vez
modelo_archivo <- udpipe_download_model(language = "spanish-ancora")
modelo <- udpipe_load_model(modelo_archivo$file_model)

mi_texto <- readLines("mi_texto.txt", encoding = "UTF-8")
anotado <- as.data.frame(udpipe_annotate(modelo, x = mi_texto))

str(anotado)
```

Compara la estructura con `ancora`. Las columnas son las mismas: **todo el código de hoy funciona sin cambios**.

La anotación automática tiene errores

En AnCora la anotación fue revisada a mano. En tu texto, no.

- La precisión en categoría gramatical suele ser alta, pero no perfecta
- En dependencias sintácticas es menor
- El modelo se entrenó con prensa y ficción **escritas**

Registros distantes de ese entrenamiento tendrán más errores: habla espontánea, redes sociales, textos históricos.

```
set.seed(42)
anotado[sample(nrow(anotado), 30), c("token", "lemma", "upos", "dep_rel")]
```

Inspecciona una muestra antes de confiar en cifras agregadas.

Qué entregar

Un guion de código y un informe de máximo dos páginas:

- **Descripción del texto**: qué es, de dónde viene, por qué lo elegiste, tamaño
- **Tres preguntas exploratorias**, formuladas **antes** de mirar resultados
- **Análisis**: al menos un univariado categórico, uno numérico y un cruce, con gráficos
- **Hallazgos**: incluyendo lo que no esperabas
- **Limitaciones**: qué no puedes concluir y qué haría falta para concluirlo

Si algo contradijo tu intuición inicial, dilo. Es el resultado más valioso.

La estructura que se repite

1. **Inventario**: qué hay, cuánto hay, qué falta
2. **Distribuciones univariadas**: primero categóricas, luego numéricas, mirando la forma antes de resumir
3. **Agregación**: cambiar de nivel de análisis
4. **Relaciones entre variables**

Esta secuencia se aplica a cualquier corpus, con independencia del contenido.

Lo que hay que documentar

Decisiones tomadas hoy, ninguna de ellas obvia:

- ¿Entra la puntuación en el análisis?
- ¿Qué hacer con las oraciones sin verbos?
- ¿Qué categorías cuentan como palabras de contenido?
- ¿Se excluyen las raíces al calcular distancias?

> La diferencia entre un análisis exploratorio y una serie de gráficos sueltos está, en buena medida, en si esas decisiones quedaron registradas.

Referencias

- Nivre, J. et al. (2020). Universal Dependencies v2. ***Proceedings of LREC 2020***. universaldependencies.org
- Taulé, M., Martí, M. A. y Recasens, M. (2008). AnCora: Multilevel Annotated Corpora for Catalan and Spanish. ***LREC 2008***.
- Wijffels, J. (2023). ***udpipe***. Paquete de R. bnosac.github.io/udpipe
- Liu, H. (2008). Dependency distance as a metric of language comprehension difficulty. ***Journal of Cognitive Science***, 9(2), 159-191.
- Gries, S. Th. (2009). ***Quantitative Corpus Linguistics with R***. Routledge.