LIIN-933

Análisis exploratorio de datos de lectura

Juan Zamora O.

Módulo de Análisis Exploratorio de Datos

INSTITUTO DE ESTADÍSTICA
IES PUCV

PONTIFICIA UNIVERSIDAD CATÓLICA DE VALPARAÍSO

Qué haremos hoy

Usamos una base de datos real (MECO).

Buscaremos explorar qué nos dicen estos datos sobre la lectura.

La idea es ir avanzando juntos en el análisis del conjunto de datos.

MECO

Corpus Multilingüe de Movimientos Oculares (***Multilingual Eye-movement Corpus***).

- Esfuerzo internacional coordinado de laboratorios de seguimiento ocular
- Los participantes leen en su lengua materna con registro infrarrojo de video
- Doce textos expositivos, traducidos y adaptados a cada lengua
- Más de veinte lenguas entre sus distintas versiones

Estructura cruzada: cada palabra fue leída por muchos participantes, cada participante leyó muchas palabras.

Datos: https://osf.io/3527a

Las medidas oculomotoras

Variable	Contenido
`word`, `ianum`	La palabra y su posición en el texto
`subid`, `lang`	Participante y lengua
`skip`, `firstrun.skip`	Omisión total y de primera pasada
`nfix`, `refix`	Número de fijaciones, refijación
`reg.in`, `reg.out`	Regresión hacia y desde la palabra
`firstfix.dur`	Duración de la primera fijación
`firstrun.dur`	Duración de primera pasada
`dur`	Tiempo total de lectura

Carga de datos de Eye-tracking

Los archivos vienen en formato `.rda`, que contiene objetos con su propio nombre:

```
load("joint_data_trimmed.rda")
```

```
str(meco); names(meco); dim(meco)
```

```
length(unique(meco$subid))      # participantes
length(unique(meco$lang))       # lenguas
table(meco$lang)
```

Las muestras **no** son de igual tamaño: el número de participantes varía entre laboratorios.

Valores Faltantes (***Missing values***)

```
colSums(is.na(meco[, c("firstfix.dur", "firstrun.dur", "dur")]))
table(meco$skip, is.na(meco$dur))
```

¡No son un defecto!

Una palabra omitida no tiene duración porque nunca fue fijada.

Dos preguntas distintas, dos cálculos distintos:

```
mean(meco$dur, na.rm = TRUE)          # ¿sobre qué población promedia?
fijadas <- subset(meco, skip == 0)
mean(fijadas$dur)                     # explícito
```

`na.rm = TRUE` usado mecánicamente oculta la decisión.

Actividades del bloque 1

1.1 Construye la tabla de participantes por lengua y ordénala. ¿Cuál tiene más y cuál menos? ¿Qué problema plantea esa desigualdad para comparar lenguas?

1.2 Verifica la relación de orden entre las tres duraciones (`firstfix.dur`, `firstrun.dur` y `dur`) sobre palabras fijadas (`skip==0`). Si alguna observación la incumple, examínala.

Omisión y regresión

Variables codificadas como 0 y 1. Su media es directamente la proporción de unos.

```
mean(meco$skip)                    # tasa global de omisión
mean(meco$reg.in, na.rm = TRUE)    # tasa de regresiones entrantes
```

Las regresiones son frecuentes en la lectura: la literatura las sitúa entre el cinco y el veinte por ciento de todos los sacádicos.

Comprobar dónde cae este corpus en ese rango es la primera verificación empírica de la sesión.

Comparación entre lenguas

```
omision <- tapply(meco$skip, meco$lang, mean)
sort(omision)

barplot(sort(omision), las = 2, cex.names = 0.8,
        main = "Tasa de omisión por lengua",
        ylab = "Proporción de palabras omitidas")
```

¿Qué lenguas esperas en cada extremo?¿por qué?

Actividades del bloque 2

2.1 Calcula la tasa global de omisión y la de regresiones entrantes (`reg.in`). Contrasta la segunda con el rango del cinco al veinte por ciento de la literatura.

2.2 Compara la tasa de omisión total (`skip`) con la de primera pasada (`firstrun.skip`). ¿Cuál es mayor y por qué tiene que ser así necesariamente?

Construir un predictor

```
meco$long_palabra <- nchar(meco$word)
summary(meco$long_palabra)
```

```
tapply(meco$long_palabra, meco$lang, mean)
```

La columna `word` contiene la palabra como texto

Usndo `nchar()` obtiene de ella una variable numérica.

Recodificar en grupos

```
meco$long_grupo <- cut(meco$long_palabra,
                       breaks = c(0, 3, 5, 8, Inf),
                       labels = c("muy corta", "corta", "media", "larga"))

table(meco$long_grupo)
tapply(meco$skip, meco$long_grupo, mean)
```

`cut()` devuelve un factor con los niveles ya ordenados. Los intervalos son abiertos por la izquierda: tres caracteres cae en la primera categoría, cuatro en la segunda.

Actividades del bloque 3

3.1 Calcula la longitud media de palabra por lengua y ordénala. Contrástala con la tasa de omisión del bloque 2: ¿se confirma tu predicción?

3.2 Recodifica la longitud en cuatro grupos y calcula la tasa de omisión por grupo. Describe la relación en una frase.

Miremos la “forma” de tiempos de lectura

```
fijadas <- subset(meco, skip==0)
hist(fijadas$dur, breaks = 100,
     main = "Tiempo total de lectura por palabra", xlab = "ms")

mean(fijadas$dur)
median(fijadas$dur)
```

Asimetría marcada hacia la derecha: muchas duraciones breves y una cola larga de duraciones prolongadas.

La media y la mediana difieren de forma sustantiva. La media está siendo desplazada hacia arriba por los valores de la cola.

Debemos mirar la forma antes de resumirla con un número (media, mediana...)

Transformación logarítmica

```
par(mfrow = c(1, 2))
hist(fijadas$dur, breaks = 100, main = "Escala original", xlab = "ms")
hist(log(fijadas$dur), breaks = 100, main = "Escala log", xlab = "log(ms)")
par(mfrow = c(1, 1))
```

La versión transformada es aproximadamente simétrica.

Cambia la escala de interpretación, y las conclusiones deben formularse en consecuencia.

Agregar por participante

```
por_part <- aggregate(dur ~ subid + lang, data = fijadas, FUN = mean)
names(por_part)[3] <- "dur_media"

nrow(por_part)        # debe coincidir con el número de participantes
```

Incluir `lang` en la fórmula conserva la lengua de cada participante.

```
tasas <- aggregate(cbind(skip, reg.in) ~ subid + lang,
                   data = meco, FUN = mean)
lectores <- merge(por_part, tasas, by = c("subid", "lang"))
```

Por qué importa el nivel (Pseudo-replicación)

```
mean(fijadas$dur)              # promedio sobre palabras
mean(por_part$dur_media)       # promedio sobre participantes
```

Un análisis a nivel de palabra que trate todas las observaciones como independientes está mal especificado

Hay muchas observaciones por participante y no son independientes.

Actividades del bloque 4

4.1 Construye el histograma de `dur` sobre palabras fijadas, calcula media y mediana e interpreta la diferencia. Repite con la transformación logarítmica.

4.2 Agrega por participante la duración media, la tasa de omisión y la tasa de regresión. Verifica que el número de filas coincide con el número de participantes.

Numérica por categórica

```
boxplot(dur_media ~ lang, data = por_part,
        las = 2, cex.axis = 0.8,
        main = "Tiempo medio de lectura por lengua",
        xlab = "", ylab = "Milisegundos")
```

Agregamos primero por participante y comparamos ***después***.

Hacer el diagrama directamente sobre las palabras produciría cajas basadas en decenas de miles de observaciones no independientes, con una dispersión que refleja variabilidad entre palabras y no entre lectores.

Dos variables numéricas

```
long_dur <- aggregate(dur ~ long_palabra, data = fijadas, FUN = median)
plot(long_dur$long_palabra, long_dur$dur, pch = 16, type = "b",
     xlab = "Caracteres", ylab = "Mediana del tiempo total (ms)")

cor(fijadas$long_palabra, fijadas$dur, method = "pearson")
cor(fijadas$long_palabra, fijadas$dur, method = "spearman")
```

Pearson supone linealidad y es sensible a los extremos. Con una variable tan asimétrica, ***Spearman*** es más informativo.

Que ambos difieran es en sí mismo un dato sobre la forma de la relación.

Actividades del bloque 5

5.1 Construye el diagrama de cajas de la duración media por lengua, a nivel de participante. ¿Qué lenguas muestran los tiempos más largos y cuáles la mayor dispersión entre lectores?

5.2 Elige dos lenguas del corpus ojalá con sistemas de escritura distintos, y repite los análisis.

```
mis_lenguas <- c("es", "fi")
mi_sub <- subset(meco, lang %in% mis_lenguas)
```

Conclusiones

- ¿El análisis se hace sobre todas las palabras o solo sobre las fijadas?
- ¿Se transforman las duraciones o no?
- ¿En qué puntos se cortan los grupos de longitud?
- ¿A qué nivel se agrega antes de comparar?
- ¿Qué coeficiente de correlación se reporta?

Referencias

- Siegelman, N., Schroeder, S., Acartürk, C. et al. (2022). Expanding horizons of cross-linguistic research on reading: The Multilingual Eye-movement Corpus (MECO). ***Behavior Research Methods***, 54, 2843-2863.
- Siegelman, N. et al. (2025). Wave 2 of the Multilingual Eye-Movement Corpus (MECO): New text reading data across languages. ***Scientific Data***.
- Datos: https://osf.io/3527a