# LIIN-933

## Análisis exploratorio morfosintáctico

Juan Zamora O.

Módulo de Análisis Exploratorio de Datos






# Agenda

Dejamos los datos inventados. A partir de ahora, corpus real y anotado.

La pregunta cambia: ya no es cómo funciona una función, sino **qué nos dicen estos datos sobre la lengua**.

Dos partes:

- Recorrido guiado sobre el treebank AnCora del español
- Extensión individual: anotar y analizar un texto propio

Ten RStudio abierto. Casi no mostraré resultados: los números salen de tu consola.

# El arco de la sesión

| Bloque | Análisis | Tipo de variable |
|---|---|---|
| Categorías gramaticales | Univariado | Nominal |
| Rasgos morfológicos | Univariado y cruces | Nominal extraída de texto |
| Nivel oracional | Agregación | Conteo, sesgada |
| Dependencias | Bivariado | Numérica por categórica |

Cada bloque introduce un tipo de variable nuevo. La complejidad crece de forma deliberada.

# UD Spanish AnCora

Treebank del español dentro del proyecto Universal Dependencies.

- Texto periodístico y de ficción
- Anotación morfosintáctica **revisada manualmente**
- Versión completa: unas 17.700 oraciones, 547.000 ocurrencias

Trabajaremos con el archivo de desarrollo: 1.650 oraciones, 53.000 ocurrencias.
Suficiente y rápido.

```
url_base <- "https://raw.githubusercontent.com/UniversalDependencies/UD_Span
download.file(paste0(url_base, "es_ancora-ud-dev.conllu"),
              destfile = "es_ancora-ud-dev.conllu")
```

# El formato CoNLL-U

Una línea por ocurrencia, diez campos separados por tabuladores, oraciones separadas por líneas en blanco.

| Campo | Contenido |
|---|---|
| `token`, `lemma` | Forma del texto y forma de diccionario |
| `upos` | Categoría gramatical universal |
| `feats` | Rasgos morfológicos, separados por barras |
| `head_token_id` | Posición del núcleo del que depende |
| `dep_rel` | Relación de dependencia |

Cuando `head_token_id` vale 0, la ocurrencia es la raíz de la oración.

```
writeLines(head(readLines("es_ancora-ud-dev.conllu", n = 30)))
```

# Carga e inventario

```
library(udpipe)
ancora <- udpipe_read_conllu("es_ancora-ud-dev.conllu")
str(ancora)
```

Cuatro preguntas antes de preguntarle nada a los datos:

```
nrow(ancora)                          # ocurrencias
length(unique(ancora$sentence_id))    # oraciones
length(unique(ancora$upos))           # categorías
colSums(is.na(ancora))                # faltantes
```

El campo `feats` estará vacío en categorías sin morfología flexiva. Eso no es un error del corpus, es una propiedad del sistema.

```
table(ancora$upos, is.na(ancora$feats))
```

# Actividades 1

**1.1** Carga el corpus y responde: ocurrencias, oraciones, tipos léxicos distintos en `token` y en `lemma`. ¿Por qué difieren los dos últimos, y en qué dirección?

**1.2** Con `table()` sobre `upos`, cuenta las categorías presentes. El inventario oficial de UD tiene diecisiete. ¿Falta alguna? Propón una explicación.

**1.3** Calcula la razón tipo-ocurrencia sobre `token` y sobre `lemma`. ¿Cuál responde mejor a la pregunta por la riqueza léxica?

# Distribución univariada

Variable nominal: tablas de frecuencia y gráficos de barras.

```
frec_upos <- table(ancora$upos)
round(prop.table(frec_upos) * 100, 2)

barplot(sort(frec_upos, decreasing = TRUE),
        las = 2, cex.names = 0.8,
        main = "Distribución de categorías gramaticales",
        ylab = "Ocurrencias")
```

Ordenar por frecuencia, no alfabéticamente: el orden alfabético no informa nada.

Dos cosas que discutir al ver el gráfico: dónde queda `PUNCT`, y cuán sesgada está la distribución pese a tratarse de un inventario pequeño y cerrado.

# Densidad léxica

Proporción de palabras de contenido sobre el total.

```
contenido <- c("NOUN", "VERB", "ADJ", "ADV", "PROPN")
ancora$es_contenido <- ancora$upos %in% contenido
mean(ancora$es_contenido)
```

Recuerda el mecanismo: `%in%` devuelve lógicos, y la media de un vector lógico es la proporción de verdaderos.

La cifra no dice nada en abstracto. Cobra sentido al **comparar** entre textos o registros.

# Actividades 2

**2.1** Genera la tabla de proporciones de `upos` ordenada de mayor a menor. ¿Qué tres categorías concentran la mayor parte de las ocurrencias?

**2.2** Repite el gráfico excluyendo la puntuación. Compara ambas versiones: ¿cambia la interpretación?

**2.3** Calcula la densidad léxica global, y luego excluyendo `PUNCT` del denominador. ¿Cuál es más comparable con otro corpus?

**2.4** Calcula qué proporción del corpus ocupan `DET` y `ADP` juntos. Comenta el resultado a la luz de la ley de Zipf.

# El campo feats

Pares atributo-valor separados por barras verticales:

```
Mood=Ind|Number=Sing|Person=3|Tense=Pres|VerbForm=Fin
```

Presencia de un rasgo, con `grepl()`:

```
ancora$femenino <- grepl("Gender=Fem", ancora$feats)
table(ancora$femenino)
```

Extraer el **valor**, no solo la presencia, requiere una expresión regular con captura. Lo haremos con una función propia.

# Extraer valores

```r
extraer_rasgo <- function(feats, rasgo) {
  patron <- paste0(rasgo, "=([A-Za-z]+)")
  valor <- regmatches(feats, regexpr(patron, feats))
  valor <- sub(paste0(rasgo, "="), "", valor)
  resultado <- rep(NA_character_, length(feats))
  resultado[grepl(patron, feats)] <- valor
  resultado
}

ancora$genero <- extraer_rasgo(ancora$feats, "Gender")
ancora$modo   <- extraer_rasgo(ancora$feats, "Mood")

table(ancora$genero, useNA = "ifany")
```

`useNA = "ifany"` hace visibles los faltantes. Sin él, `table()` los oculta.

Atajo del paquete: `cbind_morphological(ancora, term = "feats")`

# Preguntas específicamente lingüísticas

```r
sust <- subset(ancora, upos == "NOUN")
table(sust$genero, sust$numero)

verbos <- subset(ancora, upos == "VERB")
sort(table(verbos$modo), decreasing = TRUE)
```

**Antes de ejecutar la última línea:** anota tu estimación de la proporción de subjuntivo sobre indicativo.

Después compárala con el dato.

# Actividades 3

**3.1** Extrae `Person` y tabula su distribución en formas finitas (`VerbForm=Fin`). ¿Qué persona domina y qué relación tiene con el tipo de texto?

**3.2** Tabla de contingencia género por número en adjetivos. Conviértela a proporciones por filas con `margin = 1` e interprétala.

**3.3** Proporción de subjuntivo sobre el total de formas con modo marcado. Contrasta con tu estimación previa.

**3.4** Compara la distribución de número entre sustantivos y adjetivos. ¿Son similares? Explica la diferencia si la hay.

**3.5** Tabula `VerbForm` y calcula qué proporción de las formas verbales son no finitas.

# Longitud de oración

Muchas preguntas se formulan a nivel de oración, no de ocurrencia. Eso requiere agregar.

```
long_oracion <- aggregate(token_id ~ sentence_id,
                          data = ancora, FUN = length)
names(long_oracion)[2] <- "n_tokens"

hist(long_oracion$n_tokens, breaks = 40,
     main = "Longitud de oración", xlab = "Ocurrencias")

mean(long_oracion$n_tokens)
median(long_oracion$n_tokens)
```

Mira la forma antes de resumirla con un número. Si media y mediana difieren, la cola está arrastrando la media.

# Valores atípicos y composición

```r
boxplot(long_oracion$n_tokens, horizontal = TRUE)

# Inspeccionar el caso extremo
oracion_larga <- long_oracion$sentence_id[which.max(long_oracion$n_tokens)]
paste(subset(ancora, sentence_id == oracion_larga)$token, collapse = " ")
```

Composición gramatical por oración:

```r
comp <- as.data.frame.matrix(table(ancora$sentence_id, ancora$upos))
comp$n_tokens <- rowSums(comp)
comp$ratio_nom_verb <- comp$NOUN / comp$VERB
```

Cuidado: si una oración no tiene verbos, la razón es infinita. Verifícalo antes de promediar.

# Actividades 4

**4.1** Calcula longitud media y mediana de oración. Interpreta la diferencia.

**4.2** Histograma de la longitud, y luego el mismo restringido a oraciones de menos de cincuenta ocurrencias. ¿Qué se ve mejor en cada uno?

**4.3** Identifica las cinco oraciones más largas y reconstruye su texto. ¿Son legítimas o hay problemas de segmentación?

**4.4** Calcula la densidad léxica por oración y compara su distribución con la cifra global. ¿Por qué pueden diferir?

**4.5** Razón sustantivo sobre verbo por oración, excluyendo las oraciones sin verbos. Examina las cinco más altas: ¿qué tienen en común?

# Distribución de relaciones

La anotación establece qué depende de qué. Esto no está disponible en un corpus etiquetado solo por categoría.

```
frec_dep <- sort(table(ancora$dep_rel), decreasing = TRUE)
head(frec_dep, 15)
round(prop.table(frec_dep)[1:10] * 100, 2)
```

# Distancia de dependencia

Número de posiciones entre una palabra y su núcleo. Medida con respaldo empírico en psicolingüística: distancias mayores implican mayor carga de memoria de trabajo.

```
ancora$tok_num  <- as.numeric(ancora$token_id)
ancora$head_num <- as.numeric(ancora$head_token_id)

ancora$dist_dep <- ifelse(ancora$head_num == 0, NA,
                          abs(ancora$head_num - ancora$tok_num))

hist(ancora$dist_dep[!is.na(ancora$dist_dep)], breaks = 50,
     main = "Distancia de dependencia", xlab = "Distancia")
```

La distribución es fuertemente asimétrica: casi todas las dependencias son cortas. Ese es el hallazgo que sostiene la hipótesis de minimización de distancia.

# El primer análisis bivariado

¿Depende la distancia del tipo de relación?

```
relaciones <- c("det", "amod", "nsubj", "obj", "obl", "advmod")
sub_rel <- subset(ancora, dep_rel %in% relaciones)

boxplot(dist_dep ~ dep_rel, data = sub_rel,
        main = "Distancia por tipo de relación",
        xlab = "", ylab = "Distancia", las = 2)
```

También la dirección:

```
ancora$direccion <- ifelse(ancora$head_num > ancora$tok_num,
                           "núcleo a la derecha", "núcleo a la izquierda")
table(ancora$direccion)
```

# Actividades 5

**5.1** Diez relaciones más frecuentes con sus proporciones. ¿Cuáles esperabas arriba y cuáles te sorprenden?

**5.2** Distancia media y mediana del corpus. Interpreta la diferencia según la forma de la distribución.

**5.3** Proporción de núcleo a la izquierda frente a la derecha. Relaciónalo con el orden de constituyentes del español.

**5.4** Diagrama de cajas de distancia por tipo de relación. ¿Qué relaciones muestran distancias más largas? Explicación sintáctica.

**5.5** ¿Se relaciona la distancia con la longitud de la oración? Agrega por oración, une con `merge()` y haz un diagrama de dispersión. Describe el patrón **sin afirmar causalidad**.

# Anotar con udpipe

Todo lo anterior funciona sobre cualquier texto en español, porque `udpipe` produce la misma estructura de datos.

```
# Solo la primera vez
modelo_archivo <- udpipe_download_model(language = "spanish-ancora")
modelo <- udpipe_load_model(modelo_archivo$file_model)

mi_texto <- readLines("mi_texto.txt", encoding = "UTF-8")
anotado <- as.data.frame(udpipe_annotate(modelo, x = mi_texto))

str(anotado)
```

Compara la estructura con `ancora`. Las columnas son las mismas: **todo el código de hoy funciona sin cambios**.

# La anotación automática tiene errores

En AnCora la anotación fue revisada a mano. En tu texto, no.

- La precisión en categoría gramatical suele ser alta, pero no perfecta
- En dependencias sintácticas es menor
- El modelo se entrenó con prensa y ficción **escritas**

Registros distantes de ese entrenamiento tendrán más errores: habla espontánea, redes sociales, textos históricos.

```
set.seed(42)
anotado[sample(nrow(anotado), 30), c("token", "lemma", "upos", "dep_rel")]
```

Inspecciona una muestra antes de confiar en cifras agregadas.

# Qué entregar

Un guion de código y un informe de máximo dos páginas:

- **Descripción del texto**: qué es, de dónde viene, por qué lo elegiste, tamaño
- **Tres preguntas exploratorias**, formuladas **antes** de mirar resultados
- **Análisis**: al menos un univariado categórico, uno numérico y un cruce, con gráficos
- **Hallazgos**: incluyendo lo que no esperabas
- **Limitaciones**: qué no puedes concluir y qué haría falta para concluirlo

Si algo contradijo tu intuición inicial, dilo. Es el resultado más valioso.

# La estructura que se repite

1. **Inventario**: qué hay, cuánto hay, qué falta
2. **Distribuciones univariadas**: primero categóricas, luego numéricas, mirando la forma antes de resumir
3. **Agregación**: cambiar de nivel de análisis
4. **Relaciones entre variables**

Esta secuencia se aplica a cualquier corpus, con independencia del contenido.

# Lo que hay que documentar

Decisiones tomadas hoy, ninguna de ellas obvia:

- ¿Entra la puntuación en el análisis?
- ¿Qué hacer con las oraciones sin verbos?
- ¿Qué categorías cuentan como palabras de contenido?
- ¿Se excluyen las raíces al calcular distancias?

> La diferencia entre un análisis exploratorio y una serie de gráficos sueltos está, en buena medida, en si esas decisiones quedaron registradas.

# Referencias


- Nivre, J. et al. (2020). Universal Dependencies v2. ***Proceedings of LREC 2020***. universaldependencies.org
- Taulé, M., Martí, M. A. y Recasens, M. (2008). AnCora: Multilevel Annotated Corpora for Catalan and Spanish. ***LREC 2008***.
- Wijffels, J. (2023). ***udpipe***. Paquete de R. bnosac.github.io/udpipe
- Liu, H. (2008). Dependency distance as a metric of language comprehension difficulty. ***Journal of Cognitive Science***, 9(2), 159-191.
- Gries, S. Th. (2009). ***Quantitative Corpus Linguistics with R***. Routledge.