LIIN-933

Análisis exploratorio de datos de lectura (continuación con el corpus)

Juan Zamora O.

Módulo de Análisis Exploratorio de Datos

INSTITUTO DE ESTADÍSTICA
IES PUCV

PONTIFICIA UNIVERSIDAD CATÓLICA DE VALPARAÍSO

Qué haremos hoy

Anteriormente describimos la forma de una distribución mirando un histograma. Hoy la describimos numéricamente.

Cinco bloques: tendencia central, dispersión, posición relativa, diagrama de caja, medidas de asociación.

Seguimos con los datos de lectura de MECO. Cada medida se calcula sobre una variable que ya conocemos: `dur`, `long_palabra`, `nfix`.

Media, mediana y moda

```
mean(fijadas$dur)
median(fijadas$dur)
```

La moda no tiene función incorporada en R. Se construye a partir de una tabla de frecuencias:

```
moda <- function(x) {
  tabla <- table(x)
  as.numeric(names(tabla)[tabla == max(tabla)])
}

moda(fijadas$long_palabra)
```

Tres medidas: valor central por suma, valor central por posición, valor más repetido.

Cuándo cada medida es apropiada

Medida	Es apropiada cuando	No es apropiada cuando
Media	La distribución es simétrica	Hay asimetría marcada o valores extremos
Mediana	Hay asimetría o valores extremos	Se necesita usar la suma total de los datos
Moda	La variable es categórica o discreta	Hay muchos valores distintos con frecuencia similar

```
mean(fijadas$dur) - median(fijadas$dur)
```

Una diferencia notoria entre media y mediana da cuenta de asimetría.

Actividades del bloque 1

1.1 Calcula la media, la mediana y la moda de `nfix` (número de fijaciones) sobre el objeto `fijadas`. Reporta los tres valores con dos decimales cuando corresponda.

1.2 Calcula la media y la mediana de `dur` por separado para cada lengua, usando `tapply()`. Identifica la lengua donde la diferencia entre ambas medidas es mayor.

1.3 Calcula la diferencia entre media y mediana de `dur` como proporción de la mediana: `(media - mediana) / mediana`. Expresa el resultado como porcentaje.

Percentiles y cuantiles

Un percentil indica el valor por debajo del cual se encuentra un porcentaje determinado de las observaciones.

```
quantile(fijadas$dur, probs = c(0.10, 0.25, 0.50, 0.75, 0.90))
```

El percentil 50 es la mediana. Los percentiles 25 y 75 son el primer y el tercer cuartil.

```
quantile(fijadas$dur, probs = seq(0, 1, by = 0.1))   # deciles
```

Uso de percentiles para definir umbrales

Los percentiles permiten clasificar observaciones sin fijar un umbral arbitrario de antemano.

```
umbral_90 <- quantile(fijadas$dur, probs = 0.90)
umbral_90

fijadas$lectura_lenta <- fijadas$dur > umbral_90

mean(fijadas$lectura_lenta)      # debe ser aproximadamente 0.10
```

El diez por ciento de las palabras con mayor tiempo de lectura quedan marcadas, sin necesidad de decidir un número fijo de milisegundos.

Actividades del bloque 2

2.1 Calcula los percentiles 10, 25, 50, 75 y 90 de `long_palabra` sobre `meco`. Interpreta el percentil 90: ¿qué significa ese valor en palabras simples?

2.2 Define como "palabra larga" a toda palabra con longitud igual o superior al percentil 90 de `long_palabra`. Calcula qué proporción de las palabras del corpus cumple esa condición y verifica que el resultado es cercano al esperado.

2.3 Calcula el percentil correspondiente a una duración de 300 milisegundos dentro de `fijadas$dur`, usando la función `ecdf()`. Redacta una frase que exprese ese resultado en términos de percentil.

Rango y rango intercuartílico

```
max(fijadas$dur) - min(fijadas$dur)      # rango

IQR(fijadas$dur)                         # rango intercuartílico
```

El rango depende únicamente de los dos valores extremos y es muy sensible a ellos.

El rango intercuartílico es la diferencia entre el tercer y el primer cuartil, y contiene el cincuenta por ciento central de los datos:

```
quantile(fijadas$dur, probs = c(0.25, 0.75))
```

Varianza y desviación estándar

```
var(fijadas$dur)      # varianza
sd(fijadas$dur)       # desviación estándar
```

La desviación estándar se expresa en la misma unidad que la variable original; la varianza, en esa unidad al cuadrado.

Por esa razón, la desviación estándar es la que se reporta habitualmente.

```
sqrt(var(fijadas$dur)) == sd(fijadas$dur)
```

Coeficiente de variación

Varianza y desviación estándar no permiten comparar variables en escalas distintas. El coeficiente de variación sí, porque es adimensional:

$$CV = \frac{\text{desviación estándar}}{\text{media}} \times 100$$

```
cv <- function(x) sd(x) / mean(x) * 100

cv(fijadas$dur)              # milisegundos
cv(fijadas$long_palabra)     # caracteres
```

Un CV mayor indica más dispersión relativa, sin importar la unidad de medida.

Actividades del bloque 3

3.1 Calcula el rango, el rango intercuartílico, la varianza y la desviación estándar de `dur` sobre `fijadas`. Presenta los cuatro valores en una tabla.

3.2 Calcula la desviación estándar de `dur` por separado para cada lengua con `tapply()`. Identifica la lengua con mayor y con menor dispersión.

3.3 Calcula el coeficiente de variación de `dur` y el de `long_palabra`. ¿Cuál de las dos variables presenta mayor dispersión relativa?

3.4 Repite el cálculo del coeficiente de variación de `dur`, mostrado en la lámina anterior, pero calculado por separado para cada lengua. Ordena el resultado de mayor a menor.

Construcción del diagrama

Resume cinco valores: el mínimo, el primer cuartil, la mediana, el tercer cuartil y el máximo, ajustando los dos últimos según un criterio de valores atípicos.

```
boxplot(fijadas$dur,
        main = "Tiempo total de lectura por palabra",
        ylab = "Milisegundos")

boxplot(dur ~ lang, data = fijadas,
        las = 2, cex.axis = 0.8,
        main = "Tiempo de lectura por lengua",
        ylab = "Milisegundos")
```

Criterio de valores atípicos

Un valor se considera atípico si está por debajo de $Q_1 - 1{,}5 \times IQR$ o por encima de $Q_3 + 1{,}5 \times IQR$.

```
Q1 <- quantile(fijadas$dur, 0.25)
Q3 <- quantile(fijadas$dur, 0.75)
IQR <- Q3 - Q1

limite_inferior <- Q1 - 1.5 * IQR
limite_superior <- Q3 + 1.5 * IQR

c(limite_inferior, limite_superior)

atipicos <- subset(fijadas, dur < limite_inferior | dur > limite_superior)
nrow(atipicos)
round(nrow(atipicos) / nrow(fijadas) * 100, 2)
```

El valor 1,5 es una convención, no una regla derivada de los datos.

Actividades del bloque 4

4.1 Calcula los límites inferior y superior para valores atípicos de `dur` sobre `fijadas`, siguiendo el criterio de la lámina anterior. Indica cuántas observaciones caen fuera de esos límites y qué porcentaje representan del total.

4.2 Construye el diagrama de caja de `dur` separado por `long_grupo`. Ordena las categorías del eje horizontal de menor a mayor longitud antes de graficar.

4.3 A partir del diagrama de la actividad 4.2, indica qué grupo de longitud presenta la mayor cantidad de valores atípicos visibles en el gráfico.

4.4 Calcula el límite superior de valores atípicos de `dur` por separado para dos lenguas distintas. Indica si el límite es el mismo o distinto entre ambas, y qué implica eso sobre la variabilidad de cada lengua.

Correlación entre dos variables numéricas

```
cor(fijadas$long_palabra, fijadas$dur, method = "pearson")
```

```
cor.test(fijadas$long_palabra, fijadas$dur, method = "pearson")
```

`cor()` devuelve solo el coeficiente. `cor.test()` añade un intervalo de confianza y un valor p que evalúa si la correlación observada es distinguible de cero.

```
cor.test(fijadas$long_palabra, fijadas$dur, method = "spearman")
```

Con un conjunto de datos de este tamaño, casi cualquier correlación distinta de cero resulta significativa. El valor p informa sobre la existencia de asociación, no sobre su magnitud.

Qué es un test de hipótesis

Un procedimiento para decidir, con una regla fijada de antemano, si los datos observados son incompatibles con una afirmación sobre un parámetro de la población.

Se compone de 5 elementos:

Elemento	Concepto
H_0	Afirmación de partida: no hay efecto
H_1	Lo que se sostiene si H0 se rechaza
Estadístico	Un número que resume la discrepancia entre datos y H0
Valor **p**	Probabilidad de un resultado tan extremo o más, **si** H_0 **fuera cierta**
Decisión	Comparar p con un umbral α fijado antes de ver los datos

El ejemplo: comparar dos lenguas

¿Difiere la duración media de lectura entre dos lenguas del corpus?

- H_0**:** la duración media es igual en ambas lenguas
- H_1**:** las medias difieren
- **Estadístico:** t, la diferencia de medias en unidades de error estándar

```
t.test(dur ~ lang, data = subset(fijadas, lang %in% c("es", "fi")))
```

El umbral α, habitualmente 0.05, queda fijado **antes** de ejecutar esta línea.

Dos precisiones sobre la decisión

El test nunca acepta H_0. Puede rechazarla o no rechazarla. ***No rechazar*** H0 no prueba que sea verdadera.

Rechazar H_0 no mide el tamaño del efecto. La decisión es binaria.

Del test al valor p

El test reduce todos los datos al estadístico de prueba.

1. Se calcula el estadístico observado. En este caso t.
2. Bajo H_0, ese estadístico tiene una distribución conocida, centrada en cero
3. El valor p es la proporción de esa distribución tan extrema o más que el t observado
4. La decisión compara ese valor p con el umbral α

Leer la salida del test

Cada componente de la salida corresponde a un paso del procedimiento:

```
res <- t.test(dur ~ lang, data = subset(fijadas, lang %in% c("es", "fi")))

res$statistic   # el t observado: la discrepancia resumida
res$parameter   # grados de libertad: fijan la forma de la distribucion bajo
res$p.value     # proporcion de esa distribucion mas extrema que el t obser
```

La misma distribución, dos caminos

La permutación de la sección anterior y la fórmula de `t.test()` calculan lo mismo:

- El histograma de `r_perm` **es** la distribución del estadístico bajo H_0, construida mezclando los datos
- La fórmula de `t.test()` aporta esa misma distribución por vía teórica, sin simular

Cuando los supuestos de la fórmula se cumplen, ambos caminos convergen al mismo valor p.

Qué es el valor p

Principio fundamental: Nunca se prueba H_1 de forma directa, sino que se evalúa cuán incompatibles son los datos con H_0.

El valor p cuantifica esa incompatibilidad:

Probabilidad de observar un resultado tan extremo, o más extremo, que el obtenido, **si H_0 fuera cierta**.

Afirmación incorrecta	Por qué
Es la probabilidad de que H0 sea verdadera	Se calcula asumiendo que H0 es verdadera
Es la probabilidad de que el resultado se deba al azar	No describe el origen del dato observado
Un valor pequeño indica un efecto grande	Depende también del tamaño de la muestra
Garantiza que un nuevo estudio replicará el resultado	Resume una sola muestra, no predice otras

Asociación entre dos variables categóricas

Para variables categóricas se usa una tabla de contingencia y una prueba de independencia.

```
tabla <- table(meco$skip, meco$long_grupo)
tabla

chisq.test(tabla)
```

La prueba evalúa si la distribución de una variable depende de las categorías de la otra.

```
resultado <- chisq.test(tabla)
resultado$expected     # frecuencias esperadas bajo independencia
resultado$statistic     # estadístico chi-cuadrado
```

Actividades del bloque 5

5.1 Calcula la correlación de Pearson y de Spearman entre `nfix` y `dur` sobre `fijadas`. Indica si ambos coeficientes son similares o difieren de forma apreciable.

5.2 Ejecuta `cor.test()` entre `long_palabra` y `dur`. Reporta el coeficiente, el intervalo de confianza y el valor p en una sola frase.

5.3 Construye la tabla de contingencia entre `meco$skip` y `meco$lang`. Ejecuta `chisq.test()` sobre esa tabla y reporta el estadístico y el valor p.

5.4 A partir del resultado de la actividad 5.3, extrae las frecuencias esperadas con `resultado$expected` y compáralas con la tabla observada para dos lenguas cualesquiera. Señala en qué lengua la diferencia entre lo observado y lo esperado es mayor.

Qué deberías poder hacer

- Calcular media, mediana y moda, y decidir cuál reportar según la forma de la distribución
- Calcular rango, rango intercuartílico, varianza, desviación estándar y coeficiente de variación
- Obtener percentiles y usarlos para definir umbrales
- Identificar valores atípicos con el criterio de 1,5 veces el rango intercuartílico
- Calcular e interpretar correlaciones y pruebas de independencia

Referencias

- Gries, S. Th. (2021). ***Statistics for Linguistics with R*** (3.ª ed.). Mouton de Gruyter.
- Baayen, R. H. (2008). ***Analyzing Linguistic Data***. Cambridge University Press.
- Tukey, J. W. (1977). ***Exploratory Data Analysis***. Addison-Wesley.
- Datos: https://osf.io/3527a