Clasificador Naive-Bayes

EST852 – Machine Learning

Juan Zamora O.

Octubre, 2024.

INSTITUTO DE ESTADÍSTICA IES PUCV

PONTIFICIA UNIVERSIDAD CATÓLICA DE VALPARAÍSO

Estructura de la Presentación

1. Introducción
2. Teorema de Bayes

Introducción

- Los métodos bayesianos combinan conocimiento previo (probabilidades apriori) con datos observados
- Posibilitan la creación de algoritmos de aprendizaje:
  - Aprendizaje bayesiano ingenuo
  - Aprendizaje de redes bayesianas (belief networks)
- Proveen de un marco conceptual muy útil

Teorema de Bayes

$$P(h|D) = \frac{P(D|h)P(h)}{P(D)}$$

- $P(h)$: probabilidad apriori de hipotesis h
- $P(D)$: probabilidad apriori de datos de entrenamiento D
- $P(h|D)$: probabilidad de que se cumpla h cuando se observa D
- $P(D|h)$: probabilidad de observar D cuando se cumple h

Elección de una hipotesis

$$P(h|D) = \frac{P(D|h)P(h)}{P(D)}$$

En general, se desea encontrar la hipotesis más probable luego de observar los datos de entrenamiento.

- Hipotesis máxima a posteriori (h_{MAP}):

$$h_{MAP} = \underset{h \in H}{\texttt{argmax}} P(h|D)$$

Hipotesis máxima a posteriori

$$h_{MAP} = \underset{h \in H}{\texttt{argmax}} P(h|D)$$

$$= \underset{h \in H}{\texttt{argmax}} \frac{P(D|h)P(h)}{P(D)}$$

$$= \underset{h \in H}{\texttt{argmax}} P(D|h)P(h)$$

- *Nota*: Si se asume que $P(h_i) = P(h_j), \forall h_i, h_j \in H$, entonces

$$h_{ML} = \underset{h_i \in H}{\texttt{argmax}} P(D|h_i)$$

Ejemplo

Un paciente se somete un examen de cáncer y el resultado es positivo. Este test entrega positivo de manera correcta en solo el 98% de los casos en la enfermedad está realmente presente, y un negativo correcto en solo el 97% de los casos en que la enfermedad **no** está presente. Adicionalmente, el 0.8% de toda la población tiene esta enfermedad.

$$
\begin{array}{ll}
P(\text{cancer}) = & P(\neg\text{cancer}) = \\
P(\oplus|\text{cancer}) = & P(\ominus|\text{cancer}) = \\
P(\oplus|\neg\text{cancer}) = & P(\ominus|\neg\text{cancer}) =
\end{array}
$$

Ejemplo

Un paciente se somete un examen de cáncer y el resultado es positivo. Este test entrega positivo de manera correcta en solo el 98% de los casos en la enfermedad está realmente presente, y un negativo correcto en solo el 97% de los casos en que la enfermedad **no** está presente. Adicionalmente, el 0.8% de toda la población tiene esta enfermedad.

$$
\begin{array}{cc}
P(\text{cancer}) = .008 & P(\neg\text{cancer}) = .992 \\
P(\oplus|\text{cancer}) = .98 & P(\ominus|\text{cancer}) = .02 \\
P(\oplus|\neg\text{cancer}) = .03 & P(\ominus|\neg\text{cancer}) = .97
\end{array}
$$

Suponga que se observa un nuevo paciente para quien el test indicó un resultado positivo. ¿Deberíamos diagnosticar al paciente como con cancer o no?

Para responder debemos encontrar la hipotesis máxima aposteriori, es decir:

$$P(\text{cancer}|\oplus)$$

$$P(\neg\text{cancer}|\oplus)$$

$$P(\text{cancer}|\oplus) = \frac{P(\oplus|\text{cancer})P(\text{cancer})}{P(\oplus)}$$
$$P(\neg\text{cancer}|\oplus) = \frac{P(\oplus|\neg\text{cancer})P(\neg\text{cancer})}{P(\oplus)}$$

Podemos ignorar $P(\oplus)$, ya que no afectará la conclusión. Entonces,

$$P(\text{cancer}|\oplus) \simeq P(\oplus|\text{cancer})P(\text{cancer})$$
$$P(\neg\text{cancer}|\oplus) \simeq P(\oplus|\neg\text{cancer})P(\neg\text{cancer})$$

Usando las cantidades calculadas anteriormente:

$$P(\oplus|\text{cancer})P(\text{cancer}) = (0.98)0.008 = 0.0078$$

$$P(\oplus|\neg\text{cancer})P(\neg\text{cancer}) = (0.03)0.992 = 0.0298$$

Aún cuando es posible calcular $P(\oplus)$ para un cálculo exacto, los valores anteriores nos indican que es muy poco probable (aún con un positivo) tener la enfermedad.

Por lo tanto, $h_{MAP} = \neg\text{cancer}$.

Clasificación de una nueva instancia

- Nos hemos enfocado en la **hipotesis más probable**, dados los datos de entrenamiento (h_{MAP})
- Dada una nueva instancia x, ¿cual es la **clasificación más probable**?

La clasificación más probable se obtiene combinando todas las hipotesis, ponderadas por sus probabilidades a posteriori.

Clasificador Bayesiano Óptimo

$$\underset{v_j \in V}{\texttt{argmax}} \sum_{h_i \in H} P(v_j|h_i)P(h_i|D)$$

- v_j son las posibles clases en que puede ser etiquetada la instancia
- Las hipotesis son funciones, en nuestro caso, de clasificación (e.g. hiperplanos).

Ejemplo

$$
\begin{array}{lll}
P(h_1|D) = 0.4, & P(\ominus|h_1) = 0, & P(\oplus|h_1) = 1 \\
P(h_2|D) = 0.3, & P(\ominus|h_2) = 1, & P(\oplus|h_2) = 0 \\
P(h_3|D) = 0.3, & P(\ominus|h_3) = 1, & P(\oplus|h_3) = 0
\end{array}
$$

Entonces

$$\sum_{h_i \in H} P(\oplus|h_i)P(h_i|D) = 0.4$$

$$\sum_{h_i \in H} P(\ominus|h_i)P(h_i|D) = 0.6$$

$$\underset{v_j \in V}{\texttt{argmax}} \sum_{h_i \in H} P(v_j|h_i)P(h_i|D) = \ominus$$

mientras que la h_{MAP} indicaría que la instancia es etiquetada como $\oplus$

Clasificador Bayesiano Ingenuo

Cuando usar:

- Tamaños de datasets medianos o grandes
- Atributos que describen a cada instancia son condicionalmente independientes dada la etiqueta o clasificación

Aplicaciones exitosas:

- Diagnostico de enfermedades
- Clasificación de textos (SPAM)

- Función de respuesta es $f : X \to V$
- Cada instancia x es descrita por atributos $\{a_1, a_2, \dots, a_n\}$
- Valor más probable de $f(x)$ es:

$$v_{MAP} = \underset{v_j \in V}{\texttt{argmax}} P(v_j | a_1, a_2, \dots, a_n)$$

$$= \underset{v_j \in V}{\texttt{argmax}} \frac{P(a_1, a_2, \dots, a_n | v_j) P(v_j)}{P(a_1, a_2, \dots, a_n)}$$

$$= \underset{v_j \in V}{\texttt{argmax}} P(a_1, a_2, \dots, a_n | v_j) P(v_j)$$

Supuesto de Bayes Ingenuo

$$P(a_1, a_2, \ldots, a_n) = \Pi_i P(a_i|v_j)$$

Lo que lleva al clasificador bayesiano ingenuo

$$v_{NB} = \underset{v_j \in V}{\texttt{argmax}} P(v_j) \Pi_i P(a_i|v_j)$$

- Cada $P(a_i|v_j)$ puede tener una distribución de probabilidad específica.
- Generalmente se utilizan la Normal, Bernoulli y Multinomial.