EST-733 2022-II

Machine Learning

Juan Zamora O.

Agosto 2022





PONTIFICIA
UNIVERSIDAD
CATÓLICA DE
VALPARAÍSO

Introducción

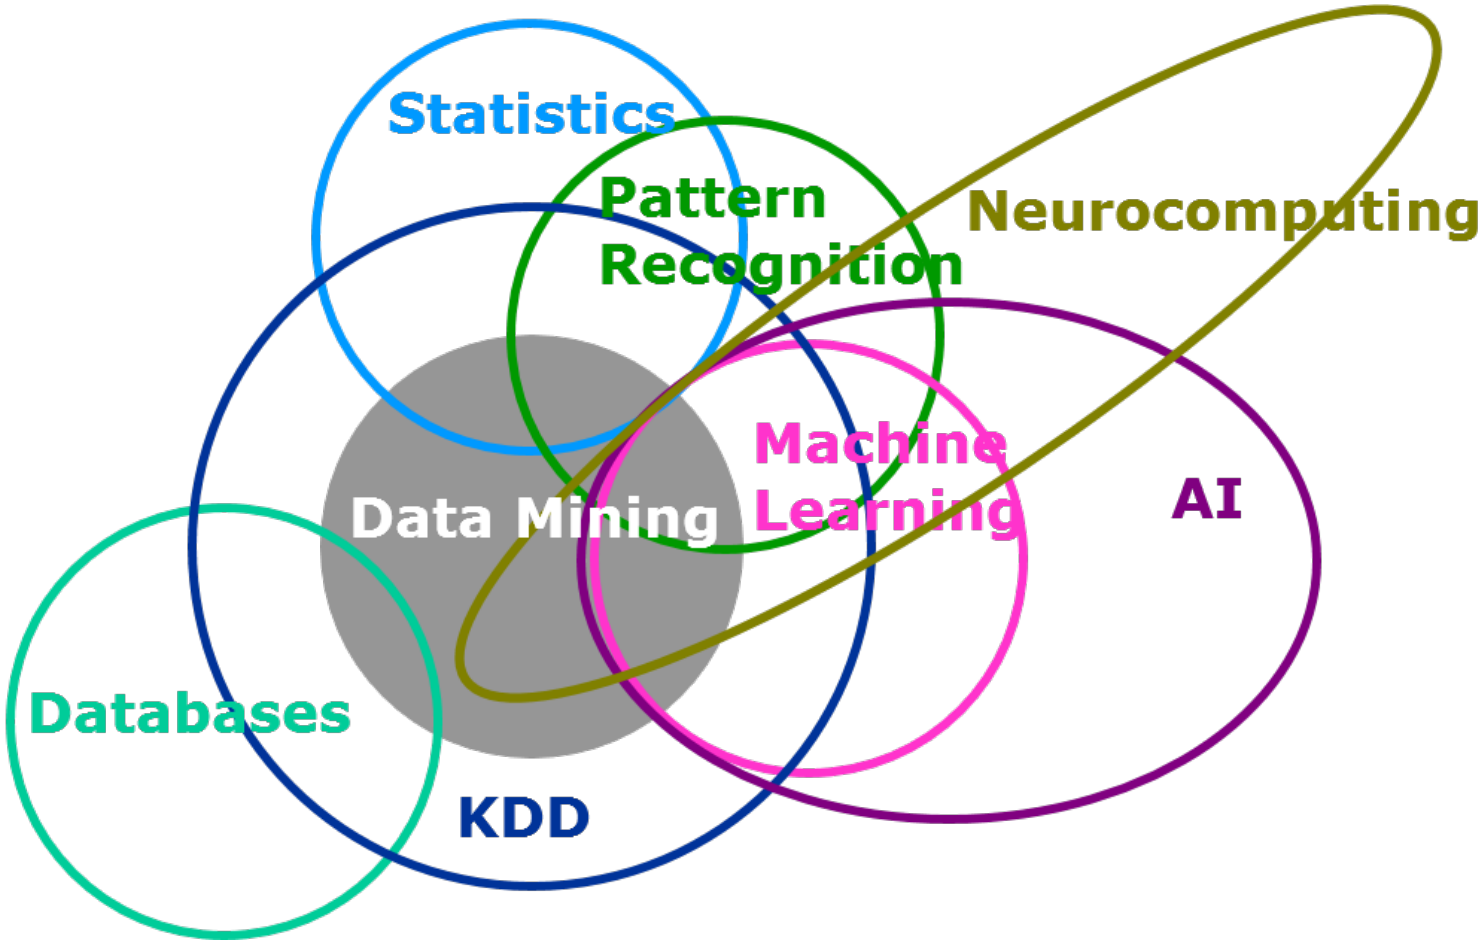
INSTITUTO DE ESTADÍSTICA
IES PUCV

Introducción

- Subconjunto de la IA que incluye técnicas estadísticas que permiten que los algoritmos computacionales (máquinas) mejoren en su desempeño deuna tarea a medida que ganan experiencia ejecutandola.
- Algoritmos usados para segmentar los datos y predecir la verosimilitud de eventos futuros basandose en eventos pasados
- Programas pueden realizar tareas sin un conjunto de instrucciones programadas explicitamente para hacerlo

Statistical Learning vs Machine Learning

- No hay una definición clara
- Diferencia puede venir
  - del origen de los métodos
  - del volúmen y dimensionalidad de los datos usados
- Durante el desarrollo de este curso **no** haremos distinción alguna entre ellas



Fuente wikipedia.org

INSTITUTO DE ESTADÍSTICA
IES PUCV

Tipos de Aprendizaje

En general se divide en tres grandes categorias: 1. Predictivo o **Supervisado** 2. No Supervisado 3. Reforzado

1. Predictivo o **Supervisado**

- Observaciones (datos) representados por vectores **x** junto a las respuestas/salidas **y** generadas por el Sistema.
- Cada x_i es un vector M dimensional y representa la colección de M atributos medidos o covariables.
- Las respuestas y_i pueden ser nominal/categórica o real
- El objetivo es aprender la asociación entre las covariables y la salida usando los datos $(x_i, y_i)_{i=1}^{N}$

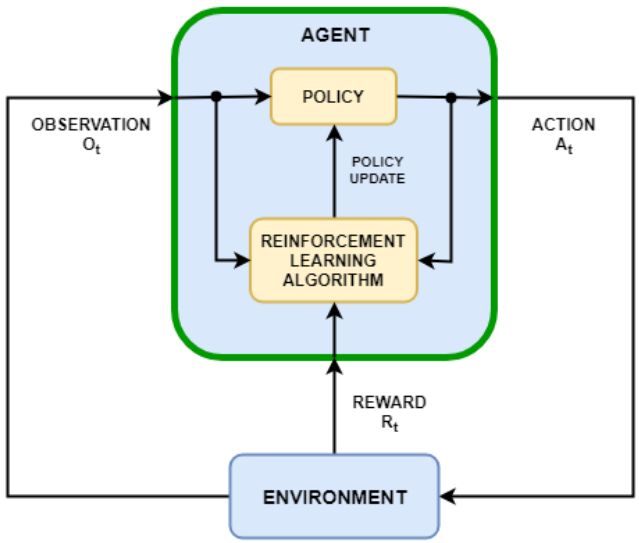
INSTITUTO DE ESTADÍSTICA
IES PUCV

2. Descriptivo o **No-Supervisado**

- Observaciones (datos) representados por vectores **x**
- Cada x_i es un vector M dimensional y representa la colección de M atributos medidos o covariables.
- El objetivo es encontrar patrones que puedan ser útiles o interesantes

INSTITUTO DE ESTADÍSTICA IES PUCV

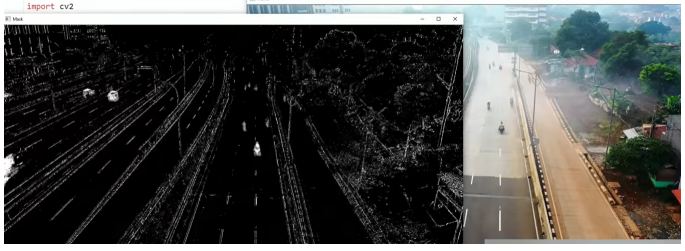
3. Reforzado
   - Consiste en aprender a actuar o comportarse usando mecanismos de recompensa y castigo

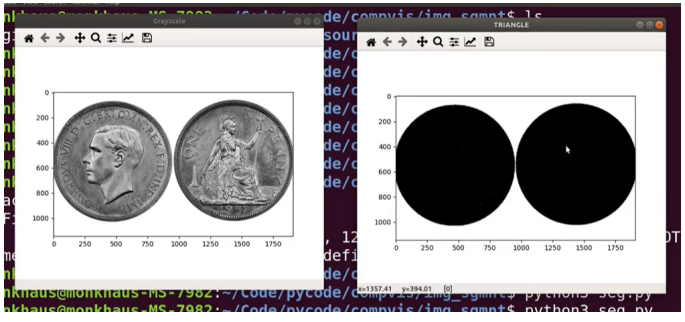


Fuente mathworks.com

INSTITUTO DE ESTADÍSTICA
IES PUCV

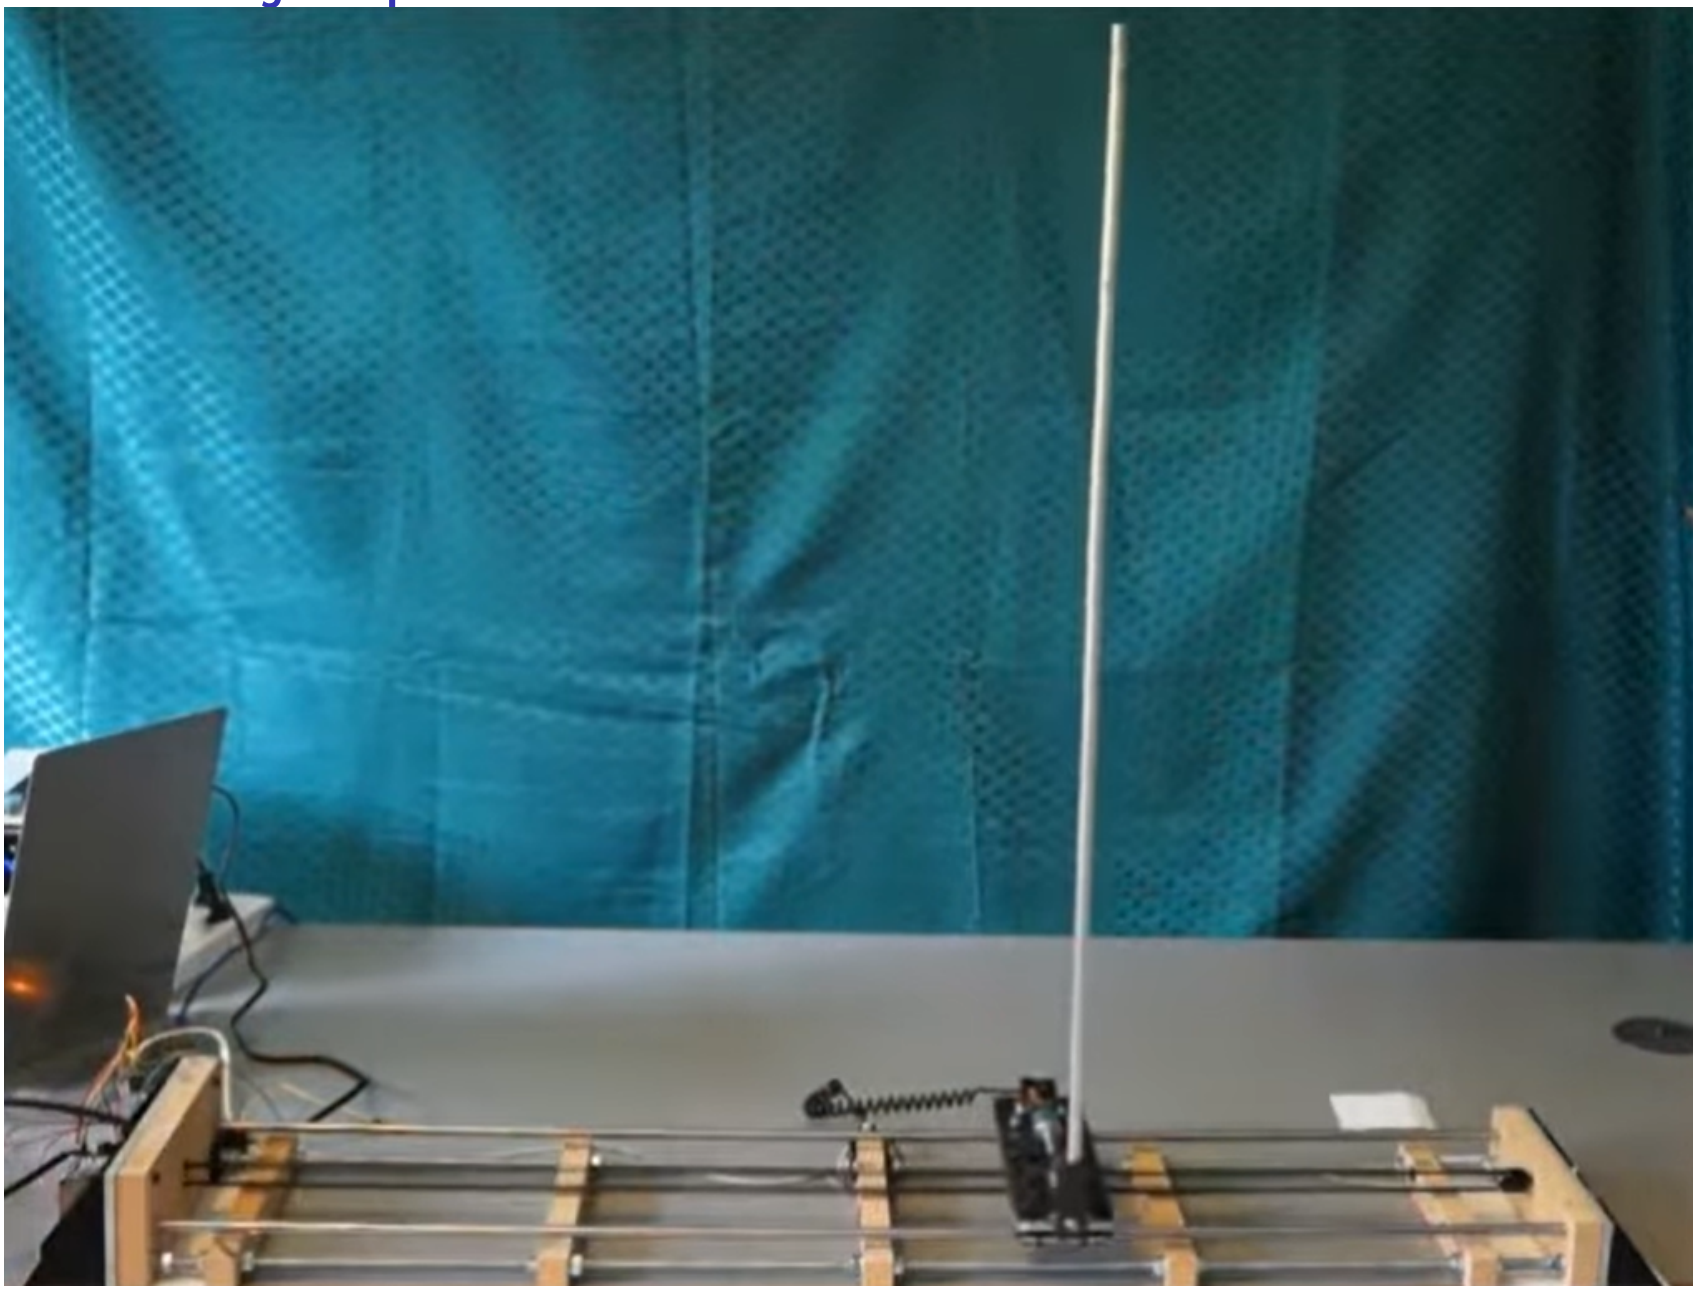
Videos de ejemplo





https://youtu.be/W-oVad7x-HQ?t=1078

Videos de ejemplo



Contexto del Curso

Dentro del curso nos enfocaremos en el primero de los aprendizajes, es decir el aprendizaje supervisado.

El problema del Aprendizaje Supervisado

INSTITUTO DE ESTADÍSTICA
IES PUCV

El problema del Aprendizaje Supervisado

- Dada una serie de observaciones X e y, se desea encontrar la función f que relacione a X con la respuesta y
- Esta función f es desconocida e imposible de encontrar . . . no tenemos *todos* los datos
- **Enfoque práctico**: Aproximarla mediante otra función g
- Este proceso de intentar alcanzar la mejor aproximación de f se denomina **aprendizaje**

INSTITUTO DE ESTADÍSTICA
IES PUCV

Proceso de aprendizaje

- El aprendizaje opera mediante ejemplos a través de un profesor
- El Sistema bajo estudio es observado en término de *entradas* y *salidas* $(\mathbf{x}_i, y_i)$
- Los valores de entrada al sistema x_i son ingresadas a una versión artificial del Sistema que produce salidas $\hat{f}(\mathbf{x}_i)$ en respuesta

INSTITUTO DE ESTADÍSTICA IES PUCV

- Este sistema artificial puede modificar la asociación $\hat{f}$ entre la **entrada** y la **salida** en respuesta a las diferencias $y_i - \hat{f}(\mathbf{x}_i)$
- Este proceso de aprendizaje converge hacia una salida del sistema artificial *suficientemente cercana* (útil) para todas las posibles entradas que probablemente se encontraran en la practica

INSTITUTO DE ESTADÍSTICA IES PUCV

Ejemplos de aproximaciones

- Modelo lineal: $\hat{f}(\mathbf{x}) = g_\beta(\mathbf{x}) = \mathbf{x}^T\beta$
- Modelo con expansión de bases lineales: $\hat{f}(\mathbf{x}) = g_\theta(\mathbf{x}) = \sum_{k=1}^{K} h_k(\mathbf{x})\theta_k$
  - donde $h_k(\mathbf{x})$ puede ser expansiones polinomiales como $\{x_1^2, x_1x_2^2\}$ o trigonométricas $\{cos(x_1), x2\}$ si consideramos solo dos atributos por observación

Para el primer caso, es posible usar mínimos cuadrados para estimar los parámetros β minimizando la suma residual de cuadrados:

$$RSS(\beta) = \sum_{i=1}^{N}(y_i - f_\beta(\mathbf{x}_i))^2$$

INSTITUTO DE ESTADÍSTICA IES PUCV

Medición de la calidad del Modelo

- El desempeño de un modelo ya entrenado se mide sobre un conjunto de datos no visto en la etapa de ajuste
- Este conjunto tiene observaciones representadas con los mismos atributos usados en la etapa de construcción del Modelo
- Se cuantifica mediante la calidad de la aproximación de las predicciones
  - E.g. Accuracy para clasificación
  - E.g. MSE para la tarea de regresión

INSTITUTO DE ESTADÍSTICA IES PUCV

Algunos ejemplos

- Predecir si un paciente hospitalizado por un accidente cardiaco, tendrá otra ataque.
- Identificar el borde de una imagen
- Identificar si un mensaje de correo es SPAM o no
- Identificar si un relato fue generado por una persona con ún trastorno mental

El subproblema de Clasificación

- Si todos los $y_i \in \{1, ..., C\}$ donde C es el número de categorías de objetos
- Cuando $C = 2$ el problema se denomina de clasificación binaria
- Valores $C > 2$ determinan el problema como de clasificación multiclase
- Independiente de qué caso tratemos, el **objetivo** es realizar predicciones sobre **nuevas** observaciones de las cuales no tenemos la respuesta del Sistema

INSTITUTO DE ESTADÍSTICA IES PUCV