EST-852

Evaluación y selección de modelos

Juan Zamora O.

Machine Learning





Introducción

- La calidad de un método se mide por su capacidad de generalización
- Esta capacidad se relaciona con su poder predictivo sobre datos de prueba independientes
- Es muy importante poder evaluar este desempeño
  - Guía la elección del ***método de aprendizaje***/modelo
  - Entrega medida de la calidad esperada del modelo escogido

Sesgo y Varianza

Escenario general

Se tiene una variable objetivo $Y \in \mathbb{R}$, un vector de entradas X y un modelo de predicción $\hat{f}(X)$ estimada a partir de un conjunto de entrenamiento $\mathcal{T}$.

La función que permite cuantificar el error en las predicciones se denomina **función de pérdida** y se denota mediante $L(Y, \hat{f}(X))$

- Algunas elecciones para esta función de pérdida son

$$L(Y, \hat{f}(X)) = \begin{cases} (Y - \hat{f}(X))^2 & \text{, error cuadrático} \\ |Y - \hat{f}(X)| & \text{, error absoluto} \end{cases}$$

- Para respuestas categóricas G con K valores, generalmente se modelan las probabilidades $p_k(X) = Pr(G = k|X)$ y se escoge $\hat{G}(X) = \underset{k}{\text{argmax}}\hat{p}_k$

$$L(G, \hat{G}(X)) = I(G \neq \hat{G}(X))^2 \quad \text{, pérdida 0-1}$$
$$L(G, \hat{p}(X)) = -2\sum_{k=1}^{K} log\, \hat{p}_k(X) \quad \text{, ***deviance***}$$

Error de predicción

- El error de generalización o **error de prueba** corresponde al error de predicción sobre una muestra de prueba independiente específica $\mathcal{T}$

$$Err_{\mathcal{T}} = E[L(Y, \hat{f}(X))|\mathcal{T}]$$

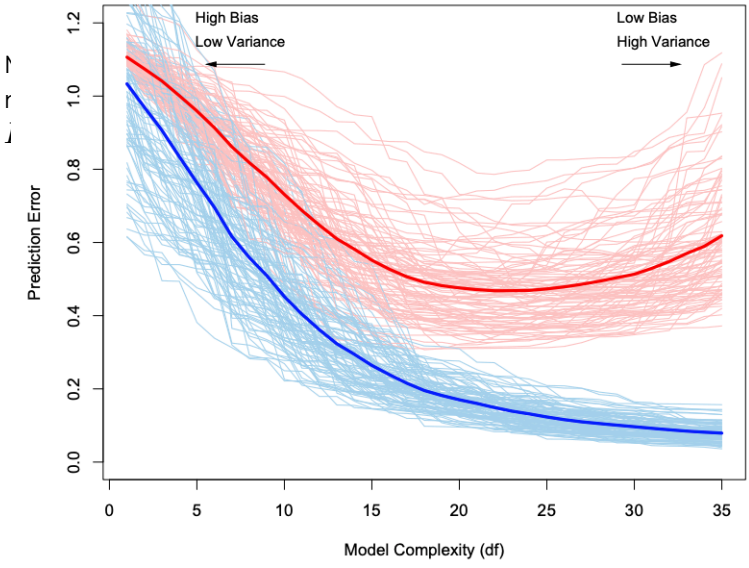
  - Cada par (X, Y) es escogido al azar a partir de su distribución conjunta

- Otra cantidad relacionada es el error de predicción esperado

$$Err = E[Err_{\mathcal{T}}] = E[L(Y, \hat{f}(X))]$$

  - En este caso la esperanza se calcula sobre todo lo aleatorio, incluyendo la aleatoriedad en el conjunto de entrenamiento $\mathcal{T}$ que produjo $\hat{f}$.

- A continuación, se muestra ejemplo de modelo ajustado sobre 100 conjuntos de entrenamiento distintos ($Err_{\mathcal{T}}$ en rojo claro)



Fuente fuente ***Hastie et al., 2017***

Error de entrenamiento

- Se define como la pérdida promedio sobre la muestra de entrenamiento

$$\overline{err} = \frac{1}{|\mathcal{T}|} \sum_{i=1}^{|\mathcal{T}|} L(y_i, \hat{f}(x_i))$$

o también

$$\overline{err} = -\frac{2}{|\mathcal{T}|} \sum_{i=1}^{|\mathcal{T}|} log\, \hat{p}_{g_i}(x_i)$$

- En la figura anterior, el error de entrenamiento aparece en azul.
- Este error es un **estimador optimista** del error de predicción

Error vs complejidad del modelo

- A medida que el modelo aumenta su complejidad se adapta de manera más cercana a los datos de entrenamiento
- Es decir, se produce una disminución del error de entrenamiento
- La complejidad está asociada a algún parámetro del modelo
- Se produce una disminución en el sesgo y un aumento en la varianza del error de predicción

¿Para qué todo esto?

Perseguiremos dos tareas/objetivos

- **Selección del modelo**
  - Estimar el desempeño de diferentes modelos para escoger el mejor
- **Evaluación del Modelo**
  - Luego de escoger el mejor modelo, estimar su error de predicción sobre nuevos datos

Escenario con abundancia de datos

- Ambos problemas pueden ser abordados dividiendo los datos en 3 grupos

Entrenamiento	**Validación**	**Prueba**
—	—	—
Para ajustar los modelos	Estimar error de pred. en la selección de modelos	Evaluación del error de generalización para el modelo escogido

- Muchos/Pocos datos depende de la complejidad del modelo, razón señal a ruido de función generadora de los datos ...

Escenario con insuficiencia de datos

- Métodos analíticos: AIC, BIC, MDL
  - Útiles para clases de estimadores lineales en sus parámetros
  - Usados para comparar entre modelos en lugar de estimar capacidad de generalización
- Remuestreo: CV o Bootstrap
  - Útilidad para cualquier estimador del error de predicción

Validación Cruzada

- Mecanismo más simple y usado para estimar el error de predicción
- Usaremos parte de los datos disponibles para ajustar el modelo y otra parte distinta para probarlo (varias veces)

K-Fold cv

- Datos se dividen en K grupos de igual tamaño
- E.g. $K = 5$

Valid	Train	Train	Train	Train
Train	Valid	Train	Train	Train
Train	Train	Valid	Train	Train
Train	Train	Train	Valid	Train
Train	Train	Train	Train	Valid

- Se ajusta el modelo con $K - 1$ partes y se calcula el error de predicción sobre la restante

- Se obtienen K estimaciones del error de predicción
- Cada observación i es mapeada a una partición mediante la función $\kappa : \{1 \dots N\} \longrightarrow \{1 \dots K\}$
- Además, anotemos como $\hat{f}^{-k}(x)$ a la función ajustada calculada sin la k-ésima parte del conjunto de datos
- Luego, el estimador CV del error de predicción es

$$CV(\hat{f}) = \frac{1}{N} \sum_{i=1}^{N} L(y_i, \hat{f}^{-\kappa(i)}(x_i))$$

Selección de Modelo usando k-fold cv

Si consideramos un conjunto de modelos indexados sobre el parámetro α, anotaremos $\hat{f}_{\alpha}^{-k}(x)$ al α-ésimo modelo ajustado sin la k-ésima parte del conjunto de datos

La siguiente función entregará estimador de su error de predicción

$$CV(\hat{f}_{\alpha}) = \frac{1}{N}\sum_{i=1}^{N} L(y_i, \hat{f}_{\alpha}^{-\kappa(i)}(x_i))$$

Finalmente, el valor $\hat{\alpha}$ que la minimiza nos permitirá seleccionar nuestro modelo.

Consideraciones generales

- Valor de k generalmente está entre 5 y 10
- Algunos métodos pueden ser muy sensibles al tamaño del conjunto de entrenamiento, especialmente cuando hay pocos datos (< 100)
- Usar información de la respuesta Y antes de aplicar k-fold cv sobre los mismos datos es trampa
  - Se obtendrá una estimación optimista del error
  - Por ejemplo, seleccionar variables usando Información Mutua sobre todos los datos antes de aplicar CV.

Actividad

1. Averigüe acerca del uso de la Información mutua para selección de variables
2. Busque en `Scikit-learn` cómo realizar este cálculo respecto de la variable objetivo (***target***)
3. Escoja un conjunto de datos para la tarea de clasificación
4. ***Rankee*** las co-variables según Información mutua
5. Escoja las top-P
6. Escoja un modelo de clasificación (e.g. Naive Bayes) y fije los valores de sus parámetros
7. Realice k-fold CV usando únicamente los predictores seleccionados
8. Reporte $CV(\hat{f}_\alpha)$
9. Repita 5-8 para 3 valores distintos de P