EST-852

Métodos de Kernel y SVM

Juan Zamora O.

Machine Learning





PONTIFICIA
UNIVERSIDAD
CATÓLICA DE
VALPARAÍSO

Planteamiento del problema

Se dispone de m observaciones etiquetadas

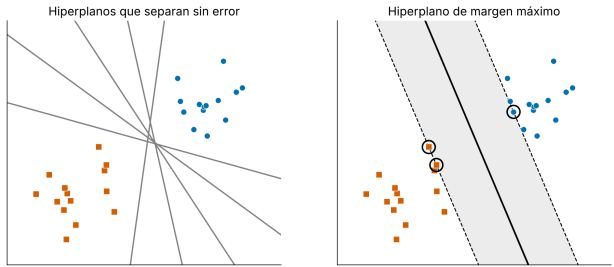
$$(\mathbf{x}_1, y_1), \dots, (\mathbf{x}_m, y_m) \in \mathcal{X} \times \{\pm 1\}.$$

El aprendizaje consiste en **generalizar** a objetos no vistos: dado un nuevo $\mathbf{x} \in \mathcal{X}$, predecir su etiqueta $y \in \{\pm 1\}$.

- En esta sesión se escoge y de modo que el par $(\mathbf{x}, y)$ sea ***similar*** a los ejemplos de entrenamiento.
- Por lo tanto, se necesita una **medida de similitud** en $\mathcal{X}$. No cualquier función sirve: debe cumplir ciertas propiedades (sección de kernels).

Notación: m = número de observaciones; d = dimensión, con $\mathcal{X} \subset \mathbb{R}^d$.

Muchos hiperplanos separan los datos



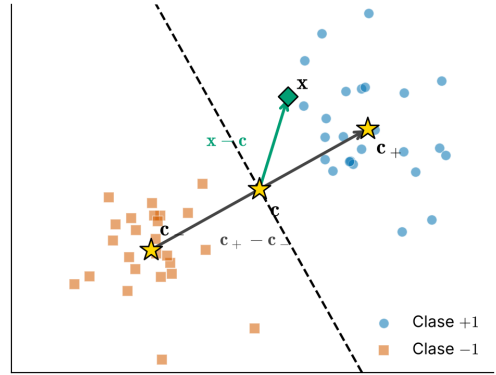
- Si las clases son linealmente separables, existen infinitos hiperplanos con error de entrenamiento nulo.
- ¿Cuál elegir? El que maximiza el **margen**: la distancia mínima a los puntos de entrenamiento.
- Justificación: robustez ante pequeñas perturbaciones de los datos y una cota de generalización basada en los vectores soporte (se verá más adelante).

Clasificador de centroides

Sea $\mathcal{X} \subset \mathbb{R}^d$ y supongamos que ambas clases tienen observaciones ($m_+, m_- > 0$).

$$\mathbf{c}_+ = \frac{1}{m_+} \sum_{i:\, y_i = +1} \mathbf{x}_i, \qquad \mathbf{c}_- = \frac{1}{m_-} \sum_{i:\, y_i = -1} \mathbf{x}_i, \qquad \mathbf{c} = \tfrac{1}{2}(\mathbf{c}_+ + \mathbf{c}_-)$$

- Regla: asignar el nuevo punto **x** a la clase cuyo centroide esté más cerca.
- No se requiere separabilidad lineal. Tampoco se garantiza error de entrenamiento nulo cuando las clases son separables.



Regla de decisión geométrica

Asignar **x** al centroide más cercano equivale a evaluar el signo de una proyección:

$$\|\mathbf{x} - \mathbf{c}_-\|^2 - \|\mathbf{x} - \mathbf{c}_+\|^2 \;=\; 2\,\langle \mathbf{x} - \mathbf{c}, \mathbf{c}_+ - \mathbf{c}_- \rangle$$

- El ángulo entre el vector $\mathbf{x} - \mathbf{c}$ (de $\mathbf{c}$ a $\mathbf{x}$) y $\mathbf{c}_+ - \mathbf{c}_-$ (que conecta los centros de ambas clases) es menor que $\pi/2$ si y solo si $\mathbf{x}$ está más cerca de $\mathbf{c}_+$.
- La regla se formula solo con el producto interno $\langle \cdot, \cdot \rangle$:

$$y = \text{sgn}\,\langle \mathbf{x} - \mathbf{c}, \mathbf{c}_+ - \mathbf{c}_- \rangle$$

Desarrollo de la regla

$$
\begin{aligned}
y &= \operatorname{sgn}\langle \mathbf{x} - \mathbf{c}, \mathbf{c}_+ - \mathbf{c}_- \rangle \\
&= \operatorname{sgn}\Big(\langle \mathbf{x}, \mathbf{c}_+ \rangle - \langle \mathbf{x}, \mathbf{c}_- \rangle - \tfrac{1}{2}(\|\mathbf{c}_+\|^2 - \|\mathbf{c}_-\|^2) \Big) \\
&= \operatorname{sgn}\Big(\langle \mathbf{x}, \mathbf{c}_+ \rangle - \langle \mathbf{x}, \mathbf{c}_- \rangle + b \Big), \qquad b = \tfrac{1}{2}(\|\mathbf{c}_-\|^2 - \|\mathbf{c}_+\|^2)
\end{aligned}
$$

Se usó que $\langle \mathbf{c}, \mathbf{c}_+ - \mathbf{c}_- \rangle = \frac{1}{2}(\|\mathbf{c}_+\|^2 - \|\mathbf{c}_-\|^2)$.

Forma en productos internos

Sustituyendo los centroides:

$$y = \text{sgn}\left(\frac{1}{m_+}\sum_{i:\, y_i=+1}\langle \mathbf{x}, \mathbf{x}_i\rangle - \frac{1}{m_-}\sum_{i:\, y_i=-1}\langle \mathbf{x}, \mathbf{x}_i\rangle + b\right)$$

y el término b también se expresa con productos internos:

$$b = \frac{1}{2}\left(\frac{1}{m_-^2}\sum_{\substack{(i,j):\\ y_i=y_j=-1}}\langle \mathbf{x}_i, \mathbf{x}_j\rangle - \frac{1}{m_+^2}\sum_{\substack{(i,j):\\ y_i=y_j=+1}}\langle \mathbf{x}_i, \mathbf{x}_j\rangle\right)$$

De $\langle \mathbf{x}, \mathbf{x}_i \rangle$ a $k(\mathbf{x}, \mathbf{x}_i)$

Observación clave: los datos intervienen solo a través de productos internos. Si se reemplazan por una función de similitud k:

$$y = \text{sgn}\left(\frac{1}{m_+} \sum_{i:\, y_i = +1} k(\mathbf{x}, \mathbf{x}_i) - \frac{1}{m_-} \sum_{i:\, y_i = -1} k(\mathbf{x}, \mathbf{x}_i) + b \right)$$

- El mismo algoritmo opera ahora con la noción de similitud k.
- Con un kernel gaussiano, las sumas son (salvo una constante) estimadores de densidad de ventana de Parzen de cada clase.
- Pregunta: ¿qué funciones k son admisibles y qué espacio inducen? (siguiente sección)

Limitaciones del producto interno en el espacio de entrada

- Las clases pueden no ser linealmente separables.
- $\mathcal{X}$ no siempre es un espacio con producto interno (grafos, cadenas de caracteres, etc.).

Solución: representar los objetos en un espacio $\mathcal{H}$ con producto interno (***espacio de características***) mediante el mapeo

$$\Phi : \mathcal{X} \to \mathcal{H}, \qquad x \mapsto \mathbf{x} := \Phi(x)$$

y medir la similitud con

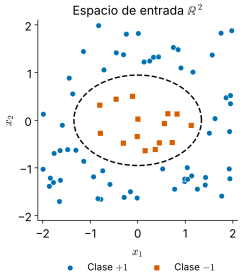
$$k(x, x') := \langle \Phi(x), \Phi(x') \rangle$$

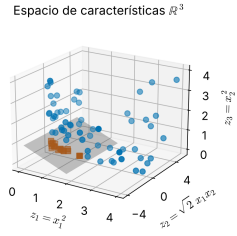
Beneficios de incrustar los datos en $\mathcal{H}$

1. Asegura que la medida de similitud proviene de un producto interno: $k(x, x') = \langle \Phi(x), \Phi(x') \rangle$.
2. Permite abordar la clasificación de manera geométrica (hiperplanos, ángulos, distancias).
3. Un mapeo Φ no lineal cambia la representación vectorial hacia una más adecuada para el problema.

Ejemplo: mapeo cuadrático

$$\Phi : \mathbb{R}^2 \to \mathbb{R}^3, \qquad (x_1, x_2) \mapsto (z_1, z_2, z_3) = (x_1^2, \sqrt{2}\, x_1 x_2, x_2^2)$$





Una frontera elíptica $ax_1^2 + bx_2^2 = c$ en el espacio de entrada se transforma en el hiperplano $az_1 + bz_3 = c$ en $\mathbb{R}^3$. Aprender la frontera se reduce a estimar un hiperplano con los puntos mapeados.

El truco del kernel

$$\langle \Phi(x), \Phi(x') \rangle = x_1^2 x_1'^2 + 2x_1 x_2 x_1' x_2' + x_2^2 x_2'^2 = (x_1 x_1' + x_2 x_2')^2 = \langle x, x' \rangle^2$$

- Se puede evaluar k sin calcular Φ explícitamente.
- Kernel polinomial homogéneo de grado p en $\mathbb{R}^d$: Φ tiene $\binom{d+p-1}{p}$ coordenadas. Con $d = 100$ y $p = 3$ son 171.700, mientras que evaluar k cuesta $O(d)$ operaciones.
- El kernel gaussiano corresponde a un espacio $\mathcal{H}$ de dimensión infinita.

Condición de semidefinición positiva (Mercer)

Una función $k : \mathcal{X} \times \mathcal{X} \to \mathbb{R}$ es un kernel válido si es

- **simétrica:** $k(x, x') = k(x', x)$, y
- **semidefinida positiva:** para todo $n \in \mathbb{N}$, $x_1, \dots, x_n \in \mathcal{X}$ y $a \in \mathbb{R}^n$,

$$\sum_{i=1}^{n} \sum_{j=1}^{n} a_i a_j \, k(x_i, x_j) \geq 0$$

(equivalentemente, la matriz de Gram $K_{ij} = k(x_i, x_j)$ es semidefinida positiva).

Entonces existe $\Phi : \mathcal{X} \to \mathcal{H}$ tal que $k(x, x') = \langle \Phi(x), \Phi(x') \rangle$.

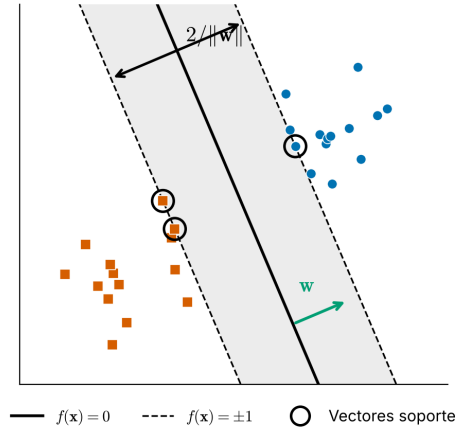
Kernels usuales

Kernel	$k(x, x')$	Parámetros
Lineal	$\langle x, x' \rangle$	—
Polinomial	$(\langle x, x' \rangle + 1)^p$	grado p
Gaussiano (RBF)	$\exp(-\|x - x'\|^2 / 2\sigma^2) = \exp(-\gamma \|x - x'\|^2)$	$\gamma = 1/2\sigma^2$

- Con γ grande (σ pequeño) la similitud es muy local.
- Sumas y productos de kernels (con coeficientes positivos) son kernels.
- Existen kernels para objetos estructurados (cadenas de caracteres, grafos, etc.): miden similitud mediante productos internos en un espacio de características mejor dotado que el espacio original de atributos.

Hiperplano separador y margen

- Función de decisión: $f(\mathbf{x}) = \langle \mathbf{w}, \mathbf{x} \rangle + b$, con clasificador $y(\mathbf{x}) = \text{sgn}\, f(\mathbf{x})$.
- La distancia de **x** al hiperplano $f = 0$ es $|f(\mathbf{x})|/\|\mathbf{w}\|$.
- $(\mathbf{w}, b)$ está definido solo salvo escala positiva. **Forma canónica:** se escala de modo que $\min_i y_i f(\mathbf{x}_i) = 1$.
- Los hiperplanos $f = \pm 1$ pasan por los puntos más cercanos y distan entre sí $2/\|\mathbf{w}\|$ (el **margen**).



Problema primal

$$\min_{\mathbf{w},b} \frac{1}{2}\|\mathbf{w}\|^2 \qquad \text{sujeto a} \qquad y_i(\langle \mathbf{w}, \mathbf{x}_i \rangle + b) \geq 1, \quad i = 1, \dots, m$$

- Maximizar el margen $2/\|\mathbf{w}\|$ es equivalente a minimizar $\frac{1}{2}\|\mathbf{w}\|^2$ (mismo minimizador; los valores óptimos no coinciden).
- Es un programa cuadrático convexo con restricciones lineales: no hay mínimos locales.
- Si las clases son linealmente separables, existe solución global y es única.

Lagrangiano y condiciones KKT

$$L(\mathbf{w}, b, \alpha) = \tfrac{1}{2}\|\mathbf{w}\|^2 - \sum_{i=1}^{m} \alpha_i \Big(y_i(\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 \Big), \qquad \alpha_i \geq 0$$

- Se **minimiza** respecto a $(\mathbf{w}, b)$ y se **maximiza** respecto a $\alpha \geq 0$ (punto silla).
- Derivando: $\mathbf{w} = \sum_i \alpha_i y_i \mathbf{x}_i$ y $\sum_i \alpha_i y_i = 0$.
- Holgura complementaria: $\alpha_i \big[y_i(\langle \mathbf{w}, \mathbf{x}_i \rangle + b) - 1 \big] = 0$.
- Luego $\alpha_i > 0$ solo si $y_i f(\mathbf{x}_i) = 1$: el punto está sobre el margen. Esos puntos son los **vectores soporte**.

Problema dual

Sustituyendo $\mathbf{w} = \sum_i \alpha_i y_i \mathbf{x}_i$ y $\sum_i \alpha_i y_i = 0$ en L:

$$\max_{\alpha} \sum_{i=1}^{m} \alpha_i - \frac{1}{2} \sum_{i,j=1}^{m} \alpha_i \alpha_j y_i y_j \langle \mathbf{x}_i, \mathbf{x}_j \rangle \quad \text{s.a.} \quad \alpha_i \geq 0, \ \sum_i \alpha_i y_i = 0$$

Función de decisión:

$$f(\mathbf{x}) = \sum_{i=1}^{m} \alpha_i y_i \langle \mathbf{x}_i, \mathbf{x} \rangle + b, \qquad b = y_s - \sum_i \alpha_i y_i \langle \mathbf{x}_i, \mathbf{x}_s \rangle$$

donde $\mathbf{x}_s$ es cualquier vector soporte ($\alpha_s > 0$). Solo los vectores soporte contribuyen a la suma.

Del dual al truco del kernel

Los datos aparecen únicamente a través de $\langle \mathbf{x}_i, \mathbf{x}_j \rangle$. Reemplazándolos por $k(\mathbf{x}_i, \mathbf{x}_j)$:

$$\max_{\alpha} \sum_i \alpha_i - \tfrac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \, k(\mathbf{x}_i, \mathbf{x}_j), \qquad f(\mathbf{x}) = \sum_{i \in SV} \alpha_i y_i \, k(\mathbf{x}_i, \mathbf{x}) + b$$

- Así se combinan el clasificador de margen máximo y el cálculo implícito de Φ (Boser, Guyon y Vapnik, 1992).
- Nunca se calculan $\Phi(\mathbf{x})$ ni $\mathbf{w}$ en $\mathcal{H}$.
- Si k es semidefinido positivo, el problema sigue siendo un programa cuadrático convexo.

Vectores soporte y generalización

- Solo los vectores soporte determinan el hiperplano: eliminar un punto con $\alpha_i = 0$ no modifica la solución.
- Cota de generalización (Cortes y Vapnik, 1995):

$$\mathbb{E}\big[P(\text{error})\big] \;\leq\; \frac{\mathbb{E}\big[\text{n.° de vectores soporte}\big]}{m}$$

(las esperanzas se toman sobre muestras de entrenamiento).

- La cota no contiene explícitamente la dimensión del espacio de características.
- Por lo tanto, pocos vectores soporte sugieren buena generalización, incluso si $\mathcal{H}$ tiene dimensión muy alta.

Formulación primal con holguras

- Con ruido o clases traslapadas, el hiperplano separador puede no existir.
- Se introducen **variables de holgura** $\xi_i \geq 0$ (con $\Phi(\mathbf{x}) = \mathbf{x}$ se recupera el caso lineal):

$$y_i\big(\langle \mathbf{w}, \Phi(\mathbf{x}_i)\rangle + b\big) \geq 1 - \xi_i, \qquad \xi_i \geq 0$$

$$\min_{\mathbf{w},b,\xi} \ \tfrac{1}{2}\|\mathbf{w}\|^2 + C\sum_{i=1}^{m} \xi_i$$

- $\xi_i = 0$: bien clasificado y fuera del margen; $0 < \xi_i \leq 1$: dentro del margen pero bien clasificado; $\xi_i > 1$: mal clasificado.
- $C > 0$ balancea margen ancho y error de entrenamiento. Es un hiperparámetro: se elige por validación cruzada.

Problema dual con restricción de caja

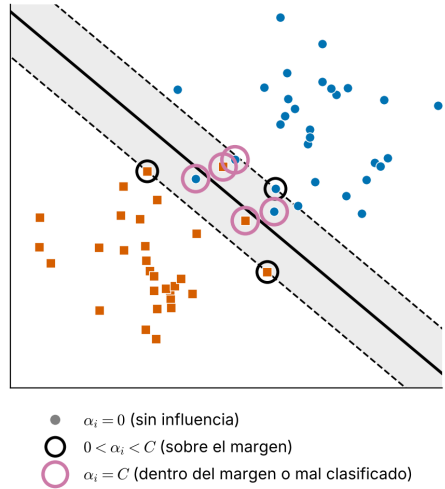
$$\max_{\alpha} \sum_i \alpha_i - \tfrac{1}{2} \sum_{i,j} \alpha_i \alpha_j y_i y_j \, k(\mathbf{x}_i, \mathbf{x}_j) \quad \text{s.a.} \quad 0 \leq \alpha_i \leq C, \ \sum_i \alpha_i y_i = 0$$

- Única diferencia con el margen duro: la cota superior $\alpha_i \leq C$ (aparece al derivar respecto a ξ_i).
- $\mathbf{w} = \sum_i \alpha_i y_i \Phi(\mathbf{x}_i)$ y $f(\mathbf{x}) = \sum_i \alpha_i y_i \, k(\mathbf{x}_i, \mathbf{x}) + b$.

Tres tipos de puntos

- $\alpha_i = 0$: $y_i f(\mathbf{x}_i) \geq 1$. Sin influencia en la solución.
- $0 < \alpha_i < C$: $y_i f(\mathbf{x}_i) = 1$. Sobre el margen ($\xi_i = 0$).
- $\alpha_i = C$: $y_i f(\mathbf{x}_i) \leq 1$. Dentro del margen o mal clasificado ($\xi_i \geq 0$).

Los **vectores soporte** son los puntos con $\alpha_i > 0$.

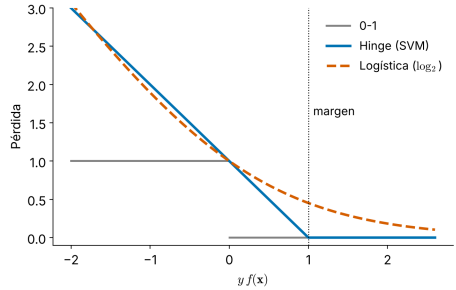


Hinge loss y regularización

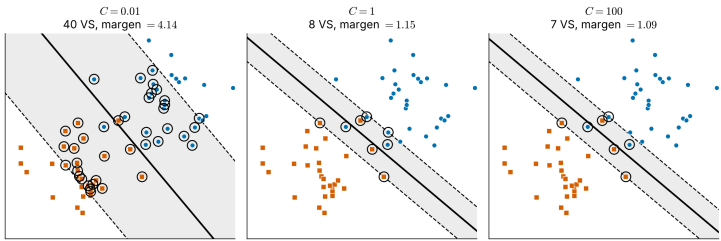
Eliminando las holguras, $\xi_i = \max\left(0, 1 - y_i f(\mathbf{x}_i)\right)$, y el problema es equivalente a

$$\min_{\mathbf{w},b} \sum_{i=1}^{m} \max\left(0,\, 1 - y_i f(\mathbf{x}_i)\right) + \lambda \|\mathbf{w}\|^2, \qquad \lambda = \frac{1}{2C}$$

- Pérdida ***hinge*** más penalización ℓ_2: misma estructura que ridge (ESL, §12.3.2).
- El hinge es una cota superior convexa de la pérdida 0-1.
- Es exactamente cero cuando $y_i f(\mathbf{x}_i) \geq 1$: los puntos fuera del margen no influyen (esparsidad). La pérdida logística nunca es cero.
- C grande $\Leftrightarrow$ λ pequeño $\Leftrightarrow$ poca regularización.



Efecto del hiperparámetro C

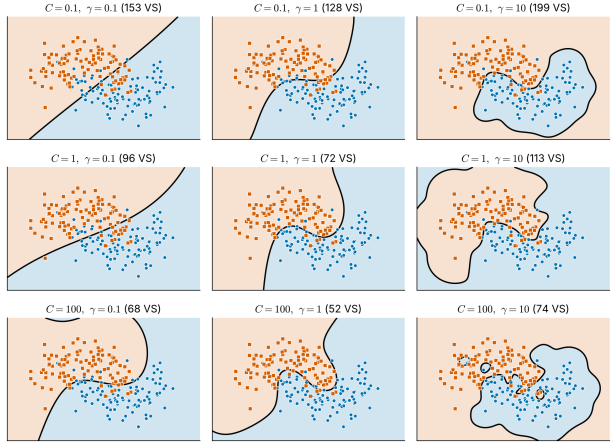


- C pequeño: margen ancho, se toleran muchas violaciones, más vectores soporte; mayor sesgo y menor varianza (riesgo de subajuste).
- C grande: margen estrecho, se penalizan las violaciones; menor sesgo y mayor varianza (riesgo de sobreajuste).
- Algunos textos parametrizan con un ***presupuesto*** de violaciones, lo que invierte el rol de C: verifique la convención de cada texto o software.

Kernel gaussiano: efecto de γ junto con C

$$f(\mathbf{x}) = \sum_{i \in SV} \alpha_i y_i \, e^{-\gamma \|\mathbf{x}_i - \mathbf{x}\|^2} + b$$

- γ pequeño: influencia amplia de cada punto, frontera suave (casi lineal).
- γ grande: influencia local, frontera muy flexible (sobreajuste). Con C pequeño casi todos los puntos terminan como vectores soporte.
- C y γ interactúan: se ajustan **conjuntamente**.



Preprocesamiento y selección de hiperparámetros

- **Estandarizar** las variables antes de usar kernels basados en distancias o productos internos: sin esto, las variables de mayor escala dominan.
- Buscar (C, γ) en una **grilla logarítmica** (p. ej. de 10^{-3} a 10^{3}) con validación cruzada k-fold; reservar un conjunto de prueba independiente para la evaluación final.
- **Desbalance de clases:** ponderar C por clase (`class_weight`) y evaluar con métricas adecuadas (F1, AUC-PR), no solo exactitud.
- **Probabilidades:** $f(\mathbf{x})$ no es una probabilidad; si se necesitan, se calibra la salida (escalamiento de Platt).
- **Costo computacional:** la matriz de Gram es $m \times m$ (memoria $O(m^2)$) y el tiempo de entrenamiento crece típicamente entre cuadrático y cúbico en m. Para m grande, preferir SVM lineal o aproximaciones de kernel.

Demostración en Python

```python
from sklearn.datasets import make_moons
from sklearn.svm import SVC
from sklearn.preprocessing import StandardScaler
from sklearn.pipeline import make_pipeline
from sklearn.model_selection import GridSearchCV

X, y = make_moons(300, noise=0.3, random_state=0)
pipe = make_pipeline(StandardScaler(), SVC(kernel="rbf"))
grid = GridSearchCV(pipe, {"svc__C": [0.01, 0.1, 1, 10, 100],
                           "svc__gamma": [0.01, 0.1, 1, 10]}, cv=5)
grid.fit(X, y)
print(grid.best_params_, grid.best_score_)
print(grid.best_estimator_["svc"].n_support_)  # vectores soporte por clase
```

En `scikit-learn`, `gamma` es el γ de $\exp(-\gamma\|x - x'\|^2)$.

Extensiones

- **Multiclase:** se combinan SVM binarias (uno-contra-uno o uno-contra-resto).
- **Regresión (SVR):** pérdida ε-insensible (ESL, §12.3.6 y §12.3.7).
- **Kernels para datos estructurados:** cadenas de caracteres, grafos.
- **Probabilidades calibradas:** si son el objetivo principal, considerar regresión logística.

Comparación con otros clasificadores lineales

Propiedad	Perceptrón	Regresión logística	SVM
Pérdida	$\max(0, -yf)$	$\log(1 + e^{-yf})$	$\max(0, 1 - yf)$
Solución	cualquier hiperplano separador (no única)	única (con regularización)	hiperplano de margen máximo
Depende de	puntos mal clasificados durante el entrenamiento	todos los puntos	solo vectores soporte
Probabilidades	no	sí	no (requiere calibración)

Resumen

- Los objetos se mapean a un espacio de características $\mathcal{H}$; el producto interno se calcula **en ese espacio** a través de la función kernel.
- La clasificación se realiza con el hiperplano de margen máximo en $\mathcal{H}$.
- Ese hiperplano queda determinado por los vectores soporte ($\alpha_i > 0$); el problema dual depende de los datos solo mediante $k(\mathbf{x}_i, \mathbf{x}_j)$.
- El margen suave relaja las restricciones con variables de holgura y equivale a minimizar ***hinge loss*** más una penalización ℓ_2.
- C controla el balance entre margen máximo y error de entrenamiento; con kernel gaussiano, γ controla la flexibilidad de la frontera. Ambos se eligen por validación cruzada, con variables previamente estandarizadas.

Preguntas para discusión

1. Si se elimina del conjunto de entrenamiento un punto con $\alpha_i = 0$, ¿cambia la solución? ¿Y si se elimina un vector soporte?
2. ¿Cómo varía el número de vectores soporte cuando $C \to 0$ y cuando $C \to \infty$?
3. ¿Por qué conviene estandarizar las variables antes de usar el kernel gaussiano?
4. Muestre que $k(x, x') = (\langle x, x' \rangle + 1)^2$ en $\mathbb{R}^2$ corresponde a un mapeo explícito $\Phi : \mathbb{R}^2 \to \mathbb{R}^6$.

Referencias

- Boser, B. E., Guyon, I. M. y Vapnik, V. N. (1992). A training algorithm for optimal margin classifiers. ***Proceedings of COLT '92***, 144–152. https://doi.org/10.1145/130385.130401
- Cortes, C. y Vapnik, V. (1995). Support-vector networks. ***Machine Learning***, 20, 273–297. https://doi.org/10.1007/BF00994018
- Schölkopf, B. y Smola, A. J. (2002). ***Learning with Kernels***. MIT Press.
- Hastie, T., Tibshirani, R. y Friedman, J. (2009). ***The Elements of Statistical Learning*** (2.ª ed.), cap. 12. Springer.
- James, G., Witten, D., Hastie, T. y Tibshirani, R. (2013). ***An Introduction to Statistical Learning***, cap. 9. Springer.