EST-850

Modelación Estadística de Aplicaciones Multidisciplinarias

Juan Zamora O.

Octubre, 2024.





Estructura

1. Minería de Opiniones
2. Procesamiento de texto para análisis de sentimiento
3. Clasificación de sentimiento usando Machine Learning
4. Conclusiones

Minería de Opiniones

- *Análisis de Sentimiento* busca determinar la polaridad de las opiniones de usuarios (pos,neg o neutra) acerca de un determinado asunto.
- *Clasificación de sentimiento* se refiere al conjunto de métodos que permiten determinar si una oración o documento encierra una polaridad positiva, negativa o neutra.
- Utilidad en diversos dominios masivos.
- Servicios (Salinca 2015), Turísmo (Gräbner et al. 2012), Educación (Sangeetha and Prabha 2021) …
- Tendencias en algunas acciones en mercados financieros (Li et al. 2014)

Carga emotiva en texto

... awesome caramel sauce and sweet toasty almonds. I love this place!

... awful pizza and ridiculously overpriced ...

¿Qué rasgos de estos textos permiten identificar su polaridad?

Palabras positivas y negativas

- A menudo usamos palabras para describir como nos sentimos respecto de *algo*
- Las personas asocian determinadas connotaciones y significados a las palabras
- Algunas son evidentes
  - Amor, amistad, sí… transmiten sentimientos **positivos**.
  - Odio, malo, no … transmiten sentimientos **negativos**.
- Otras no tanto
  - Quizás, indiferente …

- SA basado en lexicons emplea palabras y frases recolectadas y graduadas según polaridad.
- La polaridad de las palabras en el texto es evaluada según el Lexicon para determinar la orientación del texto.

Lexicons generados manualmente

- Existen vocabularios anotados (Lexicon) que permiten identificar la polaridad de cada palabra
- Opinion Lexicon: www.cs.uic.edu/~liub/FBS/sentiment-analysis.html
- Opinion Finder: mpqa.cs.pitt.edu/opinionfinder/
- Linguistic Inquiry and Word Count (LIWC) liwc.wpengine.com/
- Valence Aware Dictionary and sEntiment Reasoner (VADER) github.com/cjhutto/vaderSentiment
- Avanzado: Ver (Hutto and Gilbert 2014)

- … también librerías que permiten componer las polaridades individuales para generar una general por texto
  - **Poco para el castellano**

No volvería , aunque fuera gratis .

```
>>> [{'neg': 0.196, 'neu': 0.804, 'pos': 0.0, 'compound':
    -0.296}
```

Algoritmo aditivo simple de identificación de polaridad

Estrategia

- Usando vocabulario con palabras positivas $(+1)$ y negativas $(+1)$
- Dado un texto t, contabilizar palabras Positivas (**P**) y Negativas (**N**)
- Definir el sentimiento del texto como:

$$sent(t) = \frac{P - N}{P + N}$$

Este método permite identificar la tendencia dominante entre Positiva y Negativa.

Extensión multiplicativa con modificadores

Anteriormente…

- Palabras contribuyen aditivamente a la puntuación de sentimiento
- Ausencia de contexto …
  - Ejemplo: “not pretty” es radicalmente distinto a “pretty”
- Luego, una idea es incorporar el cambio en polaridad multiplicando la valencia de cada palabra por la de su modificadora
- *n-gramas*

Modificadores

- Se define el peso de cada modificador, es decir:
  - *not* $\Rightarrow -1.0$
  - *much* $\Rightarrow +1.3$
  - *very* $\Rightarrow +1.5$
  - *pretty* $\Rightarrow +1.5$
  - *somewhat* $\Rightarrow +1.2$
- Cada palabra encontrada es buscada primero en los modificadores.
- Si no está, se busca en las palabras con valencia (pos o neg).
- Si no es modificadora y tampoco tiene valencia, entonces es una señal de continuar con el sgte. n-grama.

Lexicons generados automáticamente con Corpus

- Existen grandes volúmenes de textos con valoraciones generadas por miles de personas
  - Generalmente, estas valoraciones están en una escala (e.g. 1-5)

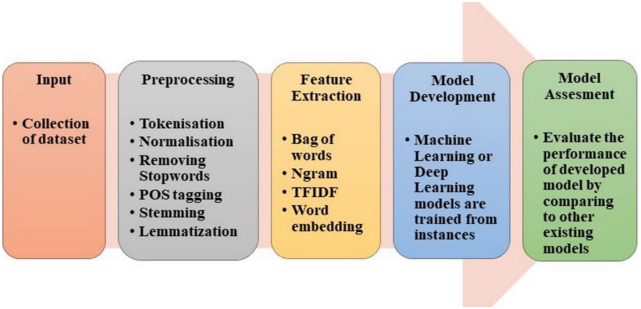
¿Es posible construir lexicons de manera automática?

- Sí, usando Machine Learning.
- Cada lexicon generado es aplicable al dominio de donde se generó
- ¡También tiene sesgos!

Detección de emociones

- A menudo se asocia el análisis de sentimiento con el de emociones
- El reconocimiento de emociones a partir del texto consiste en identificar los sentimientos (alegría, pena, rabia …) plasmados en cada documento.
- Ver (Nandwani and Verma 2021) para más detalle.

Procesamiento de texto para análisis de sentimiento



Fuente (Nandwani and Verma 2021)

Extracción de rasgos para la clasificación de sentimiento

- El enfoque más sencillo es *Bag of Words* (BoW)

$$\vec{d}_{ij} = \mathsf{freq}(d_i, j)$$

- Otra alternativa es *Tf-IDf*

$$\vec{d}_{ij} = \frac{\mathsf{freq}(d_i, j)}{\mathsf{max}\,\mathsf{freq}(d_i, k)} \times \mathtt{log}\,\frac{N}{n_j}$$

Selección características

- Es posible filtrar por frecuencia
- Criterios como χ^2 o información mutua
  - Ver (Madasu and Elango 2020)

Selección de términos usando χ^2

- χ^2 permite medir la relación entre variables
- Se usa para medir relación entre característica (palabra) y la etiqueta de clase (variable objetivo)
- Un valor igual a 0 indica independencia, mientras que valores más altos representan mayor relación
- Se calcula para cada palabra, y contrasta la cantidad de ocurrencias en todos los documentos de cada clase **con** la proporción esperada de su ocurrencia en cada clase

$$\hat{\chi}^2(w_i) = \sum_{k=1}^{C} \frac{n_k}{N} \cdot \chi^2(w_i, c_k)$$

Métodos usados

En general cualquier técnica vectorial:

- Naive Bayes (ejemplo)
- Support Vector Machines
- XGB

Calidad de los resultados obtenidos

- Dado que la tarea es de clasificación, se usan las medidas tradicionales
  - Accuracy = $\frac{TP+TN}{TP+TN+FP+FN}$
  - Precision = $\frac{TP}{TP+FP}$
  - Recall = $\frac{TP}{TP+FN}$
  - F1 = $\frac{2*\text{Precision}*\text{Recall}}{\text{Precision}+\text{Recall}} = \frac{2*TP}{2*TP+FP+FN}$

Selección y Validación del Modelo

Escenario con abundancia de datos

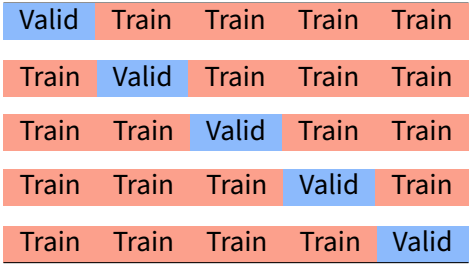
- División de los datos en 3 grupos

Entrenamiento	**Validación**	**Prueba**
—	—	—
Para ajustar los modelos	Estimar desempeño de cada modelo	Evaluación del modelo escogido

- Muchos/Pocos datos depende de la complejidad del modelo, razón señal a ruido de función generadora de los datos …

K-Fold cv

- Datos se dividen en K grupos de igual tamaño
- E.g. $K = 5$



- Se ajusta el modelo con $K - 1$ partes y se calcula el desempeño sobre la restante

- Sea M_θ un método de ML con vector de parámetros θ
- Cada observación i es mapeada a una partición mediante la función

$$\pi : \{1 \dots N\} \longrightarrow \{1 \dots K\}$$

- Anotemos como $\hat{M}_\theta^{-k},\ k \in \{1 \dots K\}$, al método entrenado sin la k-ésima partición del conjunto de datos
- Luego de los K experimentos, el estimador de la desempeño $Q(\hat{M}_\theta)$ es el promedio de los K experimentos

Selección de Modelo usando k-fold cv

Si consideramos un conjunto de modelos $M_{\theta_1}, M_{\theta_2}, ...$ y sus estimaciones de desempeño

El modelo seleccionado será aquel que corresponda al

$$\underset{\theta_i}{\texttt{arg max}}\{Q(\hat{M}_{\theta_1}), Q(\hat{M}_{\theta_2}), ...\}$$

Consideraciones generales

- Valor de k generalmente está entre 5 y 10
- Algunos métodos pueden ser muy sensibles al tamaño del conjunto de entrenamiento, especialmente cuando hay pocos datos (< 100)
- Usar información de la respuesta Y antes de aplicar k-fold cv sobre los mismos datos es trampa
  - Se obtendrá una estimación optimista del error
  - Por ejemplo, seleccionar variables usando Información Mutua sobre todos los datos antes de aplicar CV.

Conclusiones

- Análisis de sentimiento tiene múltiples aplicaciones en diversos dominios
- Existen métodos basados en lexicon, corpus y diccionarios (no abordado)
- Preprocesamiento del texto es clave
- Existe una cantidad considerable de colecciones con textos formales e informales
- Redes sociales es un *nicho* interesante, sobre todo si se consideran problemas como la detección de odio o sarcasmo
- Existe una brecha importante en el desarrollo de métodos para otros idiomas (castellano por ejemplo)

Referencias I

Gräbner, Dietmar, Markus Zanker, Günther Fliedl, and Matthias Fuchs. 2012. "Classification of Customer Reviews Based on Sentiment Analysis." In *Information and Communication Technologies in Tourism 2012*, 460–70. Springer.

Hutto, Clayton, and Eric Gilbert. 2014. "Vader: A Parsimonious Rule-Based Model for Sentiment Analysis of Social Media Text." In *Proceedings of the International AAAI Conference on Web and Social Media*, 8:216–25. 1.

Li, Xiaodong, Haoran Xie, Li Chen, Jianping Wang, and Xiaotie Deng. 2014. "News Impact on Stock Price Return via Sentiment Analysis." *Knowledge-Based Systems* 69: 14–23.

Madasu, Avinash, and Sivasankar Elango. 2020. "Efficient Feature Selection Techniques for Sentiment Analysis." *Multimedia Tools and Applications* 79: 6313–35.

Nandwani, Pansy, and Rupali Verma. 2021. "A Review on Sentiment Analysis and Emotion Detection from Text." *Social Network Analysis and Mining* 11 (1): 81.

Salinca, Andreea. 2015. "Business Reviews Classification Using Sentiment Analysis." In *2015 17th International Symposium on Symbolic and Numeric Algorithms for Scientific Computing (SYNASC)*, 247–50. IEEE.

Referencias II

Sangeetha, K, and D Prabha. 2021. “Sentiment Analysis of Student Feedback Using Multi-Head Attention Fusion Model of Word and Context Embedding for LSTM.” *Journal of Ambient Intelligence and Humanized Computing* 12: 4117–26.